NGHIÊN CỨU HỆ THỐNG HỎI ĐÁP TRỰC QUAN TIẾNG VIỆT HIỆU QUẢ SỬ DỤNG MÔ HÌNH VISION-LANGUAGE

Efficient Vietnamese Visual Question Answering using Vision-Language Models



FPT UNIVERSITY

Phạm Lê Huy Hoàng – SE182670

Hồ Đắc Toàn – SE183249

Trần Quốc Huân – SE193642

Văn Quang Trường – SE182458

Giảng viên hướng dẫn: PGS. Đặng Ngọc Minh Đức

Phạm Minh Trí

Department of Artificial Intelligence

FPT University

This capstone project submitted in partial fulfillment of the requirement for the *Degree of Bachelor of Artificial Intelligence in Computer Science*

FPT University Tháng 12/2026

Lời cam đoan

Chúng tôi cam đoan rằng, ngoại trừ những phần có trích dẫn rõ ràng công trình của người khác, nội dung của khóa luận này là kết quả làm việc của chính nhóm và chưa từng được nộp, toàn bộ hay một phần, để xét cấp bất kỳ văn bằng nào khác tại trường này hay trường khác. Khóa luận là kết quả làm việc chung của bốn thành viên ghi trên trang bìa; trách nhiệm của từng thành viên được trình bày ở Phụ lục A. Khóa luận không chứa kết quả hợp tác với người ngoài nhóm, trừ những phần được nêu rõ trong nội dung và trong lời cảm ơn.

Phạm Lê Huy Hoàng – SE182670
Hồ Đắc Toàn – SE183249
Trần Quốc Huân – SE193642
Văn Quang Trường – SE182458
Tháng 12/2026

Lời cảm ơn

Nhóm xin gửi lời cảm ơn đến PGS. Đặng Ngọc Minh Đức và thầy Phạm Minh Trí đã hướng dẫn nhóm trong suốt học kỳ, đặc biệt là yêu cầu phải có sơ đồ baseline, hiểu dữ liệu và đánh giá rõ ràng trước khi nói đến cải tiến. Nhóm cũng cảm ơn các giảng viên phản biện ở Review 1 và Review 2: các câu hỏi về bài toán, số lượng token, cách tính metric và bằng chứng so với SOTA đã định hình lại nhiều phần của khóa luận này. Cuối cùng, nhóm cảm ơn Trường Đại học FPT đã tạo môi trường học tập và tác giả của các bộ dữ liệu ViVQA và ViTextVQA đã công bố dữ liệu cho cộng đồng.

Tóm tắt

Hỏi đáp trên ảnh tiếng Việt (Vietnamese Visual Question Answering) đòi hỏi mô hình vừa hiểu ảnh vừa đọc được chữ tiếng Việt có dấu trong ảnh, trong khi các vision-language model (VLM) mã nguồn mở chủ yếu được huấn luyện thiên về tiếng Anh và việc fine-tune toàn bộ mô hình vượt quá tài nguyên của một nhóm sinh viên. Khóa luận này nghiên cứu cách thích nghi một VLM cho tiếng Việt chỉ bằng parameter-efficient fine-tuning trên một GPU Google Colab.

Nhóm chọn Qwen2.5-VL-3B-Instruct làm baseline, tái lập nó trên TextVQA val (VQA Accuracy 79,60 so với 79,3 công bố), rồi đo zero-shot trên hai bộ dữ liệu tiếng Việt: ViVQA (ảnh đời thường) và ViTextVQA (ảnh có chữ). Zero-shot chỉ đạt Exact Match (EM) 22,09 và 29,12, chủ yếu do trả lời sai định dạng và sai ngôn ngữ. QLoRA 4-bit với 0,196% tham số huấn luyện nâng EM lên 76,64 trên ViVQA và 50,26 trên ViTextVQA.

Cải tiến đề xuất là **QLoRA nhận biết OCR**: chữ trong ảnh được đọc bằng PaddleOCR và VietOCR, sắp theo thứ tự đọc và đưa vào prompt ngay trong lúc huấn luyện. Trên toàn bộ 10.028 câu test ViTextVQA, phương pháp đạt EM 53,35 và ANLS 73,89, hơn QLoRA thông thường cùng dữ liệu 3,09 điểm EM (kiểm định McNemar $p = 6{,}7 \times 10^{-21}$), ổn định trên ba seed, và cao hơn kết quả công bố tốt nhất trước đây (EM 25,48). Thí nghiệm giai thừa 2×2 cho thấy lợi ích chỉ xuất hiện khi OCR có mặt cả lúc huấn luyện lẫn lúc suy luận (tương tác $+4{,}9$ EM): đóng góp nằm ở việc dạy mô hình dùng OCR, không ở việc thêm OCR vào prompt.

Khóa luận có ablation, phân tích lỗi tự động đối chiếu với duyệt tay mù, và đo hallucination bằng POPE-vi, một bộ 4.985 câu hỏi tiếng Việt do nhóm xây. Kết quả cho thấy EM đánh giá thấp mô hình (khoảng 55% lỗi EM là đúng ý), lỗi đọc chữ tiếng Việt còn chiếm khoảng 17 điểm EM, và hallucination chỉ chiếm khoảng 2–4% câu trả lời. Mọi lần chạy dùng một GPU L4 với VRAM dưới 8,4 GB, có log và gói tái lập. Hệ thống được đóng gói thành một prototype web trả lời kèm chữ OCR làm bằng chứng.

Từ khóa: Vietnamese VQA, vision-language model, QLoRA, parameter-efficient fine-tuning, OCR, scene text, hallucination.

Mục lục

Lời cam đoan **iii**

Lời cảm ơn **v**

Tóm tắt **vii**

Danh sách hình vẽ **xv**

Danh sách bảng **xvii**

Danh mục từ viết tắt **xix**

1 GIỚI THIỆU **1**

1.1 Tổng quan 1

1.1.1 Thông tin đề tài 1

1.1.2 Tổng quan đề tài 2

1.2 Bối cảnh và động lực 4

1.2.1 Hỏi đáp trên ảnh và vision-language model 4

1.2.2 Nhu cầu đọc chữ tiếng Việt trong ảnh 4

1.2.3 Tiếng Việt với các VLM thiên tiếng Anh 5

1.2.4 Thích nghi mô hình lớn với chi phí nhỏ 5

1.2.5 Ràng buộc tài nguyên 6

1.3 Phát biểu bài toán 6

1.3.1 Trả lời đúng định dạng và đúng ngôn ngữ 7

1.3.2 Đọc chữ tiếng Việt có dấu trong ảnh 7

1.3.3 Thứ tự đọc và ranh giới cụm chữ 7

1.3.4 Hạn chế hallucination 7

1.3.5 Thích nghi và đánh giá trong giới hạn tài nguyên 7

1.4 Khoảng trống nghiên cứu 8

1.5 Mục tiêu 9
1.6 Câu hỏi nghiên cứu và giả thuyết 10
1.7 Đóng góp 11
1.8 Ý nghĩa của đề tài 12
1.9 Phạm vi và giới hạn 13
1.9.1 Phạm vi 13
1.9.2 Giới hạn 13
1.9.3 Ngoài phạm vi 15
1.10 Tổ chức nhóm 15
1.10.1 Cơ cấu và vai trò 15
1.10.2 Kế hoạch giao tiếp 16
1.11 Cách tiếp cận quản lý dự án 16
1.11.1 Các giai đoạn 16
1.11.2 Tích hợp các thành phần 17
1.11.3 Quản lý chất lượng và rủi ro 17
1.11.4 Theo dõi tiến độ 17
1.12 Cấu trúc khóa luận 18

2 CÁC NGHIÊN CỨU LIÊN QUAN 19
2.1 Hỏi đáp trên ảnh và VQA đọc chữ trong ảnh 19
2.1.1 Bài toán VQA 19
2.1.2 VQA đọc chữ trong ảnh 19
2.2 Vision-language model 20
2.3 Parameter-efficient fine-tuning 21
2.3.1 Vì sao cần PEFT 21
2.3.2 LoRA 22
2.3.3 QLoRA 22
2.3.4 PEFT cho vision-language model 22
2.4 VQA tiếng Việt 23
2.4.1 Bộ dữ liệu 23
2.4.2 Phương pháp 23
2.5 Hallucination và cách đo 24
2.6 Tổng kết và khoảng trống nghiên cứu 25

3 DỮ LIỆU VÀ PHƯƠNG PHÁP 27
3.1 Tổng quan quy trình 27
3.2 Dữ liệu 29

3.2.1 Hai bộ dữ liệu . . . 29
3.2.2 Chia tập . . . 29
3.2.3 Tiền xử lý: từ file gốc đến bản ghi sạch . . . 30
3.2.4 Chất lượng dữ liệu . . . 31
3.3 Mô hình nền Qwen2.5-VL-3B-Instruct . . . 32
3.3.1 Lý do chọn . . . 32
3.3.2 Kiến trúc . . . 32
3.3.3 Tiền xử lý ảnh . . . 34
3.3.4 Kiểu số và lượng tử hóa . . . 36
3.3.5 Tái lập baseline . . . 36
3.4 Thích nghi bằng QLoRA . . . 37
3.4.1 Cấu hình adapter . . . 37
3.4.2 Nhãn huấn luyện và che nhãn . . . 37
3.4.3 Siêu tham số . . . 38
3.5 Phương pháp đề xuất: QLoRA nhận biết OCR . . . 38
3.5.1 Động lực . . . 38
3.5.2 Đường OCR . . . 39
3.5.3 Chọn cấu hình OCR . . . 41
3.5.4 Prompt . . . 41
3.5.5 Huấn luyện B3 và B3-full . . . 41
3.6 Giao thức đánh giá . . . 41
3.6.1 Chuẩn hóa đáp án . . . 41
3.6.2 Thước đo . . . 42
3.6.3 Kiểm định thống kê . . . 43
3.6.4 Luật quyết định ghi trước . . . 43
3.6.5 Đo hallucination: POPE-vi . . . 43
3.6.6 Phân tích lỗi . . . 44
3.7 Thiết lập thí nghiệm . . . 44
3.8 Thiết kế prototype . . . 45

4 KẾT QUẢ **47**
4.1 Tái lập baseline và kết quả zero-shot . . . 47
4.1.1 Tái lập số đã công bố (R0) . . . 47
4.1.2 Zero-shot trên dữ liệu tiếng Việt (B1) . . . 47
4.2 QLoRA . . . 49
4.3 QLoRA nhận biết OCR . . . 50
4.4 Ablation . . . 51

4.4.1 Chỉ thêm OCR khi suy luận . . . 51
4.4.2 OCR lúc huấn luyện × OCR lúc suy luận . . . 52
4.4.3 Lượng dữ liệu × OCR . . . 52
4.4.4 Độ ổn định theo seed . . . 53
4.4.5 Cấu hình LoRA . . . 53
4.4.6 Một adapter cho hai bộ dữ liệu . . . 54
4.5 Kết quả theo loại câu hỏi ViTextVQA . . . 54
4.6 Chi phí tính toán . . . 54
4.7 Phân tích độ nhạy: ảnh có cờ xoay EXIF . . . 55
4.8 Kiểm chứng prototype . . . 56
4.9 Tổng hợp theo giả thuyết . . . 57

5 THẢO LUẬN 59
5.1 QLoRA sửa loại lỗi nào . . . 59
5.2 Cơ chế của QLoRA nhận biết OCR . . . 59
5.3 Lỗi còn lại của B3-full: do OCR hay do mô hình . . . 60
5.4 Duyệt tay 150 lỗi . . . 61
5.5 Lỗi trên ViVQA . . . 62
5.6 Hallucination . . . 63
5.6.1 Kết luận theo luật . . . 63
5.6.2 Phân tích sau, ngoài luật . . . 64
5.7 Bốn vấn đề tiếng Việt . . . 65
5.8 Ví dụ định tính . . . 65
5.9 Giới hạn và tính hợp lệ . . . 66
5.10 Khía cạnh đạo đức và sử dụng có trách nhiệm . . . 67

6 KẾT LUẬN 69
6.1 Tóm tắt . . . 69
6.2 Trả lời các câu hỏi nghiên cứu . . . 69
6.3 Đóng góp . . . 70
6.4 Giới hạn . . . 71
6.5 Hướng phát triển . . . 71

Tài liệu tham khảo 73

Phụ lục A Kế hoạch quản lý dự án 77
A.1 Phạm vi công việc và ước lượng . . . 77

A.2 Mục tiêu quản lý 77
A.3 Rủi ro 79
A.4 Quy trình dự án 79
A.5 Quản lý chất lượng 82
A.6 Kế hoạch đào tạo 82
A.7 Sản phẩm bàn giao 83
A.8 Phân công trách nhiệm 83
A.9 Giao tiếp trong dự án 85
A.10 Quản lý cấu hình 85

Phụ lục B Gói tái lập **87**
B.1 Thành phần 87
B.2 Môi trường 88
B.3 Dữ liệu 88
B.4 Các mô hình chính thức 89
B.5 Lệnh chạy 89
B.6 Prototype 90
B.7 Độ tất định và giới hạn đã biết 90

Danh sách hình vẽ

1.1 Tổng quan hệ thống ViVQA-VLM với một ví dụ của mỗi bộ dữ liệu. Cột phải là đáp án gold của hai câu hỏi; ô màu cam là chữ OCR thật của ảnh ViTextVQA 16267.jpg, vẫn còn lỗi dấu. Chi tiết từng bước nằm ở Chương 3. 3

3.1 Quy trình tám bước. Bước 3 (OCR) chỉ chạy với ViTextVQA; dòng chữ OCR được lưu cache rồi ghép vào prompt ở bước 5. B1, B2 và B3 đi qua cùng quy trình, chỉ khác ở bước 3 và bước 6. 28
3.2 Qwen2.5-VL-3B-Instruct trong khóa luận: ảnh đi qua Conv3D, vision encoder và MLP merger thành token ảnh; câu hỏi và chữ OCR đi qua tokenizer thành token chữ; LM decoder (4-bit, đóng băng, gắn LoRA) đọc cả chuỗi và sinh câu trả lời. Khung bên trái là cấu trúc một khối của vision encoder. Sơ đồ vẽ lại, phỏng theo Hình 1 trong báo cáo kỹ thuật của Bai và cộng sự [1]. 33
3.3 Tiền xử lý ảnh: từ file ảnh đến lưới token ảnh, với một ví dụ ViVQA (chỉ làm tròn cạnh) và một ví dụ ViTextVQA (thu nhỏ vì vượt trần 512 token). Lưới trên ảnh ViTextVQA chỉ để minh họa. 35
3.4 Đường OCR trên ảnh ViTextVQA 16267.jpg: 13 hộp chữ được dò, đọc và nối thành dòng OCR. Chữ OCR còn nhiễu (“SÓ”, “MIẾN” thay vì “SỐ”, “MIỀN”), trong khi đáp án gold là “đại lý xổ số miền bắc”. 40

4.1 EM trên toàn bộ tập test. Màu xám: mốc so sánh (zero-shot và kết quả công bố); xanh: QLoRA; cam: phương pháp đề xuất QLoRA nhận biết OCR. . . 50
4.2 Hiệu ứng tương tác giữa OCR lúc huấn luyện và OCR lúc suy luận (test2000, train8k). Hai đường cắt nhau: OCR chỉ giúp khi có ở cả hai lúc. 52

Danh sách bảng

1.1 Mục tiêu và tiêu chí hoàn thành 9
1.2 Giả thuyết và câu hỏi nghiên cứu tương ứng 11
1.3 Trong và ngoài phạm vi 14

2.1 So sánh bốn VLM trong phạm vi đề cương 21
2.2 Các cách thích nghi một mô hình lớn 23
2.3 Các nghiên cứu VQA tiếng Việt tiêu biểu 24
2.4 Khoảng trống, bằng chứng và cách khóa luận xử lý 25

3.1 Các lần chạy chính và vai trò của chúng 29
3.2 Hai bộ dữ liệu dùng trong khóa luận 30
3.3 So sánh 512 và 1.280 token ảnh trên ViTextVQA 36
3.4 Số tham số LoRA theo từng phép chiếu ($r = 16$) 37
3.5 Siêu tham số huấn luyện 38

4.1 Tái lập Qwen2.5-VL-3B-Instruct trên TextVQA val (5.000 câu) 48
4.2 Kết quả zero-shot (B1) trên toàn bộ tập test 48
4.3 Zero-shot so với QLoRA trên toàn bộ tập test 49
4.4 Kết quả trên toàn bộ tập test ViTextVQA (10.028 câu) 50
4.5 Thêm dòng OCR chỉ lúc suy luận (test2000) 51
4.6 EM theo OCR lúc huấn luyện và lúc suy luận (test2000, train8k) 52
4.7 EM theo lượng dữ liệu và OCR (toàn bộ test ViTextVQA) 53
4.8 B3 so với B2-sub theo seed (test2000, train8k) 53
4.9 Ablation cấu hình LoRA (test2000, công thức B3) 53
4.10 Adapter dùng chung (SH) so với adapter chuyên biệt cùng ngân sách 54
4.11 EM theo loại câu hỏi trên toàn bộ test ViTextVQA 55
4.12 Chi phí huấn luyện và suy luận (một GPU L4) 55
4.13 Kiểm chứng prototype theo luật đặt trước 56
4.14 Kết luận cho từng giả thuyết 57

5.1 Kiểu lỗi trên các câu sai EM (% số câu sai của từng mô hình) 60
5.2 Thay đổi từ B2 sang B3-full theo trạng thái OCR (toàn bộ test ViTextVQA) 60
5.3 Nguồn lỗi tự động của B3-full (4.678 câu sai) 61
5.4 Kết quả duyệt tay lỗi EM (CI95 Wilson trong ngoặc) 61
5.5 Kiểu lỗi theo nhãn tay (% số lỗi đã duyệt) 62
5.6 Kết quả POPE-vi (500 ảnh chưa thấy khi huấn luyện, 4.985 câu) 63
5.7 Bốn vấn đề tiếng Việt và số đo tương ứng 65
5.8 Ví dụ định tính trên test ViTextVQA và ViVQA 66

A.1 Phân rã công việc 78
A.2 Rủi ro đã xảy ra và cách xử lý 80
A.3 Tuần làm việc và lịch thực (năm 2026) 81
A.4 Các mốc của khoa 81
A.5 Paper nền tảng theo mảng 82
A.6 Sản phẩm bàn giao 83
A.7 Phân công 84
A.8 Kênh giao tiếp 84
A.9 Công cụ và hạ tầng 85

B.1 Thành phần của gói tái lập 87
B.2 Mô hình chính thức và notebook tái lập 89

Danh mục từ viết tắt

Từ viết tắt

ANLS Average Normalized Levenshtein Similarity: độ giống theo ký tự

bf16 bfloat16: số thực 16 bit có dải giá trị rộng như fp32

CI95 Khoảng tin cậy 95%

ECE Expected Calibration Error: sai lệch giữa độ tin cậy và độ chính xác thực tế

EM Exact Match: câu trả lời trùng khít với đáp án sau chuẩn hóa

EXIF Thông tin kèm file ảnh, gồm cờ cho biết ảnh cần xoay khi hiển thị

LoRA Low-Rank Adaptation: thêm hai ma trận hạng thấp vào các lớp tuyến tính và chỉ huấn luyện chúng

MLP Multi-Layer Perceptron: mạng nơ-ron truyền thẳng nhiều lớp

NF4 4-bit NormalFloat: kiểu lượng tử hóa 4-bit

Scene-text VQA VQA mà câu trả lời phải đọc từ chữ xuất hiện trong ảnh

OCR Optical Character Recognition: nhận dạng chữ trong ảnh

PEFT Parameter-Efficient Fine-Tuning: chỉ huấn luyện một phần rất nhỏ các tham số

POPE Polling-based Object Probing Evaluation: đo hallucination bằng câu hỏi có/không

Q-Former Querying Transformer: bộ nối ảnh–ngôn ngữ của BLIP-2

QLoRA LoRA trên mô hình nền đã lượng tử hóa 4-bit (NF4)

SOTA State of the art: kết quả tốt nhất đã công bố

ViT Vision Transformer: bộ mã hóa ảnh dạng transformer, chia ảnh thành các ô (patch)

VLM Vision-Language Model: mô hình nhận cả ảnh và văn bản, sinh văn bản

VQA-Acc VQA Accuracy: min(số đáp án gold trùng / 3, 1)

VQA Visual Question Answering: hỏi đáp trên ảnh

Chương 1

GIỚI THIỆU

Chương này giới thiệu đề tài theo thứ tự từ vấn đề đến giải pháp. Mục 1.1 nêu thông tin chung và hình dung tổng quát về hệ thống. Mục 1.2 trình bày bối cảnh: hỏi đáp trên ảnh, nhu cầu đọc chữ tiếng Việt trong ảnh, những khó khăn riêng của tiếng Việt và ràng buộc tài nguyên. Mục 1.3 phát biểu bài toán và tách nó thành các bài toán con. Các mục 1.4 đến 1.8 nêu khoảng trống nghiên cứu, mục tiêu, câu hỏi nghiên cứu, giả thuyết, đóng góp và ý nghĩa của đề tài. Mục 1.9 xác định phạm vi và giới hạn. Các mục 1.10 và 1.11 tóm tắt cách nhóm tổ chức và quản lý dự án; chi tiết nằm ở Phụ lục A.

1.1 Tổng quan

1.1.1 Thông tin đề tài

- **Tên đề tài:** Nghiên cứu hệ thống hỏi đáp trực quan tiếng Việt hiệu quả sử dụng mô hình Vision-Language.
- **Tên tiếng Anh:** Efficient Vietnamese Visual Question Answering using Vision-Language Models.
- **Tên viết tắt:** ViVQA-VLM.
- **Mã đề tài:** FA26AI29. **Mã nhóm:** GFA26AI35.
- **Học phần:** AIP491, khóa luận tốt nghiệp ngành Trí tuệ nhân tạo, Trường Đại học FPT.
- **Thời gian thực hiện:** 15 tuần, từ ngày 07/09/2026 đến tháng 12/2026.
- **Thành viên:**

  - Phạm Lê Huy Hoàng (SE182670), trưởng nhóm, phụ trách PEFT / Training;
  - Hồ Đắc Toàn (SE183249), phụ trách VLM / Baseline;
  - Trần Quốc Huân (SE193642), phụ trách Dataset / OCR;
  - Văn Quang Trường (SE182458), phụ trách Evaluation / Deployment.
- **Giảng viên hướng dẫn:** PGS. Đặng Ngọc Minh Đức và thầy Phạm Minh Trí.

1.1.2 Tổng quan đề tài

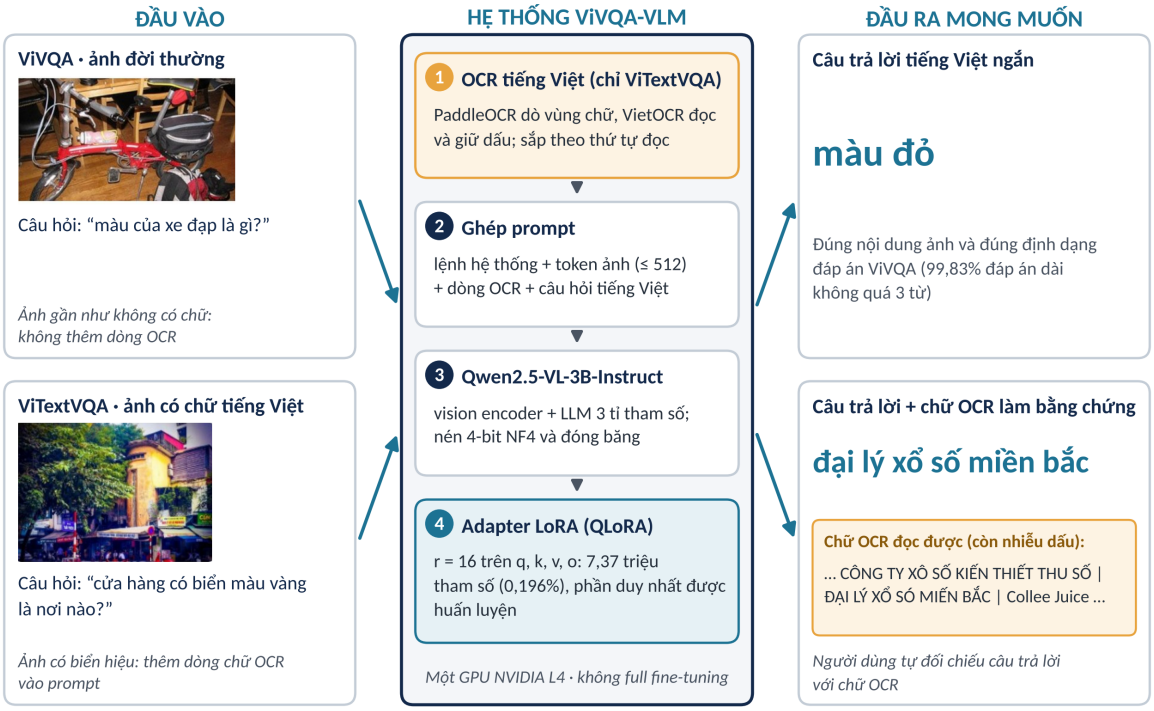
Ảnh chụp bằng điện thoại ngày càng trở thành một cách tra cứu thông tin: người dùng chụp một biển hiệu, một hộp thuốc hay một tờ thực đơn rồi muốn hỏi ngay "cửa hàng này tên gì?", "số điện thoại là bao nhiêu?". Bài toán đứng sau nhu cầu đó là hỏi đáp trên ảnh (Visual Question Answering, VQA). Các vision-language model (VLM) mã nguồn mở hiện nay giải bài toán này khá tốt với tiếng Anh, nhưng với tiếng Việt chúng thường trả lời bằng tiếng Anh, trả lời dài dòng, đọc mất dấu hoặc nói về những thứ không có trong ảnh.

Đề tài này nghiên cứu cách thích nghi một VLM mã nguồn mở cho hỏi đáp trên ảnh tiếng Việt với chi phí nhỏ: chỉ huấn luyện thêm một adapter rất nhỏ, mô hình nền giữ nguyên, và mọi thí nghiệm chạy trên một GPU Google Colab. Hệ thống làm được bốn việc chính:

- trả lời câu hỏi tiếng Việt về nội dung chung của ảnh (màu sắc, số lượng, vật thể, vị trí) bằng câu trả lời ngắn, đúng định dạng;
- đọc chữ tiếng Việt có dấu trên biển hiệu, nhãn hàng, bảng giá để trả lời câu hỏi cần đọc chữ;
- hiển thị kèm dòng chữ OCR đọc được từ ảnh và mức tin cậy, để người dùng tự kiểm tra câu trả lời;
- chạy trên một GPU với bộ nhớ dưới 8,4 GB khi huấn luyện và dưới 5 GB khi dùng prototype.

Hình 1.1 cho thấy hệ thống từ góc nhìn người dùng. Đầu vào là một ảnh và một câu hỏi tiếng Việt. Nếu ảnh có chữ, PaddleOCR [2] dò các vùng chữ và VietOCR [3] đọc chúng, giữ nguyên dấu; dòng chữ này được ghép vào prompt cùng ảnh và câu hỏi. Mô hình nền Qwen2.5-VL-3B-Instruct [1] được nén 4-bit và đóng băng; nhóm chỉ huấn luyện một adapter LoRA chiếm 0,196% số tham số. Đầu ra là câu trả lời tiếng Việt ngắn, kèm chữ OCR làm bằng chứng khi có.

Đề tài được định hướng là một nghiên cứu có thể tái lập, không phải một ứng dụng demo. Vì vậy, trước khi cải tiến, nhóm tái lập baseline trên một benchmark có số đã công bố; mọi



Hình 1.1 Tổng quan hệ thống ViVQA-VLM với một ví dụ của mỗi bộ dữ liệu. Cột phải là đáp án gold của hai câu hỏi; ô màu cam là chữ OCR thật của ảnh ViTextVQA 16267.jpg, vẫn còn lỗi dấu. Chi tiết từng bước nằm ở Chương 3.

cải tiến đều được so với baseline dưới cùng điều kiện, có kiểm định thống kê, ablation, phân tích lỗi và đo hallucination. Sản phẩm của đề tài gồm ba phần: mô hình đã thích nghi cho tiếng Việt, một prototype web đã được kiểm chứng cho cùng câu trả lời với đường đánh giá, và khóa luận kèm gói tái lập (mã nguồn, adapter, cấu hình, script suy luận, log của mọi lần chạy).

1.2 Bối cảnh và động lực

1.2.1 Hỏi đáp trên ảnh và vision-language model

Visual Question Answering (VQA) yêu cầu hệ thống trả lời một câu hỏi bằng ngôn ngữ tự nhiên dựa trên nội dung ảnh [4]. Khác với phân loại ảnh hay phát hiện vật thể, VQA cần hiểu đồng thời ảnh, ngữ nghĩa câu hỏi và đôi khi cả chữ xuất hiện trong ảnh [5, 6]. Các hệ thống VQA ban đầu ghép một bộ mã hóa ảnh (CNN) với một bộ mã hóa câu hỏi (LSTM) và chọn đáp án từ một tập cố định. Cách này hợp với câu hỏi như "có mấy con mèo?" nhưng không hợp với câu hỏi cần đọc chữ: tên một cửa hàng chưa từng xuất hiện trong tập huấn luyện sẽ không bao giờ có trong tập đáp án.

Nhánh VQA đọc chữ trong ảnh (scene-text VQA) ra đời để giải quyết vấn đề này. TextVQA [5] và ST-VQA [6] đưa ra các câu hỏi mà đáp án phải đọc từ chữ trong ảnh, còn M4C [7] cho phép mô hình sao chép từ ngữ trong kết quả OCR vào câu trả lời. Các vision-language model gần đây như BLIP-2 [8], LLaVA [9], Florence-2 [10] và Qwen2.5-VL [1] thay đổi cách tiếp cận: một bộ mã hóa ảnh biến ảnh thành chuỗi token, một mô hình ngôn ngữ lớn đọc chuỗi đó cùng câu hỏi và sinh câu trả lời tự do. Các VLM này trả lời được câu hỏi mở và đọc được chữ trong ảnh ngay ở mức zero-shot, tức là không cần huấn luyện thêm cho tác vụ cụ thể.

1.2.2 Nhu cầu đọc chữ tiếng Việt trong ảnh

Chữ tiếng Việt xuất hiện khắp nơi trong ảnh đời thường: biển hiệu cửa hàng, bảng giá, thực đơn, nhãn hàng hóa, biển chỉ đường, giấy tờ. Nhiều câu hỏi người dùng đặt ra về những ảnh này chỉ trả lời được bằng cách đọc đúng chữ: tên cửa hàng, địa chỉ, số điện thoại, giá tiền, hạn sử dụng. Với những câu hỏi này, câu trả lời gần đúng thường là sai: một chữ số sai trong số điện thoại hay một dấu thanh sai trong tên riêng làm câu trả lời mất giá trị.

Một hệ thống hỏi đáp trên ảnh tiếng Việt đáng tin cậy có thể làm nền cho nhiều ứng dụng: công nghệ hỗ trợ người khiếm thị đọc thông tin xung quanh, tra cứu nhanh thông tin từ ảnh chụp, và số hóa nội dung từ ảnh. Các ứng dụng này cần hệ thống không chỉ hiểu ảnh mà còn đọc đúng chữ có dấu và trả lời bằng tiếng Việt tự nhiên.

1.2.3 Tiếng Việt với các VLM thiên tiếng Anh

Phần lớn VLM mã nguồn mở được tiền huấn luyện chủ yếu trên dữ liệu tiếng Anh và tiếng Trung. Khi dùng cho tiếng Việt, nhóm quan sát bốn vấn đề riêng, ký hiệu V1–V4 và dùng xuyên suốt khóa luận:

V1, đọc chữ có dấu trong ảnh. Dấu thanh là nét rất nhỏ; đọc sai một dấu là đổi nghĩa ("BÁNH MÌ" đọc thành "banh mi"). Vấn đề này nặng hơn khi ảnh phải thu nhỏ để giới hạn số token ảnh, vì nét dấu có thể chỉ còn vài điểm ảnh. Nhiều công cụ OCR được huấn luyện cho chữ Latin cũng làm rơi dấu.

V2, sai ngôn ngữ hoặc sai định dạng. Mô hình trả lời bằng tiếng Anh, chen chữ Trung, hoặc trả lời cả câu dài trong khi đáp án chỉ vài từ. Ví dụ, với câu hỏi "đây là bảo tàng gì?", mô hình trả lời "Bảo tàng Lịch sử Quốc gia." trong khi đáp án là "lịch sử quốc gia". Câu trả lời đúng ý nhưng không khớp đáp án, nên bị chấm sai theo Exact Match.

V3, thứ tự chữ và ranh giới từ. Khoảng trắng trong tiếng Việt tách âm tiết, không tách từ; đọc sai thứ tự các vùng chữ là vỡ từ ("cửa hàng điện thoại" thành "cửa điện hàng thoại"). Một biển hiệu thường có nhiều dòng chữ, nên mô hình còn phải chọn đúng cụm chữ cần trả lời và cắt đúng ranh giới của cụm đó.

V4, hallucination. Câu trả lời trôi chảy nhưng nói về vật hoặc chữ không có trong ảnh. Vì câu trả lời nghe hợp lý, người dùng khó tự phát hiện lỗi, nên vấn đề này ảnh hưởng trực tiếp đến độ tin cậy của hệ thống.

Với dữ liệu tiếng Việt, khoảng cách giữa máy và người còn lớn: trên ViTextVQA [11], kết quả công bố tốt nhất trước khóa luận này là EM 25,48, trong khi người đạt 88,00. Mỗi vấn đề V1–V4 được đo bằng số liệu cụ thể ở Chương 4 và tổng hợp lại ở Chương 5.

1.2.4 Thích nghi mô hình lớn với chi phí nhỏ

Cách thông thường để đưa một mô hình đã tiền huấn luyện vào một tác vụ mới là fine-tune toàn bộ tham số. Với một VLM vài tỉ tham số, cách này cần lưu trọng số, gradient và trạng thái optimizer cho mọi tham số, tức cần nhiều GPU dung lượng lớn. Parameter-efficient fine-tuning (PEFT) giải quyết vấn đề này bằng cách giữ nguyên mô hình nền và chỉ huấn luyện một phần rất nhỏ tham số thêm vào, ví dụ adapter [12, 13] hoặc LoRA [14]. LoRA thêm vào mỗi lớp tuyến tính hai ma trận hạng thấp và chỉ huấn luyện hai ma trận đó. QLoRA [15] đi thêm một bước: mô hình nền được lượng tử hóa 4-bit để giảm bộ nhớ, trong khi adapter LoRA vẫn được huấn luyện ở độ chính xác cao hơn.

Nhờ QLoRA, việc thích nghi một VLM 3 tỉ tham số trở nên khả thi trên một GPU phổ thông. Câu hỏi còn bỏ ngỏ là cách làm này hiệu quả đến đâu với tiếng Việt, và nên đưa thêm thông tin gì vào quá trình thích nghi để mô hình đọc chữ tiếng Việt tốt hơn. Đây là điểm xuất phát của đề tài.

1.2.5 Ràng buộc tài nguyên

Huấn luyện lại toàn bộ một VLM vài tỉ tham số (full fine-tuning) cần nhiều GPU dung lượng lớn, vượt quá điều kiện của một nhóm sinh viên. Trường không có máy chủ GPU cho đề tài, nên mọi thí nghiệm chạy trên Google Colab, chủ yếu trên một GPU NVIDIA L4 24 GB. Ngân sách tính toán là hữu hạn: một lần huấn luyện QLoRA trên toàn bộ ViTextVQA mất khoảng 12 giờ L4, nên số lần huấn luyện đầy đủ là ràng buộc lớn nhất của kế hoạch thí nghiệm.

Đề tài vì vậy đặt hiệu quả thành một ràng buộc thiết kế tường minh: chỉ dùng parameter-efficient fine-tuning (LoRA [14], QLoRA [15]) và báo cáo kèm thời gian huấn luyện, thời gian suy luận và bộ nhớ GPU cho mọi kết quả. Ràng buộc này cũng ảnh hưởng đến các lựa chọn thiết kế khác, ví dụ số token ảnh tối đa (Chương 3): mỗi lựa chọn được đo chi phí trước khi chốt, thay vì chọn cấu hình lớn nhất có thể chạy.

1.3 Phát biểu bài toán

Cho ảnh I và câu hỏi tiếng Việt q, hệ thống sinh câu trả lời tiếng Việt $\hat{a} = f(I, q)$. Câu trả lời được so với đáp án gold a sau cùng một bước chuẩn hóa văn bản. Hai bộ dữ liệu đặt ra hai yêu cầu khác nhau:

- **ViVQA** [16]: câu hỏi chung về ảnh (màu sắc, số lượng, vật thể, vị trí); 99,83% đáp án dài không quá 3 từ, nên EM và VQA-Acc là thước đo phù hợp.
- **ViTextVQA** [11]: đáp án là chữ đọc được trong ảnh, trung bình 4,18 từ; ANLS [6] được dùng thêm vì chịu được lỗi đọc nhỏ ở mức ký tự.

Với ví dụ của ViVQA, câu hỏi "màu của xe đạp là gì?" có đáp án "màu đỏ". Với ví dụ của ViTextVQA, câu hỏi "cửa hàng có biển màu vàng là nơi nào?" có đáp án "đại lý xổ số miền Bắc", chữ lấy trực tiếp từ biển hiệu (Hình 1.1). Hàm f phải được xây dựng bằng cách thích nghi một VLM mã nguồn mở chỉ bằng PEFT, chạy trên một GPU Colab. Bài toán chung này được tách thành năm bài toán con dưới đây.

1.3.1 Trả lời đúng định dạng và đúng ngôn ngữ

Bài toán con đầu tiên là làm cho mô hình trả lời đúng kiểu đáp án của từng bộ dữ liệu: ngắn, bằng tiếng Việt, không giải thích thêm. Ở chế độ zero-shot, câu trả lời của mô hình dài trung bình 2,9 từ so với 1,6 từ của đáp án trên ViVQA, và 5,4 từ so với 3,7 từ trên ViTextVQA; 18% câu ViTextVQA có câu trả lời chứa đúng đáp án nhưng vẫn trượt EM. Nếu không giải quyết vấn đề định dạng này, mọi so sánh khác đều bị che lấp bởi lỗi định dạng.

1.3.2 Đọc chữ tiếng Việt có dấu trong ảnh

Bài toán con thứ hai là đọc đúng chữ có dấu. Để giới hạn chi phí, mỗi ảnh được biểu diễn bằng tối đa 512 token ảnh; 57,7% ảnh ViTextVQA chạm mức trần này và phải thu nhỏ, khiến nét dấu càng khó nhận ra. Dùng một công cụ OCR riêng để đọc chữ từ ảnh gốc là một hướng bù lại, nhưng công cụ OCR cũng có thể làm rơi dấu: bộ nhận dạng Latin của PaddleOCR đọc "Kiểu Thẩm" thành "Kiu Thm". Câu hỏi đặt ra là chọn công cụ OCR nào và đưa kết quả OCR vào mô hình như thế nào.

1.3.3 Thứ tự đọc và ranh giới cụm chữ

Một ảnh ViTextVQA thường có nhiều vùng chữ: tên cửa hàng, khẩu hiệu, số điện thoại, địa chỉ. Bài toán con thứ ba là sắp các vùng chữ theo đúng thứ tự đọc, rồi chọn đúng cụm chữ và cắt đúng ranh giới cụm cần trả lời. Ví dụ, đáp án là "ủy ban nhân dân quận 2" nhưng mô hình chỉ trả lời "nhân dân quận 2": đọc đúng chữ nhưng cắt sai ranh giới, nên vẫn bị chấm sai.

1.3.4 Hạn chế hallucination

Bài toán con thứ tư là bảo đảm việc thích nghi không làm mô hình bịa nội dung nhiều hơn. Huấn luyện mô hình trả lời ngắn và tự tin có thể vô tình khuyến khích mô hình trả lời cả khi ảnh không có thông tin. Trước khóa luận này chưa có bộ đo hallucination kiểu POPE [17] cho tiếng Việt, nên bài toán con này gồm cả việc xây công cụ đo.

1.3.5 Thích nghi và đánh giá trong giới hạn tài nguyên

Bài toán con cuối cùng là phương pháp: thích nghi mô hình với dưới 1% tham số được huấn luyện trên một GPU, và đánh giá sao cho kết luận đáng tin. EM là thước đo khắt khe, câu trả lời đúng ý nhưng khác cách viết vẫn bị tính sai; mỗi lần huấn luyện đầy đủ lại tốn khoảng 12 giờ GPU, nên không thể chạy lặp nhiều lần. Do đó cần một giao thức đánh giá cố định,

kiểm định thống kê ghép cặp trên cùng tập test, và thiết kế thí nghiệm sao cho mỗi bước chỉ đổi một yếu tố.

Các yếu tố làm bài toán khó hơn. Ngoài năm bài toán con trên, dữ liệu có một số đặc điểm khiến việc huấn luyện và đánh giá phức tạp hơn:

- một phần đáp án gold bị sai: khi duyệt tay lỗi của mô hình, 12,5% lỗi là do gold sai, riêng ViVQA là 19%;
- câu hỏi ViVQA được dịch máy từ COCO-QA [18] nên đôi khi không tự nhiên, và bộ dữ liệu không có câu hỏi có/không;
- ViVQA không có tập validation, và khoảng 46% câu test dùng ảnh đã xuất hiện trong tập train, tạo nguy cơ đánh giá quá cao;
- ViTextVQA không có nhãn loại câu hỏi, nên khó phân rã lỗi theo loại câu hỏi;
- một số ảnh chụp bằng điện thoại có cờ xoay EXIF; nếu bỏ qua cờ này, OCR đọc chữ nằm nghiêng và cho ra chữ vô nghĩa.

Những đặc điểm này được đo và xử lý ở Chương 3 mà không thay đổi tập train và test chính thức, để kết quả vẫn so sánh được với các công trình trước.

1.4 Khoảng trống nghiên cứu

Từ khảo sát tài liệu ở Chương 2, nhóm xác định bốn khoảng trống:

G1. Tiền huấn luyện thiên lệch tiếng Anh: mô hình zero-shot trả lời bằng tiếng Anh và sai định dạng khi gặp câu hỏi tiếng Việt.

G2. VQA tiếng Việt còn yếu, nhất là với scene-text: SOTA ViTextVQA là EM 25,48 so với 88,00 của người.

G3. Thích nghi VLM cho VQA tiếng Việt bằng PEFT chưa được nghiên cứu: các công trình VQA tiếng Việt trong nhóm khảo sát đều huấn luyện mô hình riêng hoặc dùng mô hình đóng băng, không dùng LoRA/QLoRA trên VLM lớn.

G4. Chưa có cách đo hallucination cho VQA tiếng Việt: chưa có benchmark kiểu POPE [17] bằng tiếng Việt.

Các khoảng trống này liên quan với nhau. G1 giải thích vì sao một VLM mạnh vẫn cho kết quả thấp khi dùng trực tiếp cho tiếng Việt. G2 cho thấy khoảng cách lớn nhất nằm ở câu hỏi đọc chữ. G3 là chỗ trống về phương pháp: chưa có câu trả lời cho câu hỏi "chỉ huấn luyện một adapter nhỏ trên một VLM mở thì được bao nhiêu, và nên huấn luyện với thông tin gì". G4 là chỗ trống về đánh giá: không đo được hallucination thì không biết việc thích nghi có làm hệ thống kém tin cậy đi hay không.

Khóa luận tập trung vào G3 và dùng G2, G4 làm nơi kiểm chứng. Bảng đối chiếu từng khoảng trống với bằng chứng trong tài liệu và cách khóa luận xử lý được trình bày ở Chương 2.

1.5 Mục tiêu

Mục tiêu tổng quát là thích nghi một VLM mã nguồn mở cho VQA tiếng Việt dưới ngân sách tham số nghiêm ngặt và kiểm chứng bằng thực nghiệm ít nhất một cải tiến so với baseline đã tái lập. Mục tiêu này được chia thành các mục tiêu cụ thể trong Bảng 1.1, mỗi mục tiêu có tiêu chí đo lường.

Bảng 1.1 Mục tiêu và tiêu chí hoàn thành

Mục tiêu	**Tiêu chí hoàn thành**
Tái lập đúng một baseline	Chạy lại Qwen2.5-VL-3B-Instruct trên một benchmark có số công bố và đạt sai lệch nhỏ (TextVQA val: nhóm đạt 79,60 so với 79,3 công bố)
Đo baseline zero-shot trên dữ liệu tiếng Việt	EM, VQA-Acc, ANLS trên toàn bộ test ViVQA và Vi-TextVQA, cùng một giao thức
Thích nghi chỉ bằng PEFT	QLoRA 4-bit, số tham số huấn luyện $< 1\%$, chạy trên một GPU Colab
Đề xuất và kiểm chứng ≥ 1 cải tiến	Cải tiến so với baseline dưới điều kiện y hệt, có kiểm định thống kê ghép cặp và ablation
Phân tích lỗi và hallucination	Phân rã lỗi theo loại câu hỏi và loại lỗi; đo hallucination kiểu POPE cho tiếng Việt
Prototype web	Tải ảnh, hỏi tiếng Việt, nhận câu trả lời kèm chữ OCR và mức tin cậy; cho cùng kết quả với đường đánh giá
Tái lập được	Mọi run ghi lại split, seed, phần cứng, siêu tham số, thời gian; gói tái lập gồm code, adapter, config, script suy luận

Để đạt các mục tiêu trên, nhóm đi theo một lộ trình sáu bước, trong đó mỗi bước chỉ thay đổi một yếu tố so với bước trước.

Bước 1: Tái lập baseline. Nhóm chạy lại Qwen2.5-VL-3B-Instruct trên TextVQA val với cấu hình gốc và so với số trong báo cáo kỹ thuật của mô hình. Bước này kiểm tra toàn bộ đường nạp mô hình, dựng prompt và chấm điểm trước khi dùng nó cho tiếng Việt.

Bước 2: Đo zero-shot trên dữ liệu tiếng Việt. Với cấu hình tiết kiệm (4-bit, tối đa 512 token ảnh), nhóm đo mô hình chưa huấn luyện trên toàn bộ tập test của hai bộ dữ liệu. Kết quả này là mốc so sánh cho mọi bước sau và cho biết lỗi tiếng Việt nào chiếm ưu thế.

Bước 3: Thích nghi bằng QLoRA. Nhóm huấn luyện adapter LoRA trên mô hình nền 4-bit, không thêm thông tin gì vào prompt, để đo riêng tác dụng của PEFT so với zero-shot.

Bước 4: QLoRA nhận biết OCR. Từ phân tích lỗi của bước 3, nhóm thêm dòng chữ OCR tiếng Việt vào prompt ngay trong lúc huấn luyện. Phép thử có kiểm soát được chạy trước trên một tập con 8.000 câu, so với QLoRA thường trên cùng tập con; khi kết quả đã rõ mới chạy trên toàn bộ dữ liệu.

Bước 5: Phân tích. Nhóm làm ablation cho từng thành phần, kiểm tra độ ổn định qua ba seed, phân tích lỗi tự động đối chiếu với duyệt tay, và đo hallucination bằng bộ POPE tiếng Việt do nhóm xây.

Bước 6: Prototype và gói tái lập. Nhóm đóng gói mô hình thành một prototype web, kiểm chứng prototype cho cùng câu trả lời với đường đánh giá, và chuẩn bị gói tái lập để người khác chạy lại từng con số.

1.6 Câu hỏi nghiên cứu và giả thuyết

RQ1. Zero-shot đạt bao nhiêu trên ViVQA và ViTextVQA, và lỗi tiếng Việt nào chiếm ưu thế?

RQ2. QLoRA cải thiện bao nhiêu so với zero-shot, khi không dùng full fine-tuning?

RQ3. Chữ OCR có dấu, đúng thứ tự đọc, có giúp mô hình đọc chữ trong ảnh không, và có cộng hưởng với QLoRA không?

RQ4. Sau khi thích nghi bằng QLoRA, mô hình bịa nội dung nhiều hơn hay ít hơn?

RQ1 xác định điểm xuất phát và loại lỗi cần sửa. RQ2 là câu hỏi trung tâm, ứng với khoảng trống G3. RQ3 kiểm tra cải tiến đề xuất trên phần khó nhất của bài toán là câu hỏi đọc chữ (G2). RQ4 kiểm tra mặt trái của việc thích nghi (G4).

Mỗi giả thuyết trong Bảng 1.2 có ngưỡng định lượng được ghi lại trước khi chạy thí nghiệm tương ứng. Nhờ ngưỡng ghi trước, kết luận "ủng hộ", "ủng hộ một phần" hay "không ủng hộ" được quyết định theo luật đã đặt, không theo cảm nhận sau khi thấy kết quả.

Bảng 1.2 Giả thuyết và câu hỏi nghiên cứu tương ứng

ID	**Giả thuyết**	**Trả lời**
H1	QLoRA trên Qwen2.5-VL-3B tăng EM ít nhất 5 điểm so với chính mô hình đó ở chế độ zero-shot.	RQ2; V1–V3
H2	Chữ OCR có dấu, sắp xếp từ trái-trên đến phải-dưới, đưa vào prompt tăng ANLS ít nhất 3 điểm trên ViTextVQA; kết hợp với QLoRA cho kết quả cao nhất.	RQ3; V1, V3
H3	Prompt định dạng tiếng Việt (trả lời ngắn, có dấu) tăng EM ít nhất 3 điểm và giảm câu trả lời sai ngôn ngữ hoặc mất dấu.	RQ1; V2
H4	QLoRA không làm tăng tỉ lệ hallucination so với zero-shot.	RQ4; V4

Kết quả cho từng câu hỏi nghiên cứu được báo cáo ở Chương 4, phân tích nguyên nhân ở Chương 5, và câu trả lời tổng hợp nằm ở Chương 6.

1.7 Đóng góp

Nhóm chọn Qwen2.5-VL-3B-Instruct [1] làm baseline, tái lập baseline này trước, rồi thích nghi nó cho tiếng Việt chỉ bằng QLoRA. Mô hình nền 3 tỉ tham số được lượng tử hóa 4-bit và giữ nguyên; nhóm chỉ huấn luyện 7,37 triệu tham số adapter, tức 0,196% tổng số tham số, trên một GPU NVIDIA L4. Các đóng góp của khóa luận gồm:

1. **QLoRA nhận biết OCR.** Văn bản đọc được trong ảnh bằng VietOCR (giữ dấu, sắp theo thứ tự đọc) được đưa vào prompt ngay trong lúc huấn luyện, để adapter học cách dùng nó. Trên toàn bộ tập test ViTextVQA (10.028 câu), cách này đạt EM 53,35 so với 50,26 của QLoRA thông thường với cùng dữ liệu (+3,09 EM, kiểm định McNemar $p = 6{,}7 \times 10^{-21}$), và cao hơn kết quả công bố tốt nhất trên cùng tập test (ViTextBLIP-2, EM 25,48 [11]).

2. **Một cơ chế được tách bạch.** Thí nghiệm 2×2 cho thấy OCR chỉ có ích khi được dùng cả lúc huấn luyện lẫn lúc suy luận: đưa OCR vào prompt của một mô hình chưa từng thấy OCR không cải thiện kết quả.

3. **Kết quả trên VQA tiếng Việt tổng quát.** Trên ViVQA, QLoRA nâng EM từ 22,09 (zero-shot) lên 76,64.

4. **Bộ đo hallucination tiếng Việt.** POPE-vi, gồm 4.985 câu hỏi có/không trên 500 ảnh chưa thấy khi huấn luyện.

5. **Phân tích và prototype đã kiểm chứng.** Ablation cho từng thành phần, phân tích lỗi tự động và duyệt tay, và một prototype web đã được kiểm chứng cho ra cùng câu trả lời với đường đánh giá chính thức.

1.8 Ý nghĩa của đề tài

Ý nghĩa khoa học. Khóa luận cung cấp một nghiên cứu có hệ thống về PEFT cho VLM trên VQA tiếng Việt, gồm baseline tái lập, ablation cho từng thành phần và kiểm định thống kê ghép cặp. Kết quả chính không chỉ là một con số cao hơn mà còn là một cơ chế được tách bạch: lợi ích của OCR đến từ việc huấn luyện mô hình dùng OCR, không đến từ việc thêm OCR vào prompt. Nhóm cũng đưa ra bộ POPE tiếng Việt để đo hallucination và một phân tích có số đo cho từng vấn đề V1–V4. Các kết quả này có thể dùng làm mốc so sánh cho các nghiên cứu VQA tiếng Việt sau.

Ý nghĩa phương pháp. Mọi kết luận trong khóa luận dựa trên luật quyết định được ghi lại trước khi chạy, kiểm định ghép cặp trên cùng tập test, và log đầy đủ (split, seed, GPU, thời gian). Quy trình này giúp tránh việc chọn kết quả sau khi đã thấy số liệu, và cho phép người khác chạy lại từng con số từ mã nguồn công khai. Khóa luận cũng báo cáo cả những kết quả không như kỳ vọng, ví dụ giả thuyết H3 không được ủng hộ, để người đọc thấy đầy đủ bức tranh.

Ý nghĩa thực tiễn. Hệ thống đọc và trả lời câu hỏi về biển hiệu, nhãn hàng, bảng giá, thực đơn và biểu mẫu tiếng Việt. Đây là chức năng nền cho công nghệ hỗ trợ người khiếm thị và cho các ứng dụng tra cứu thông tin từ ảnh. Prototype trả lời kèm chữ OCR và mức tin cậy, nên người dùng có cơ sở để tự kiểm tra câu trả lời thay vì tin tuyệt đối vào mô hình.

Ý nghĩa về chi phí. Vì chỉ cần một GPU và một adapter 29,5 MB, cách làm có thể áp dụng cho các nhóm nghiên cứu, doanh nghiệp nhỏ hoặc tổ chức có tài nguyên hạn chế. Một mô hình nền có thể dùng chung cho nhiều tác vụ, mỗi tác vụ chỉ cần lưu thêm một adapter nhỏ; khóa luận cũng cho thấy một adapter dùng chung cho cả hai bộ dữ liệu không kém adapter riêng cho từng bộ.

Ý nghĩa đối với tiếng Việt. Phần lớn tiến bộ của VLM được đo trên tiếng Anh. Khóa luận chỉ ra cụ thể những gì bị mất khi dùng các mô hình này cho tiếng Việt (dấu thanh, định dạng, thứ tự chữ, hallucination) và một cách bù lại với chi phí nhỏ. Cách tiếp cận này có thể áp dụng cho các ngôn ngữ ít tài nguyên khác có chữ viết dùng dấu.

1.9 Phạm vi và giới hạn

1.9.1 Phạm vi

Dữ liệu. Đề tài dùng hai bộ dữ liệu công khai ViVQA và ViTextVQA với split chính thức cố định. ViVQA không có tập validation nên nhóm tách 1.200 câu từ tập train (seed 42) để chọn mô hình; tập test giữ nguyên. Nhóm không thu thập thêm dữ liệu huấn luyện và không tăng cường dữ liệu, để kết quả so sánh được với các công trình trước trên cùng tập test.

Mô hình và cách thích nghi. Đề tài dùng đúng một baseline là Qwen2.5-VL-3B-Instruct. Các VLM khác chỉ được dùng để tham khảo khi chọn baseline. Việc thích nghi chỉ dùng QLoRA 4-bit; chữ OCR là đầu vào phụ được ghép vào prompt, không phải một mô-đun được huấn luyện.

Đánh giá. Thước đo chính là EM, VQA-Acc và ANLS; token-F1 chỉ là chỉ số phụ để so với công trình trước. Mọi so sánh dùng cùng giao thức: cùng split, seed, cấu hình suy luận và cùng một bước chuẩn hóa đáp án. Ngoài kết quả chính, đề tài có ablation, phân tích lỗi và đo hallucination.

Prototype. Prototype là một ứng dụng web chạy trên Colab với một GPU, nhận ảnh và câu hỏi tiếng Việt, trả về câu trả lời kèm chữ OCR và mức tin cậy. Prototype dùng để minh họa và kiểm chứng, không phải một sản phẩm triển khai cho nhiều người dùng.

Bảng 1.3 tóm tắt những gì nằm trong và ngoài phạm vi.

1.9.2 Giới hạn

Giới hạn về mô hình. Kết quả bị giới hạn bởi một mô hình nền 3 tỉ tham số ở dạng 4-bit. Lượng tử hóa làm giảm độ chính xác so với cấu hình gốc, và một mô hình lớn hơn có thể cho kết quả khác. Khóa luận không khẳng định kết quả giữ nguyên với các backbone khác.

Bảng 1.3 Trong và ngoài phạm vi

Trong phạm vi	Ngoài phạm vi
Hai bộ dữ liệu ViVQA và ViTextVQA, split cố định	Xây bộ dữ liệu huấn luyện mới hoặc tăng cường dữ liệu
Một baseline Qwen2.5-VL-3B-Instruct; các VLM khác chỉ để tham khảo	So sánh nhiều backbone như baseline chính
Thích nghi chỉ bằng PEFT (QLoRA 4-bit); chữ OCR làm đầu vào phụ	Full fine-tuning; huấn luyện VLM từ đầu
Metric EM, VQA-Acc, ANLS (token-F1 làm chỉ số phụ); ablation, phân tích lỗi, hallucination	Retrieval-augmented VQA với tri thức ngoài
Prototype web chạy trên Colab với một GPU	Triển khai sản phẩm quy mô lớn, ứng dụng di động

Giới hạn về OCR. Phương pháp đề xuất phụ thuộc vào chất lượng OCR. Khi dòng OCR không chứa đúng đáp án, mô hình khó trả lời đúng; ảnh mờ, chữ nhỏ hoặc chữ nghệ thuật vẫn có thể làm OCR đọc sai dấu hoặc ra chữ vô nghĩa.

Giới hạn về dữ liệu. Một phần đáp án gold bị sai, câu hỏi ViVQA được dịch máy, và ViVQA không có câu hỏi có/không. Nhóm đo các vấn đề này và báo cáo riêng, nhưng không sửa tập test chính thức.

Giới hạn về đánh giá. EM là thước đo khắt khe với câu trả lời đúng ý nhưng khác cách viết, nên nhóm bổ sung ANLS và duyệt tay. So sánh với công trình trước còn phụ thuộc vào cách chuẩn hóa đáp án mà các công trình đó không công bố đầy đủ; nhóm báo cáo thêm token-F1 để giảm ảnh hưởng của điểm này.

Giới hạn về thống kê. Mọi thí nghiệm chính chạy với một seed; riêng phần so sánh OCR được kiểm thêm trên ba seed ở tập con 8.000 câu. Mô hình đầy đủ B3-full chỉ có một seed vì mỗi lần huấn luyện tốn khoảng 12,75 giờ GPU.

Giới hạn về prototype. Mức tin cậy của prototype chưa được hiệu chỉnh tốt, nên giao diện chỉ hiển thị mức Cao, Trung bình, Thấp thay vì một con số phần trăm. Prototype chạy trong một phiên Colab nên không có tính sẵn sàng như một dịch vụ thật.

Các giới hạn này được phân tích lại ở Chương 5 và Chương 6.

1.9.3 Ngoài phạm vi

Các nội dung sau nằm ngoài phạm vi của khóa luận:

- full fine-tuning hoặc huấn luyện VLM từ đầu;
- xây bộ dữ liệu huấn luyện mới, gán nhãn thêm hoặc tăng cường dữ liệu;
- huấn luyện lại hoặc fine-tune mô hình OCR;
- retrieval-augmented VQA với nguồn tri thức bên ngoài ảnh;
- so sánh nhiều backbone như nhiều baseline chính;
- triển khai sản phẩm quy mô lớn, ứng dụng di động hoặc dịch vụ trực tuyến lâu dài;
- các câu hỏi về video hoặc nhiều ảnh cùng lúc.

Giả định. Nhóm giả định rằng split chính thức của hai bộ dữ liệu đại diện cho phân bố câu hỏi thực tế của từng bộ, rằng đáp án gold là đúng ở đa số câu (phần gold sai được đo và báo cáo riêng ở Chương 4), và rằng GPU L4 trên Colab cho kết quả ổn định giữa các phiên khi cố định seed và cấu hình.

1.10 Tổ chức nhóm

1.10.1 Cơ cấu và vai trò

Nhóm có bốn sinh viên, mỗi người phụ trách một mảng kỹ thuật theo đề cương.

Phạm Lê Huy Hoàng (SE182670) là trưởng nhóm và phụ trách mảng PEFT / Training. Ngoài việc huấn luyện các mô hình QLoRA, làm ablation cấu hình LoRA và xây adapter dùng chung, Hoàng điều phối tiến độ, tích hợp kết quả của các mảng và duyệt các kết quả liên mảng.

Hồ Đắc Toàn (SE183249) phụ trách mảng VLM / Baseline: tìm hiểu kiến trúc Qwen2.5-VL, tái lập baseline zero-shot và đối chiếu với số đã công bố.

Trần Quốc Huân (SE193642) phụ trách mảng Dataset / OCR: lấy dữ liệu từ nguồn chính thức, cố định split, kiểm tra rò rỉ giữa train và test, và tạo OCR cache bằng PaddleOCR và VietOCR.

Văn Quang Trường (SE182458) phụ trách mảng Evaluation / Deployment: cài đặt các thước đo, kiểm định thống kê, đo hallucination, xây prototype và video demo.

Bảng phân công chi tiết, kèm thư mục mã nguồn chính của từng người, nằm ở Phụ lục A.

1.10.2 Kế hoạch giao tiếp

Nhóm làm việc với giảng viên hướng dẫn theo các mốc của khoa và khi cần xác nhận một quyết định lớn, ví dụ việc chốt baseline Qwen2.5-VL-3B ngày 07/10/2026. Sau mỗi buổi review với giảng viên phản biện, nhóm điền checklist góp ý, gửi email cho giảng viên hướng dẫn và giảng viên review, rồi tải lên thư mục chung.

Trong nhóm, mỗi tuần làm việc có một README và một Team Report trong thư mục `docs/Wxx/` của repo, ghi việc đã làm, kết quả, quyết định và việc dời lại. Mã nguồn, log nhỏ và tài liệu được quản lý trên GitHub; ảnh, adapter, OCR cache và video demo được lưu trên Google Drive. Các quyết định ảnh hưởng đến kết quả chính được ghi lại trước khi chạy và được giảng viên hướng dẫn xác nhận khi cần.

1.11 Cách tiếp cận quản lý dự án

Vì đây là một đề tài nghiên cứu, kế hoạch xoay quanh thí nghiệm: mỗi kết luận ở Chương 4 phải truy ngược được về một lần chạy có log, seed và cấu hình cố định. Mục này tóm tắt cách nhóm tổ chức công việc; Phụ lục A trình bày đầy đủ phân rã công việc, lịch, rủi ro và quản lý chất lượng.

1.11.1 Các giai đoạn

Dự án được chia thành năm giai đoạn theo khung 15 tuần của đề cương:

Giai đoạn 1: Định hướng và lập kế hoạch (W01–W03). Nhóm đọc paper theo bốn mảng, lập literature matrix, phân tích hai bộ dữ liệu, xác định khoảng trống nghiên cứu, câu hỏi nghiên cứu và giả thuyết, rồi trình bày ở Review 1.

Giai đoạn 2: Dữ liệu và baseline (W04–W07). Nhóm lấy dữ liệu từ nguồn chính thức, chốt baseline Qwen2.5-VL-3B-Instruct, đo zero-shot, tái lập số công bố trên TextVQA và chốt cấu hình suy luận dựa trên số đo (số token ảnh, kiểu số).

Giai đoạn 3: Thích nghi và cải tiến (W07–W10). Nhóm huấn luyện QLoRA thường, phân tích lỗi, đề xuất QLoRA nhận biết OCR, kiểm chứng trên tập con 8.000 câu, kiểm tra qua ba seed và bảng 2×2, rồi chạy trên toàn bộ dữ liệu.

Giai đoạn 4: Đánh giá và phân tích (W10–W12). Nhóm lập bảng đánh giá đầy đủ, làm ablation cấu hình LoRA, thử adapter dùng chung, phân tích lỗi và đo hallucination bằng POPE tiếng Việt.

Giai đoạn 5: Prototype, đóng gói và khóa luận (W13–W15). Nhóm xây prototype web, kiểm chứng prototype khớp với đường đánh giá, quay video demo, chuẩn bị gói tái lập, slide bảo vệ và khóa luận.

1.11.2 Tích hợp các thành phần

Các thành phần của hệ thống được ghép với nhau qua một số điểm chung cố định. Một hàm dựng prompt duy nhất được dùng cho cả huấn luyện, đánh giá và prototype, nên không có sai lệch prompt giữa các giai đoạn. OCR được chạy một lần và lưu cache có mã băm; huấn luyện và đánh giá chỉ đọc cache. Danh sách các mô hình chính thức được sinh tự động từ log, và prototype được kiểm tra theo luật đặt trước để bảo đảm cho cùng câu trả lời với đường đánh giá.

1.11.3 Quản lý chất lượng và rủi ro

Chất lượng của đề tài trước hết là độ tin cậy của con số. Nhóm ghi luật quyết định của mỗi phép thử chính lên Git trước khi chạy, dùng kiểm định ghép cặp cho mọi so sánh, tính lại bảng kết quả trực tiếp từ file dự đoán gốc thay vì chép tay, và ghi mã băm SHA-256 cho adapter, OCR cache và file dữ liệu.

Về rủi ro, kế hoạch ban đầu liệt kê tám rủi ro. Những rủi ro đã thực sự xảy ra gồm: trường không có GPU server, fp16 làm hỏng câu trả lời trên GPU T4, dữ liệu ban đầu lấy sai nguồn, mỗi lần huấn luyện đầy đủ tốn khoảng 12 giờ, và ảnh có cờ xoay EXIF làm sai OCR cache. Cách xử lý từng rủi ro được ghi ở Phụ lục A.

1.11.4 Theo dõi tiến độ

Nhóm làm theo chu kỳ tuần: lập kế hoạch, ghi luật trước, chạy thí nghiệm, kiểm tra lại số liệu, và đóng tuần bằng README cùng Team Report. Tiến độ được đối chiếu với các mốc của khoa: Review 1, Review 2, hội đồng cấp khoa và hội đồng cấp trường. Khi một quyết định thay đổi kế hoạch, ví dụ đổi baseline hay chuyển sang Colab, quyết định đó được ghi lại cùng lý do trong báo cáo tuần.

1.12 Cấu trúc khóa luận

Chương 2 tổng quan VQA, vision-language model, parameter-efficient fine-tuning và các nghiên cứu VQA tiếng Việt. Chương 3 trình bày dữ liệu, baseline, phương pháp QLoRA nhận biết OCR và giao thức đánh giá. Chương 4 báo cáo kết quả chính và các ablation. Chương 5 thảo luận phân tích lỗi, hallucination và giới hạn. Chương 6 kết luận. Phụ lục A trình bày kế hoạch quản lý dự án, và Phụ lục B mô tả gói tái lập.

Chương 2

CÁC NGHIÊN CỨU LIÊN QUAN

Chương này tổng quan năm nhóm công trình mà khóa luận dựa vào: bài toán VQA và VQA đọc chữ trong ảnh (mục 2.1), các vision-language model (mục 2.2), các phương pháp parameter-efficient fine-tuning (mục 2.3), các nghiên cứu VQA tiếng Việt (mục 2.4) và cách đo hallucination (mục 2.5). Mục 2.6 tổng hợp các khoảng trống G1–G4 đã nêu ở Chương 1 và chỉ ra khóa luận giải quyết khoảng trống nào.

2.1 Hỏi đáp trên ảnh và VQA đọc chữ trong ảnh

2.1.1 Bài toán VQA

Antol và cộng sự [4] đặt bài toán VQA dưới dạng mở: cho một ảnh và một câu hỏi tự nhiên, hệ thống trả lời bằng một từ hoặc cụm từ ngắn. Bộ dữ liệu VQA của họ thu mười câu trả lời của người cho mỗi câu hỏi và định nghĩa thước đo VQA Accuracy: một câu trả lời được tính đúng hoàn toàn nếu ít nhất ba người cũng trả lời như vậy, tức $\mathrm{Acc}(a) = \min(\#\{\text{người trả lời } a\}/3,\ 1)$. Các hệ thống thời kỳ này ghép một mạng CNN mã hóa ảnh với một mạng LSTM mã hóa câu hỏi, rồi *phân loại* câu trả lời trên một tập đáp án thường gặp cố định. Cách đặt bài toán phân loại này hiệu quả với câu trả lời ngắn và lặp lại (màu sắc, số lượng, có/không), nhưng không thể sinh một câu trả lời chưa từng có trong tập đáp án lúc huấn luyện.

2.1.2 VQA đọc chữ trong ảnh

Nhiều câu hỏi thực tế chỉ trả lời được bằng cách đọc chữ trong ảnh: tên cửa hàng, giá tiền, số điện thoại. Singh và cộng sự [5] giới thiệu bộ TextVQA cho loại câu hỏi này và cho thấy các mô hình VQA thông thường gần như không trả lời được; mô hình LoRRA của họ đưa

thêm các từ OCR vào mô hình và cho phép *chép* một từ OCR làm câu trả lời. Biten và cộng sự [6] xây bộ ST-VQA với cùng mục tiêu và đề xuất thước đo ANLS (Average Normalized Levenshtein Similarity), tính độ giống theo ký tự giữa câu trả lời và đáp án để không phạt nặng những lỗi đọc nhỏ do OCR. M4C [7] mở rộng ý tưởng chép bằng một transformer đa phương thức sinh câu trả lời từng bước, mỗi bước chọn giữa một từ trong từ điển và một từ OCR.

Bài học chung của nhóm công trình này là: với VQA đọc chữ, chất lượng câu trả lời bị chặn bởi chất lượng chữ đọc được. Nếu OCR đọc sai hoặc sắp sai thứ tự các vùng chữ, mô hình không thể chép ra đáp án đúng. Đây là lý do khóa luận đo riêng chất lượng OCR tiếng Việt và thứ tự đọc (Chương 3).

2.2 Vision-language model

Vision-language model (VLM) hiện nay có chung một khuôn: một bộ mã hóa ảnh biến ảnh thành chuỗi vector, một bộ nối chuyển các vector đó sang không gian của mô hình ngôn ngữ, và một mô hình ngôn ngữ lớn (LLM) đọc chuỗi token ảnh cùng câu hỏi để sinh câu trả lời. Khác biệt giữa các VLM nằm ở bộ nối, ở cách xử lý độ phân giải ảnh và ở dữ liệu huấn luyện. Bảng 2.1 so sánh bốn VLM mà đề cương cho phép chọn làm baseline.

BLIP-2. Li và cộng sự [8] giữ nguyên (đóng băng) cả bộ mã hóa ảnh lẫn LLM và chỉ huấn luyện một mô-đun nhỏ ở giữa là Q-Former. Q-Former dùng một số ít query học được để rút thông tin từ ảnh thành một chuỗi token cố định đưa vào LLM. Cách làm này rẻ về huấn luyện, nhưng số token ảnh cố định và nhỏ khiến mô hình khó giữ chi tiết nhỏ như chữ trong ảnh.

LLaVA và LLaVA-1.5. Liu và cộng sự [9] nối bộ mã hóa ảnh với LLM chỉ bằng một lớp chiếu và huấn luyện trên dữ liệu hội thoại về ảnh (visual instruction tuning). LLaVA-1.5 [19] thay lớp chiếu bằng một MLP, tăng độ phân giải ảnh và thêm một câu nhắc yêu cầu trả lời ngắn; riêng câu nhắc này đã đủ để mô hình trả lời đúng kiểu ngắn mà các bộ VQA cần. LLaVA-1.5 cũng công bố cả bản fine-tune toàn bộ và bản LoRA (mục 2.3).

Florence-2. Xiao và cộng sự [10] xây một mô hình thị giác hợp nhất kiểu encoder–decoder, nhận yêu cầu bằng văn bản và sinh kết quả cho các tác vụ chú thích ảnh, phát hiện vật thể, định vị và OCR. Mô hình rất nhỏ (0,23 và 0,77 tỉ tham số) nên dễ huấn luyện, nhưng không phải mô hình hội thoại đa ngôn ngữ và không được huấn luyện cho hỏi đáp mở bằng tiếng Việt.

Qwen2.5-VL. Bai và cộng sự [1] dùng một bộ mã hóa ViT nhận ảnh ở độ phân giải gốc (native dynamic resolution): ảnh được cắt thành các ô 14×14 điểm ảnh, rồi bộ nối gộp mỗi nhóm 2×2 ô thành một token, nên số token ảnh tỉ lệ với kích thước ảnh. Mô hình ngôn ngữ là Qwen2.5, đa ngôn ngữ, và mô hình được huấn luyện nhiều trên dữ liệu tài liệu và chữ trong ảnh; bản 3 tỉ tham số đạt 79,3 trên TextVQA theo báo cáo của tác giả. Khóa luận chọn Qwen2.5-VL-3B-Instruct làm baseline; kiến trúc chi tiết và lý do chọn được trình bày ở Chương 3.

Bảng 2.1 So sánh bốn VLM trong phạm vi đề cương

Mô hình	**Bộ nối ảnh–ngôn ngữ**	**Điểm mạnh với đề tài**	**Hạn chế với đề tài**
BLIP-2	Q-Former, số token ảnh cố định; ảnh và LLM đóng băng	Rẻ khi huấn luyện; là nền của ViTextBLIP-2	Ít token ảnh, dễ mất chi tiết chữ nhỏ
LLaVA-1.5	MLP chiếu từng patch sang LLM	Kiến trúc đơn giản; có bằng chứng LoRA ngang fine-tune toàn bộ	Chủ yếu tiếng Anh; độ phân giải ảnh cố định
Florence-2	Encoder–decoder hợp nhất, yêu cầu bằng văn bản	Rất nhỏ; có tác vụ OCR riêng	Không phải mô hình hội thoại đa ngôn ngữ
Qwen2.5-VL	ViT độ phân giải gốc, gộp 2×2 ô thành một token	Đa ngôn ngữ; đọc chữ trong ảnh tốt; có bản 3B	Số token ảnh tăng theo kích thước ảnh, tốn bộ nhớ

2.3 Parameter-efficient fine-tuning

2.3.1 Vì sao cần PEFT

Fine-tune toàn bộ một mô hình lớn cho mỗi bài toán nghĩa là cập nhật và lưu một bản sao của mọi tham số. Với GPT-3 175 tỉ tham số, mỗi bản sao chiếm khoảng 350 GB ở 16-bit, và lúc huấn luyện còn phải giữ thêm gradient và trạng thái của bộ tối ưu [14]. Parameter-efficient fine-tuning (PEFT) giữ nguyên trọng số gốc và chỉ huấn luyện một phần rất nhỏ tham số thêm vào. Các hướng sớm gồm adapter [12], chèn các lớp nhỏ vào giữa các lớp của mạng, và prefix-tuning [20], học một đoạn vector đặt trước chuỗi đầu vào. Adapter làm tăng độ trễ khi suy luận vì thêm lớp tuần tự; prefix-tuning chiếm một phần độ dài chuỗi và khó tối ưu.

2.3.2 LoRA

Hu và cộng sự [14] giả định rằng phần thay đổi của trọng số khi thích nghi có hạng thấp. Với một ma trận trọng số $W_0 \in \mathbb{R}^{d\times k}$, LoRA giữ W_0 cố định và học hai ma trận nhỏ $B \in \mathbb{R}^{d\times r}$, $A \in \mathbb{R}^{r\times k}$ với $r \ll \min(d,k)$:

$$h = W_0 x + \frac{\alpha}{r} BAx. \tag{2.1}$$

B được khởi tạo bằng 0 nên lúc bắt đầu mô hình giữ nguyên hành vi gốc. Sau khi huấn luyện, BA có thể cộng thẳng vào W_0, nên suy luận không chậm hơn. Trên GPT-3, LoRA đạt kết quả ngang hoặc hơn fine-tune toàn bộ với số tham số huấn luyện ít hơn khoảng 10.000 lần và bộ nhớ GPU giảm khoảng 3 lần.

2.3.3 QLoRA

LoRA giảm số tham số phải học nhưng vẫn phải giữ trọng số gốc ở 16-bit trong bộ nhớ. Dettmers và cộng sự [15] lượng tử hóa trọng số gốc xuống 4-bit và huấn luyện LoRA ở trên, với ba kỹ thuật: kiểu số 4-bit NormalFloat (NF4) được thiết kế cho trọng số có phân phối gần chuẩn; lượng tử hóa kép (double quantization) nén cả các hằng số lượng tử hóa; và bộ tối ưu phân trang (paged optimizer) để tránh tràn bộ nhớ khi có đỉnh tiêu thụ. Nhờ đó, một LLM 65 tỉ tham số được fine-tune trên một GPU 48 GB, trong khi kết quả khớp với fine-tune 16-bit trên các thí nghiệm của tác giả. Bài báo cũng khuyến nghị gắn LoRA lên mọi lớp tuyến tính để bù sai số lượng tử hóa. Khóa luận dùng QLoRA vì đây là cách duy nhất để fine-tune một VLM vài tỉ tham số trên một GPU Colab; lựa chọn gắn LoRA chỉ vào các ma trận attention hay vào mọi lớp tuyến tính được kiểm tra bằng ablation ở Chương 4.

2.3.4 PEFT cho vision-language model

Sung và cộng sự [13] so sánh có kiểm soát các phương pháp PEFT trên các bài toán ảnh–ngôn ngữ, trong đó có VQA, và cho thấy một adapter dùng chung chỉ với 4,18% tham số huấn luyện đạt kết quả gần bằng fine-tune toàn bộ. LLaVA-1.5 cho bằng chứng tương tự ở quy mô lớn hơn: với mô hình 13 tỉ tham số, bản LoRA đạt 80,0 trên VQAv2 (bằng bản fine-tune toàn bộ), 60,2 so với 61,3 trên TextVQA, và 86,7 so với 85,9 F1 trên POPE [19]. Bảng 2.2 tóm tắt các cách thích nghi.

Tuy vậy, các bằng chứng trên đều đến từ tiếng Anh. Trong các công trình nhóm khảo sát, chưa có nghiên cứu nào kiểm chứng LoRA hoặc QLoRA trên VLM cho VQA tiếng Việt hay cho VQA đọc chữ tiếng Việt. Đây là khoảng trống G3 mà khóa luận tập trung.

Bảng 2.2 Các cách thích nghi một mô hình lớn

Cách	Tham số huấn luyện	Độ trễ suy luận	Bộ nhớ khi huấn luyện
Fine-tune toàn bộ	Toàn bộ	Không đổi	Rất lớn: trọng số, gradient, trạng thái tối ưu
Adapter	Vài phần trăm	Tăng (thêm lớp)	Giữ trọng số 16-bit
Prefix-tuning	Rất ít	Tăng nhẹ (chuỗi dài hơn)	Giữ trọng số 16-bit
LoRA	Dưới 1%	Không đổi sau khi gộp	Giữ trọng số 16-bit
QLoRA	Dưới 1%	Không đổi sau khi gộp	Trọng số 4-bit; nhỏ nhất

2.4 VQA tiếng Việt

2.4.1 Bộ dữ liệu

ViVQA. Tran và cộng sự [16] công bố bộ dữ liệu VQA tiếng Việt đầu tiên, gồm 10.328 ảnh và 15.000 cặp câu hỏi–câu trả lời. Câu trả lời ngắn, phần lớn chỉ một đến ba từ, nên bài toán thường được đặt dưới dạng phân loại.

OpenViVQA. Nguyen và cộng sự [21] xây bộ dữ liệu với câu trả lời mở, dài hơn và đòi hỏi sinh câu trả lời thay vì chọn từ một tập cố định; khoảng một nửa số mẫu có liên quan tới chữ trong ảnh [11].

ViTextVQA. Nguyen và cộng sự [11] công bố bộ dữ liệu VQA đọc chữ tiếng Việt quy mô lớn đầu tiên, gồm 16.762 ảnh và 50.342 câu hỏi, chia train, dev, test theo tỉ lệ 7:1:2. Câu trả lời thường là chữ chép từ ảnh như tên cửa hàng, khẩu hiệu, giá tiền. Người đạt 88,00 EM và 96,42 F1 trên bộ này. Các tác giả cũng cho thấy sắp xếp chữ OCR theo thứ tự từ trái sang phải, từ trên xuống dưới giúp các mô hình trả lời tốt hơn. Khóa luận dùng ViVQA và ViTextVQA; thống kê chi tiết được trình bày ở Chương 3.

2.4.2 Phương pháp

Bảng 2.3 tóm tắt các phương pháp tiêu biểu theo thời gian.

Các nghiên cứu trên đi theo một lộ trình rõ: từ đặc trưng rời rạc kết hợp attention (2021), sang bộ mã hóa đã tiền huấn luyện và mô-đun trộn đa phương thức (2022–2024), rồi tới mô hình sinh dựa trên BLIP-2 cho dữ liệu có chữ (2025). Có hai vướng mắc lặp lại. Thứ nhất, phần lớn các công trình trên ViVQA coi VQA là phân loại trên tập đáp án cố định, nên

Bảng 2.3 Các nghiên cứu VQA tiếng Việt tiêu biểu

Nghiên cứu	Cách làm	Kết quả công bố	Hạn chế
ViVQA [16], 2021	LSTM, Bi-LSTM với nhiều kiểu word embedding; Hierarchical Co-Attention; chọn đáp án trong tập cố định	Acc 34,96 trên ViVQA	Đặc trưng rời rạc; không đọc được chữ
Bi-directional Cross-Attention [22], 2022	Bộ mã hóa đã tiền huấn luyện, cross-attention hai chiều giữa ảnh và câu hỏi	Vượt baseline ViVQA	Vẫn là bài toán phân loại
PAT [23], 2023	Parallel Attention Transformer, trích đặc trưng câu hỏi theo tầng	Acc 60,55 trên ViVQA	Phân loại; không đọc chữ
BARTPhoBEiT [24], 2023	BARTpho cho tiếng Việt kết hợp bộ mã hóa ảnh kiểu BEiT	Acc 68,58 trên ViVQA	Phân loại; không đọc chữ
AViVQA-TranConI [25], 2024	BLIP-2 (đặc trưng toàn cục) và EfficientNet (đặc trưng cục bộ), BARTpho, trộn bằng BEiT-3; phân loại trên 353 đáp án	Acc 71,04 trên ViVQA	Không sinh được đáp án mới; không có OCR
ViTextBLIP-2 [11], 2025	SwinTextSpotter đọc chữ, Q-Former nối ảnh và chữ OCR, ViT5 đóng băng sinh câu trả lời	EM 25,48; F1 53,95 trên ViTextVQA	Phụ thuộc OCR ngoài; cách xa người (88,00 EM)

không trả lời được những đáp án chưa thấy khi huấn luyện, điều bắt buộc với câu hỏi đọc chữ. Thứ hai, đọc chữ tiếng Việt có dấu trong ảnh vẫn là điểm yếu: ViTextBLIP-2 dựa vào một bộ OCR bên ngoài được giữ cố định khi huấn luyện, nên lỗi đọc chữ của OCR truyền thẳng vào câu trả lời.

Cần lưu ý khi so sánh: Accuracy của các phương pháp phân loại trên ViVQA được tính trên tập đáp án cố định, không cùng cách chấm với EM của mô hình sinh tự do mà khóa luận dùng. Vì vậy các con số trên ViVQA ở Bảng 2.3 chỉ để tham khảo. Trên ViTextVQA, khóa luận so trực tiếp với ViTextBLIP-2 vì cùng tập test và cùng thước đo EM, F1 (Chương 4).

2.5 Hallucination và cách đo

Hallucination trong VLM là hiện tượng mô hình sinh nội dung trôi chảy nhưng không có trong ảnh, ví dụ nhắc tới một vật không xuất hiện. Rohrbach và cộng sự [26] đo hiện tượng này trên chú thích ảnh bằng thước đo CHAIR, đếm tỉ lệ vật được nhắc tới mà không có trong nhãn của ảnh. Cách đo này phụ thuộc vào việc tách tên vật ra khỏi câu văn và vào độ dài câu.

POPE [17] đổi sang dạng câu hỏi có/không: với mỗi ảnh, hỏi "Trong ảnh có *vật X* không?" cho cả vật có thật và vật không có. Vật không có được chọn theo ba cách: ngẫu nhiên, vật phổ biến trong toàn bộ dữ liệu, và vật hay xuất hiện cùng các vật trong ảnh (adversarial). Kết quả báo cáo bằng Accuracy, Precision, Recall, F1 và tỉ lệ trả lời "có". Vì câu trả lời chỉ là có hoặc không, POPE không cần phân tích câu văn và dễ áp dụng cho ngôn ngữ khác. Tuy vậy, chưa có bộ đo kiểu POPE nào bằng tiếng Việt (khoảng trống G4). Khóa luận xây bộ POPE-vi theo đúng giao thức này để kiểm tra giả thuyết H4 (Chương 5).

2.6 Tổng kết và khoảng trống nghiên cứu

Bảng 2.4 nối mỗi khoảng trống nêu ở Chương 1 với bằng chứng từ các công trình trên và với cách khóa luận xử lý.

Bảng 2.4 Khoảng trống, bằng chứng và cách khóa luận xử lý

Khoảng trống	**Bằng chứng**	**Khóa luận xử lý**
G1. Tiền huấn luyện thiên tiếng Anh	Các VLM chủ yếu huấn luyện trên tiếng Anh; LLaVA-1.5 chỉ có khả năng đa ngôn ngữ nổi lên, không được huấn luyện riêng	Chọn baseline đa ngôn ngữ; đo lỗi sai ngôn ngữ, sai định dạng ở chế độ zero-shot
G2. VQA tiếng Việt yếu, nhất là đọc chữ	ViTextBLIP-2 đạt 25,48 EM so với 88,00 của người; các phương pháp trên ViVQA là phân loại, không đọc chữ	Sinh câu trả lời tự do; đưa chữ OCR có dấu, đúng thứ tự vào prompt
G3. Chưa có PEFT cho VLM tiếng Việt	LoRA, QLoRA, VL-Adapter, LLaVA-1.5 chỉ kiểm chứng trên tiếng Anh	QLoRA trên Qwen2.5-VL-3B; QLoRA nhận biết OCR là đóng góp chính
G4. Chưa có bộ đo hallucination tiếng Việt	POPE và CHAIR chỉ có cho tiếng Anh	Xây POPE-vi; kiểm tra QLoRA có làm tăng hallucination không

Tóm lại, các công trình trước cho thấy VLM đọc được chữ trong ảnh, PEFT đủ để thích nghi VLM, và thứ tự chữ OCR quan trọng với VQA tiếng Việt. Điều còn thiếu là một nghiên cứu ghép ba ý này cho tiếng Việt dưới ngân sách tài nguyên nhỏ, có baseline tái lập, ablation và đo hallucination. Chương 3 trình bày cách khóa luận làm điều đó.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP

Chương này mô tả cách khóa luận trả lời bốn câu hỏi nghiên cứu ở Chương 1. Mục 3.1 tóm tắt quy trình và danh sách các lần chạy. Mục 3.2 trình bày hai bộ dữ liệu, cách chia tập và tiền xử lý. Mục 3.3 mô tả mô hình nền Qwen2.5-VL-3B-Instruct và việc tái lập nó. Mục 3.4 trình bày cách thích nghi bằng QLoRA, còn mục 3.5 trình bày cải tiến đề xuất là QLoRA nhận biết OCR. Mục 3.6 nêu giao thức đánh giá, mục 3.7 nêu thiết lập thí nghiệm, và mục 3.8 mô tả thiết kế prototype web.

3.1 Tổng quan quy trình

Mọi lần chạy đi qua cùng một quy trình tám bước, chia thành ba giai đoạn:

A. Chuẩn bị dữ liệu (chạy một lần, lưu cache). (1) tải dữ liệu gốc, (2) tiền xử lý, (3) OCR các ảnh của ViTextVQA, (4) chia tập cố định.

B. Huấn luyện và suy luận (giống hệt cho mọi lần chạy). (5) ghép prompt, (6) đưa qua Qwen2.5-VL-3B-Instruct, có hoặc không có adapter LoRA.

C. Đánh giá và sản phẩm. (7) chấm điểm và phân tích lỗi, (8) đóng gói thành prototype web.

Các phương án được so sánh chỉ khác nhau ở hai "công tắc": có đưa dòng chữ OCR vào prompt hay không (bước 3 và 5), và có huấn luyện adapter LoRA hay không (bước 6). Mọi yếu tố khác (split, seed, độ phân giải ảnh, kiểu số, cách sinh câu trả lời, hàm chấm điểm) được giữ cố định, để chênh lệch đo được chỉ do công tắc gây ra. Hình 3.1 minh họa quy trình, còn Bảng 3.1 liệt kê các lần chạy được nhắc tới trong khóa luận.



Hình 3.1 Quy trình tám bước. Bước 3 (OCR) chỉ chạy với ViTextVQA; dòng chữ OCR được lưu cache rồi ghép vào prompt ở bước 5. B1, B2 và B3 đi qua cùng quy trình, chỉ khác ở bước 3 và bước 6.

Bảng 3.1 Các lần chạy chính và vai trò của chúng

Tên	Cấu hình	Vai trò
R0	Qwen2.5-VL-3B, cấu hình gốc của paper, bf16	Tái lập số đã công bố trên TextVQA val
B1	Zero-shot, 4-bit, không OCR	Baseline trên dữ liệu tiếng Việt (RQ1)
B2	QLoRA, toàn bộ train ViTextVQA, không OCR	Đo tác dụng của QLoRA (RQ2)
C1 / C3	QLoRA trên ViVQA, 1 / 2 epoch	C3 là mô hình chính thức cho ViVQA
B2-sub	QLoRA, tập con 8.000 câu ViTextVQA, không OCR	Mốc so sánh có kiểm soát cho B3
B3	Như B2-sub, có dòng OCR khi train và test	Kiểm chứng QLoRA nhận biết OCR (RQ3)
B3-full	Như B2, có dòng OCR khi train và test	Phương pháp đề xuất; mô hình chính thức cho ViTextVQA
A1 / A2	Công thức B3, đổi lớp gắn LoRA / đổi rank	Ablation cấu hình LoRA
SH	Một adapter cho cả hai bộ dữ liệu	Dùng cho prototype

3.2 Dữ liệu

3.2.1 Hai bộ dữ liệu

Bảng 3.2 so sánh hai bộ dữ liệu. Chúng khác nhau ở nguồn ảnh, cách tạo câu hỏi và dạng đáp án, nên đặt ra hai yêu cầu khác nhau cho mô hình.

3.2.2 Chia tập

ViVQA. Bản gốc chỉ có hai file `train.csv` và `test.csv`. Nhóm xáo trộn tập train với seed 42 và tách 10% làm tập val, được 10.799 câu train và 1.200 câu val; tập test 3.001 câu giữ nguyên. Việc tách val là quyết định của nhóm, không phải của tác giả bộ dữ liệu.

ViTextVQA. Nhóm dùng split chính thức của tác giả (tỉ lệ 7:1:2): 35.159 câu train trên 11.733 ảnh, 5.155 câu dev trên 1.676 ảnh và 10.028 câu test trên 3.353 ảnh. Tập train và tập dev không có ảnh nào trùng với tập test.

Các tập con cố định. Để thí nghiệm nhanh mà vẫn so sánh được, nhóm tạo thêm các tập con, mỗi tập chọn một lần bằng seed 42 và lưu danh sách mã câu hỏi:

Bảng 3.2 Hai bộ dữ liệu dùng trong khóa luận

	ViVQA [16]	**ViTextVQA** [11]
Quy mô	15.000 câu hỏi, 10.328 ảnh	50.342 câu hỏi, 16.762 ảnh
Nguồn ảnh	Chọn ngẫu nhiên từ MS COCO [27]; ảnh đời thường, gần như không có chữ	Lấy từ Internet và ảnh tự chụp ở Việt Nam; mọi ảnh đều có chữ tiếng Việt
Cách tạo câu hỏi	Bán tự động: dịch máy các cặp hỏi–đáp của COCO-QA [18] sang tiếng Việt rồi người kiểm lại	Gán nhãn tay bởi 16 người bản ngữ; kiểm chéo đạt F1 trên 85%
Loại câu hỏi	4 loại kế thừa COCO-QA: vật thể, số lượng, màu sắc, vị trí; không có câu có/không	Hỏi về chữ trong ảnh: tên, địa điểm, sản phẩm, số liên hệ…; không có nhãn loại
Đáp án	Rất ngắn: 99,83% không quá 3 từ	Cụm chữ chép từ ảnh, trung bình 4,18 từ
Thước đo phù hợp	EM, VQA-Acc	EM, ANLS

- **dev300**: 300 câu dev ViTextVQA, dùng để chọn cấu hình (độ phân giải, kiểu số, cấu hình OCR);
- **test2000**: 2.000 câu test ViTextVQA, dùng cho các ablation cần nhiều lần chạy;
- **train8k**: 8.000 câu train ViTextVQA trên 2.670 ảnh, dùng cho B2-sub, B3 và các ablation;
- **val sạch** ViVQA: 688 câu val có ảnh không xuất hiện trong train, dùng để chọn số epoch;
- **test sạch** ViVQA: 1.219 câu test có ảnh không xuất hiện trong train, dùng để kiểm tra rò rỉ.

Nguyên tắc chung: mọi lựa chọn cấu hình được thực hiện trên dev hoặc val, không bao giờ trên test. Tập test chỉ dùng để báo cáo.

3.2.3 Tiền xử lý: từ file gốc đến bản ghi sạch

ViVQA. Script chuẩn bị tải hai file CSV từ kho của tác giả, bỏ cột chỉ số, giải mã cột loại câu hỏi (0–3 thành vật thể, số lượng, màu sắc, vị trí), chuẩn hóa câu hỏi và đáp án về Unicode NFC và bỏ khoảng trắng thừa ở hai đầu. Ảnh được tải từ MS COCO 2014 theo mã ảnh; bản ghi nào có ảnh hỏng bị loại.

ViTextVQA. Dữ liệu được tải từ kho chính thức trên Hugging Face (cần đồng ý điều khoản, giấy phép CC BY-NC 3.0). File chú thích dạng COCO (danh sách ảnh và danh sách chú thích) được làm phẳng thành một dòng cho mỗi câu hỏi. Script kiểm tra tự động số câu của từng tập, mã câu hỏi không trùng và không có đáp án rỗng. Kiểm tra này quan trọng vì kho có file `ViTextVQA_test.json` là mẫu nộp bài Kaggle với mọi đáp án là chuỗi giữ chỗ; đáp án thật nằm trong `ViTextVQA_test_gt.json`. Dùng nhầm file mẫu sẽ cho điểm vô nghĩa mà không báo lỗi. Mã băm SHA-256 của các file gốc được ghi vào báo cáo chuẩn bị để khóa phiên bản dữ liệu.

Bản ghi chuẩn. Cả hai bộ dữ liệu được đưa về cùng một dạng bản ghi gồm `question_id`, `question`, `answers` (luôn là danh sách), `image_path` và `question_type`. Trước khi huấn luyện, mẫu có đáp án rỗng hoặc thiếu ảnh bị loại. Nhóm không sửa nội dung câu hỏi hay đáp án, không tăng cường dữ liệu và không thêm dữ liệu huấn luyện từ nguồn ngoài.

Ở bước này văn bản chỉ được chuẩn hóa Unicode NFC và bỏ khoảng trắng thừa. Việc chuyển chữ thường, bỏ dấu câu và các bước chuẩn hóa khác chỉ áp dụng khi chấm điểm (mục 3.6.1), để mô hình học sinh đúng đáp án gốc.

3.2.4 Chất lượng dữ liệu

Trước khi huấn luyện, nhóm đo các vấn đề có sẵn trong dữ liệu gốc. Các vấn đề này được ghi nhận và báo cáo, không được sửa trong dữ liệu:

- **Đáp án gold sai hoặc nhiễu.** Duyệt tay 200 lỗi của B2 cho thấy 12,5% là do gold sai (ViVQA 19%), phần lớn ở các câu hỏi ViVQA dịch máy khó hiểu.
- **Ảnh trùng giữa train và test ở ViVQA.** Khoảng 46% câu test dùng ảnh đã có trong train (49% nếu tính cả val). Đây là lý do nhóm tạo val sạch và test sạch ở mục 3.2.2.
- **ViVQA không có câu có/không.** Không có đáp án "có" nào trong tập train, nên mô hình chỉ học trên ViVQA có nguy cơ quên cách trả lời câu có/không (kiểm ở Chương 5).
- **Gold ViTextVQA viết tách dấu câu**, ví dụ "0983 . 651 888" (25,7% đáp án). Hàm chuẩn hóa khi chấm xử lý điều này đối xứng cho cả đáp án và câu trả lời.
- **Ảnh có cờ xoay EXIF.** Một số ít ảnh ViTextVQA có cờ xoay; ảnh hưởng của chúng lên OCR được phân tích ở mục 4.7.

- **ViTextVQA không có nhãn loại câu hỏi.** Nhóm xây một bộ phân loại theo luật từ khóa gồm 9 loại (gọi là `qt-v1`), viết chỉ từ dev300 và đóng băng trước khi chạy trên test; kiểm trên 150 câu gán nhãn mù đạt độ chính xác 80,7%.

3.3 Mô hình nền Qwen2.5-VL-3B-Instruct

3.3.1 Lý do chọn

Đề cương cho phép chọn một trong ba baseline BLIP-2, Florence-2 và Qwen2.5-VL. Nhóm chọn Qwen2.5-VL-3B-Instruct [1] vì bốn lý do: mô hình hỗ trợ đa ngôn ngữ, trong đó có tiếng Việt; khả năng đọc chữ trong ảnh tốt (TextVQA val 79,3 theo báo cáo gốc); kích thước 3 tỉ tham số đủ nhỏ để lượng tử hóa 4-bit và huấn luyện trên một GPU Colab; và mô hình sinh câu trả lời tự do, phù hợp với đáp án dạng cụm từ của ViTextVQA. Các VLM khác chỉ được dùng làm tham chiếu zero-shot.

3.3.2 Kiến trúc

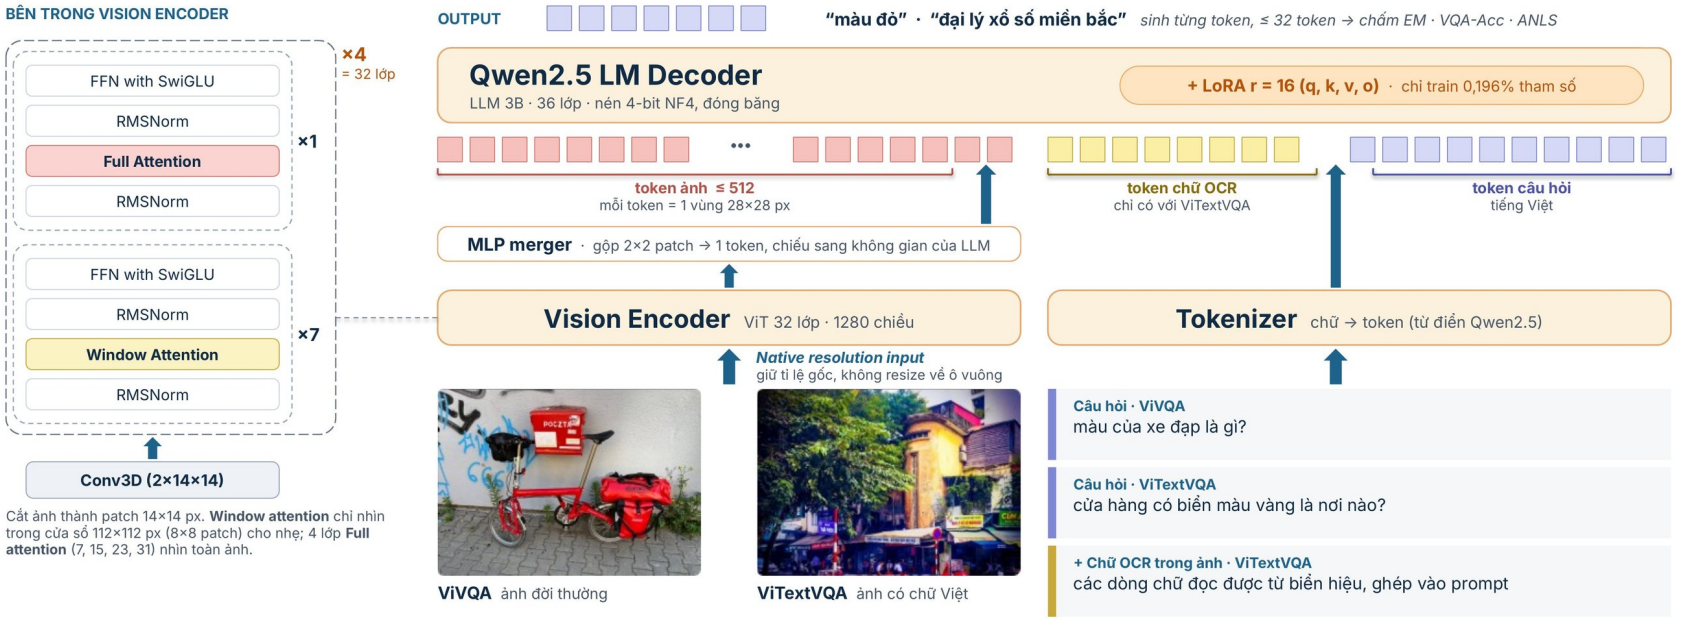
Qwen2.5-VL-3B-Instruct gồm ba khối:

1. **Vision encoder** dạng ViT [28] với 32 lớp, độ rộng 1.280. Ảnh được cắt thành các ô 14×14 điểm ảnh. Phần lớn các lớp dùng window attention, mỗi ô chỉ tính attention trong cửa sổ 112×112 điểm ảnh để giảm chi phí; bốn lớp (thứ 7, 15, 23, 31) dùng full attention trên toàn ảnh.

2. **MLP merger** gộp 2×2 ô kề nhau thành một token và chiếu sang không gian 2.048 chiều của mô hình ngôn ngữ. Mỗi token ảnh vì vậy ứng với một vùng 28×28 điểm ảnh.

3. **Mô hình ngôn ngữ Qwen2.5** gồm 36 lớp decoder, độ rộng 2.048, dùng grouped-query attention với 16 đầu query và 2 đầu key–value, mỗi đầu 128 chiều. Mô hình đọc chuỗi token ảnh cùng token chữ và sinh câu trả lời từng token một.

Hình 3.2 cho thấy đường đi của dữ liệu qua ba khối này, cùng vị trí gắn adapter LoRA (mục 3.4).



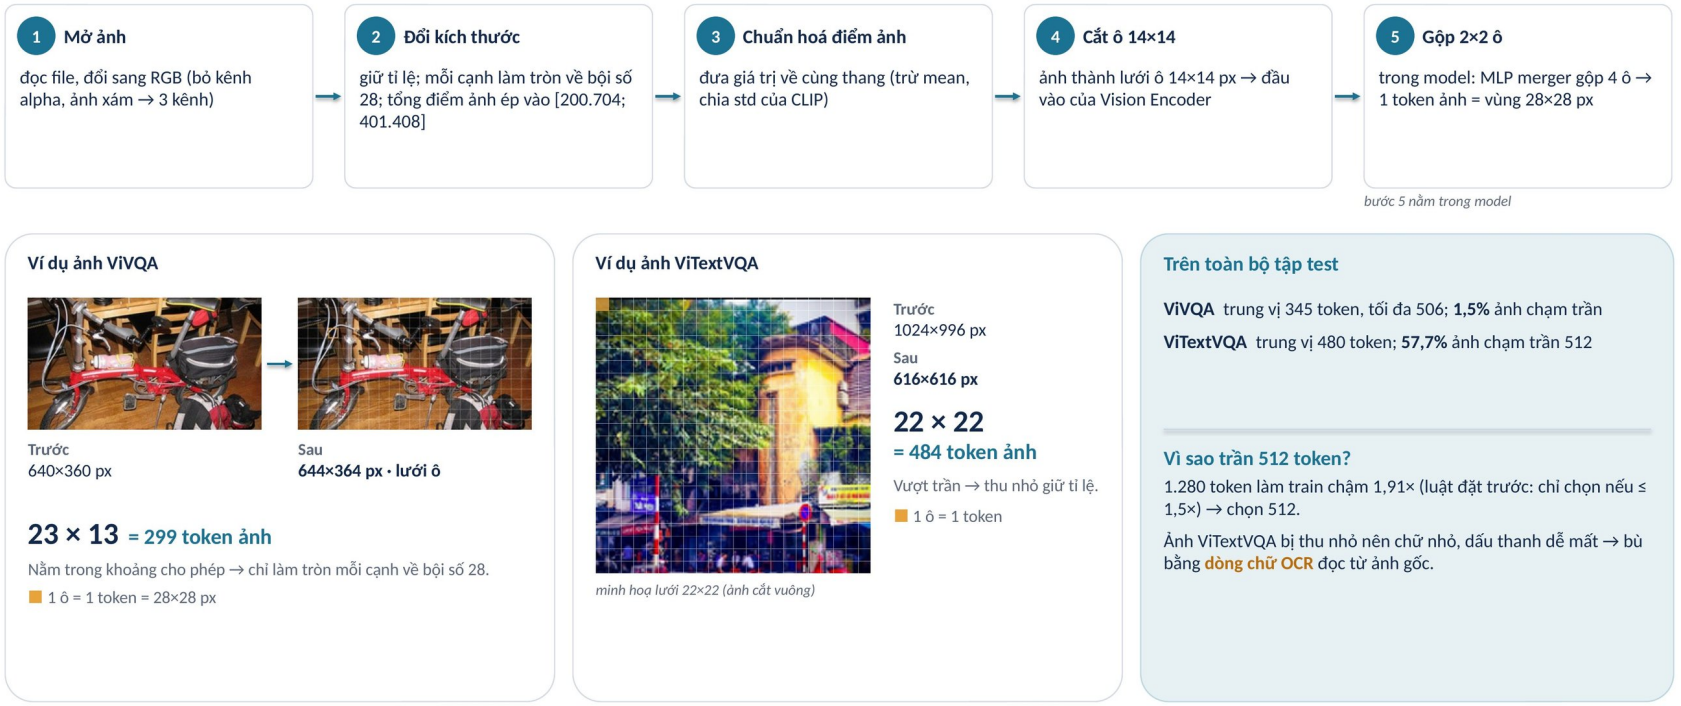
Hình 3.2 Qwen2.5-VL-3B-Instruct trong khóa luận: ảnh đi qua Conv3D, vision encoder và MLP merger thành token ảnh; câu hỏi và chữ OCR đi qua tokenizer thành token chữ; LM decoder (4-bit, đóng băng, gắn LoRA) đọc cả chuỗi và sinh câu trả lời. Khung bên trái là cấu trúc một khối của vision encoder. Sơ đồ vẽ lại, phỏng theo Hình 1 trong báo cáo kỹ thuật của Bai và cộng sự [1].

3.3.3 Tiền xử lý ảnh

Ảnh được mở và đổi sang RGB, rồi được bộ xử lý ảnh của Qwen2.5-VL đổi kích thước giữ nguyên tỉ lệ (native resolution): mỗi cạnh làm tròn về bội số của 28 và tổng số điểm ảnh được ép vào khoảng [200.704; 401.408], tức 256 đến 512 token ảnh. Ảnh lớn bị thu nhỏ, ảnh nhỏ được phóng lên. Sau đó giá trị điểm ảnh được chuẩn hóa theo trung bình và độ lệch chuẩn của bộ mã hóa ảnh. Hai ví dụ:

- Ảnh ViVQA 640×360 điểm ảnh nằm trong khoảng cho phép, chỉ được làm tròn cạnh thành 644×364, tức lưới 23×13 = 299 token ảnh.
- Ảnh ViTextVQA 1.024×996 điểm ảnh vượt trần, được thu nhỏ còn 616×616, tức lưới 22×22 = 484 token ảnh.

Trên tập test, ảnh ViVQA có trung vị 345 token (tối đa 506; chỉ 1,5% ảnh chạm trần), còn ảnh ViTextVQA có trung vị 480 token và 57,7% ảnh chạm trần 512. Hình 3.3 minh họa các bước và hai ví dụ trên.



Hình 3.3 Tiền xử lý ảnh: từ file ảnh đến lưới token ảnh, với một ví dụ ViVQA (chỉ làm tròn cạnh) và một ví dụ ViTextVQA (thu nhỏ vì vượt trần 512 token). Lưới trên ảnh ViTextVQA chỉ để minh họa.

Vì sao trần 512 token. Nhóm đặt luật trước khi đo: chọn 1.280 token nếu thời gian huấn luyện tăng không quá 1,5 lần. Bảng 3.3 cho thấy 1.280 token làm thời gian huấn luyện một epoch ViTextVQA tăng 1,91 lần, nên nhóm chọn 512 token. Phần độ phân giải bị mất, quan trọng với dấu thanh nhỏ trong chữ tiếng Việt, được bù bằng dòng chữ OCR đọc từ ảnh gốc (mục 3.5).

Bảng 3.3 So sánh 512 và 1.280 token ảnh trên ViTextVQA

Đo	**512**	**1.280**	**Chênh**
EM zero-shot (dev300)	33,3	36,0	+2,7; $p = 0{,}13$
ANLS zero-shot (dev300)	46,5	50,4	+3,9 [+1,2; +6,6]
Thời gian train 1 epoch (L4, giờ)	11,1	21,2	$\times$1,91
VRAM khi train (GB)	6,71	10,84	+62%
Suy luận (giây/câu)	2,61	3,81	$\times$1,46

3.3.4 Kiểu số và lượng tử hóa

Baseline ban đầu chạy fp16 trên GPU T4 và sinh ra 23 câu trả lời suy biến (chuỗi dấu "!" dài đúng 32 token). Nhóm chẩn đoán đây là tràn số: fp16 chỉ biểu diễn tới 65.504, logit thành vô cực và phép chọn giá trị lớn nhất rơi về token số 0, chính là "!". Thí nghiệm một biến trên 73 câu (23 câu hỏng và 50 câu đối chứng) xác nhận: fp16 hỏng 23/73 câu, fp32 và bf16 không hỏng câu nào, trong đó fp32 chậm hơn bf16 1,71 lần. Vì GPU L4 hỗ trợ bf16 còn T4 thì không, mọi lần chạy chính thức dùng bf16 trên L4.

Trọng số mô hình nền được lượng tử hóa 4-bit NF4 với double quantization [15]. Mức này giảm VRAM khi suy luận từ 10,9 GB xuống 2,5 GB và giữ 94,5% độ chính xác trên TextVQA val (mục 4.1).

3.3.5 Tái lập baseline

Paper của Qwen2.5-VL không báo cáo trên ViVQA hay ViTextVQA. Vì vậy nhóm tái lập theo hai bước. Bước một (R0) chạy mô hình với cấu hình gốc của paper trên toàn bộ 5.000 câu TextVQA val, nơi có số công bố, để kiểm tra đường suy luận của nhóm là đúng. Bước hai (B1) chạy cùng mô hình ở chế độ zero-shot với cấu hình tiết kiệm của nhóm (4-bit, tối đa 512 token ảnh) trên ViVQA và ViTextVQA, để tạo con số tham chiếu cho mọi cải tiến. Kết quả cả hai bước nằm ở mục 4.1.

3.4 Thích nghi bằng QLoRA

3.4.1 Cấu hình adapter

Theo LoRA [14] (phương trình 2.1), mỗi lớp tuyến tính được chọn nhận thêm hai ma trận hạng thấp BA; chỉ A và B được huấn luyện. Nhóm gắn adapter vào bốn phép chiếu attention `q_proj`, `k_proj`, `v_proj`, `o_proj` của 36 lớp decoder, với rank $r = 16$, $\alpha = 32$ và dropout 0,05. Mô hình nền được lượng tử hóa 4-bit NF4 và đóng băng hoàn toàn. Bảng 3.4 kiểm tra lại số tham số huấn luyện bằng tính tay.

Bảng 3.4 Số tham số LoRA theo từng phép chiếu ($r = 16$)

Phép chiếu	**Kích thước (vào → ra)**	**Tham số** $= r(d_{in} + d_{out})$
`q_proj`	$2.048 \to 2.048$	65.536
`k_proj`	$2.048 \to 256$	36.864
`v_proj`	$2.048 \to 256$	36.864
`o_proj`	$2.048 \to 2.048$	65.536
Mỗi lớp decoder		204.800
$\times$ 36 lớp		**7.372.800**

Tổng 7.372.800 tham số bằng 0,196% trong 3,76 tỉ tham số của mô hình, khớp với số do thư viện PEFT báo cáo. Kết quả khớp cũng cho thấy adapter chỉ nằm trong mô hình ngôn ngữ: vision encoder và MLP merger không bị chạm tới. Nhóm kiểm thêm bằng danh sách lớp được gắn LoRA ghi trong log huấn luyện. Adapter lưu ra file 29,5 MB.

3.4.2 Nhãn huấn luyện và che nhãn

Mỗi mẫu huấn luyện là một chuỗi theo khuôn hội thoại của Qwen: câu lệnh hệ thống cố định, ảnh, phần chữ của prompt (mục 3.5.4), rồi đáp án. Câu lệnh hệ thống là: "Bạn là trợ lý hỏi đáp hình ảnh tiếng Việt. Hãy trả lời thật NGẮN GỌN và CHÍNH XÁC bằng tiếng Việt, chỉ đưa ra đáp án, không giải thích dài dòng." Nhãn là đáp án đầu tiên trong danh sách gold, gộp khoảng trắng, giữ nguyên chữ và dấu, nối thêm token kết thúc lượt `<|im_end|>` để mô hình học khi nào dừng.

Mọi token của câu lệnh hệ thống, ảnh và câu hỏi mang nhãn -100 nên bị bỏ qua khi tính loss. Gọi $\mathscr{A}$ là tập vị trí các token đáp án, hàm mất mát là

$$\mathscr{L} = -\frac{1}{|\mathscr{A}|} \sum_{t \in \mathscr{A}} \log p_\theta \left(y_t \mid y_{<t}, I, x \right), \tag{3.1}$$

trong đó I là ảnh, x là phần chữ của prompt và θ chỉ gồm tham số LoRA. Nếu không che, phần lớn tín hiệu học sẽ dồn vào việc sinh lại hơn 500 token ảnh và câu hỏi, trong khi đáp án chỉ có vài token. Vì số token ảnh thay đổi theo kích thước ảnh, độ dài prompt được đo riêng cho từng mẫu bằng cách cho bộ xử lý chạy trên đúng phần prompt và đúng ảnh đó; chuỗi được đệm bên phải để prompt luôn nằm đầu chuỗi.

Một hàm dựng prompt duy nhất được dùng cho cả huấn luyện và đánh giá. Nhờ vậy prompt lúc huấn luyện trùng khít prompt lúc đánh giá, tránh lệch phân phối giữa hai giai đoạn.

3.4.3 Siêu tham số

Bảng 3.5 liệt kê siêu tham số dùng chung cho mọi lần huấn luyện. Riêng mô hình chính thức cho ViVQA (C3) dùng lịch hai epoch và lấy adapter sau epoch thứ hai; số epoch được chọn trên val sạch (mục 4.2).

Bảng 3.5 Siêu tham số huấn luyện

Tham số	**Giá trị**
LoRA	$r = 16$, $\alpha = 32$, dropout 0,05, gắn q, k, v, o của LLM
Lượng tử hóa	4-bit NF4, double quantization, tính toán bf16
Learning rate	2×10^{-4}, warmup 3% số bước, weight decay 0
Batch	2 mẫu $\times$ tích lũy gradient 8 = batch hiệu dụng 16
Gradient checkpointing	Bật
Số epoch	1 (C3: 2, chọn trên val sạch)
Ảnh	256–512 token (min_pixels 200.704, max_pixels 401.408)
Suy luận	Greedy, tối đa 32 token sinh
Seed	42 (kiểm độ ổn định với 42, 43, 44)

3.5 Phương pháp đề xuất: QLoRA nhận biết OCR

3.5.1 Động lực

Duyệt tay 200 lỗi của B2 cho thấy lỗi thật trên ViTextVQA chủ yếu là lỗi đọc chữ: đọc sai chữ chiếm 28%, nhầm vùng chữ 23% và sai dấu thanh 8% số lỗi. Đây đúng là hai vấn đề V1 (dấu thanh) và V3 (thứ tự chữ) ở Chương 1. Ở 512 token ảnh, ảnh ViTextVQA bị thu nhỏ nên các nét dấu nhỏ dễ mất. Một hệ OCR đọc ảnh ở độ phân giải gốc có thể cung cấp lại thông tin này dưới dạng chữ.

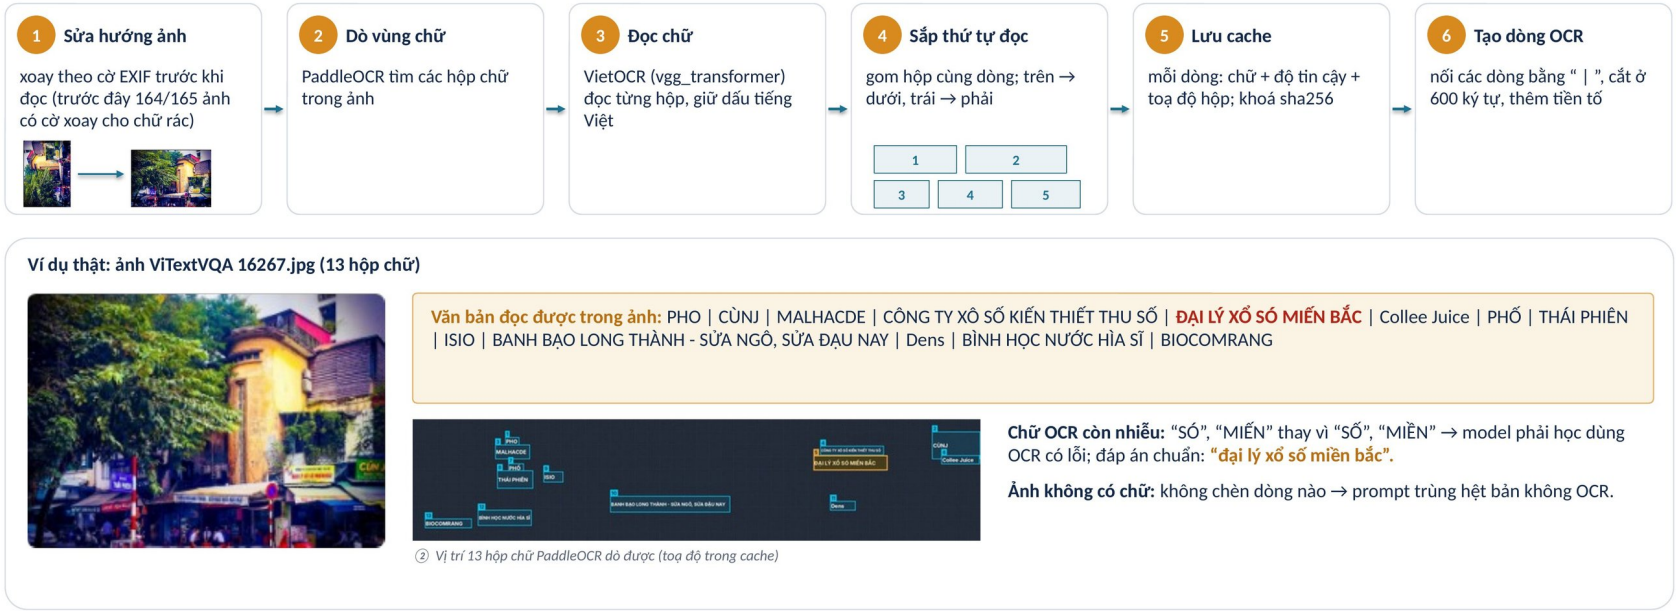
Tuy nhiên, thêm OCR vào prompt của một mô hình chưa từng thấy OCR là không đủ. Trên dev300, việc thêm dòng OCR khi suy luận làm đổi 167/300 câu trả lời của B1, nhưng chỉ sửa đúng 16 câu và làm hỏng 16 câu: mô hình dùng OCR không phân biệt. Từ đó nhóm đề xuất đưa dòng OCR vào prompt *ngay trong lúc huấn luyện* QLoRA, để adapter học khi nào nên tin và chép từ OCR, khi nào nên bỏ qua. Nhóm gọi phương pháp này là QLoRA nhận biết OCR (OCR-aware QLoRA).

3.5.2 Đường OCR

OCR chạy một lần trên ảnh gốc; kết quả được lưu vào cache và mọi lần huấn luyện, đánh giá chỉ tra cache. Nhờ vậy mọi phương án có OCR dùng đúng cùng một chữ OCR. Đường OCR gồm sáu bước:

1. **Sửa hướng ảnh** theo cờ EXIF trước khi đọc (bổ sung sau khi phát hiện lỗi, mục 4.7).
2. **Dò vùng chữ** bằng mô hình dò của PaddleOCR [2].
3. **Đọc chữ** từng vùng bằng VietOCR [3] (kiến trúc VGG–transformer), mô hình được huấn luyện cho chữ tiếng Việt có dấu.
4. **Sắp thứ tự đọc**: các hộp có tâm theo chiều dọc lệch nhau ít hơn một nửa chiều cao trung vị được gom vào cùng một dòng; các dòng xếp từ trên xuống, trong mỗi dòng xếp từ trái sang phải. Tác giả ViTextVQA đã chỉ ra thứ tự trái-trên đến phải-dưới là có ích [11].
5. **Lưu cache**: với mỗi ảnh lưu chữ, độ tin cậy và tọa độ hộp của từng dòng; cache được khóa bằng mã băm SHA-256. Lưu cả tọa độ cho phép phân tích lỗi "nhầm vùng chữ" mà không phải OCR lại.
6. **Tạo dòng OCR**: các dòng được nối bằng dấu "|", cắt ở 600 ký tự và thêm tiền tố "Văn bản đọc được trong ảnh:".

Cache phủ 15.352 ảnh ViTextVQA (toàn bộ train, test và dev300). Ảnh không đọc ra chữ nào thì không có dòng OCR, và prompt trùng hệt prompt không OCR. Hình 3.4 minh họa sáu bước trên một ảnh thật.



Hình 3.4 Đường OCR trên ảnh ViTextVQA 16267.jpg: 13 hộp chữ được dò, đọc và nối thành dòng OCR. Chữ OCR còn nhiễu ("SÓ", "MIẾN" thay vì "SỐ", "MIỀN"), trong khi đáp án gold là "đại lý xổ số miền bắc".

3.5.3 Chọn cấu hình OCR

Cấu hình OCR được chọn trên dev300 theo luật đặt trước, không nhìn tập test. Tiêu chí chính là tỉ lệ câu có đáp án gold nằm nguyên văn, đúng cả dấu, trong chữ OCR. PaddleOCR với mô hình đọc chữ Latin làm rơi dấu tiếng Việt (ví dụ "Kiểu Thẩm" thành "Kiu Thm"): đáp án nằm trong OCR ở 27,0% câu nếu so giữ dấu, nhưng 57,7% nếu bỏ dấu khi so. Khi giữ bộ dò của PaddleOCR và thay phần đọc bằng VietOCR, tỉ lệ so giữ dấu tăng lên 37,7% (kiểm định McNemar $p = 0{,}0008$). Nhóm chọn tổ hợp PaddleOCR dò và VietOCR đọc, mẫu tiền tố trung tính, cắt 600 ký tự và không lọc theo độ tin cậy.

3.5.4 Prompt

Phần chữ của prompt có hai dạng, khác nhau đúng một dòng:

- Không OCR (B1, B2, C1, C3): `Câu hỏi: {câu hỏi}`
- Có OCR (B3, B3-full, SH): `Văn bản đọc được trong ảnh: {dòng 1} | {dòng 2} | ...`, xuống dòng, rồi `Câu hỏi: {câu hỏi}`

Dòng OCR đặt trước câu hỏi để mô hình đọc nó như ngữ cảnh. Với một mẫu ViTextVQA điển hình, chuỗi đầu vào gồm khoảng 62 token câu lệnh hệ thống và khuôn hội thoại, 480 token ảnh, 76 token OCR và 11 token câu hỏi (giá trị trung vị trên toàn tập). Chuỗi dài nhất trên toàn bộ dữ liệu là 1.058 token, chỉ bằng 0,83% cửa sổ ngữ cảnh 128.000 token của mô hình; giới hạn thực tế là VRAM và thời gian huấn luyện, không phải độ dài ngữ cảnh.

3.5.5 Huấn luyện B3 và B3-full

B3 dùng đúng công thức của B2 (cùng siêu tham số, cùng 0,196% tham số), chỉ thêm dòng OCR vào prompt cả lúc huấn luyện lẫn lúc đánh giá. Nhóm kiểm chứng theo hai bước. Bước một huấn luyện trên train8k và so với B2-sub, cùng tập con nhưng không OCR; đây là phép thử có kiểm soát, rẻ và lặp lại được với nhiều seed. Bước hai (B3-full) huấn luyện trên toàn bộ 35.159 câu train và so với B2 để trả lời câu hỏi: khi đủ dữ liệu, OCR có còn giúp không.

3.6 Giao thức đánh giá

3.6.1 Chuẩn hóa đáp án

Trước khi so khớp, câu trả lời của mô hình và đáp án gold đi qua cùng một hàm chuẩn hóa `normalize_vi`, gồm sáu bậc cộng dồn:

S1. Unicode NFC: gộp chữ và dấu thành một mã thống nhất.

S2. Chuyển chữ thường.

S3. Bỏ dấu câu nhưng giữ dấu thanh tiếng Việt.

S4. Gộp khoảng trắng thừa.

S5. Bỏ tiền tố "màu" ở đầu chuỗi ("màu đỏ" thành "đỏ").

S6. Nếu cả chuỗi là một số (0–20 hoặc chục tròn đến 100), đổi chữ thành chữ số ("ba" thành "3").

Hàm không bỏ dấu thanh ("con mèo" khác "con meo") và không gộp từ đồng nghĩa, nên EM giữ tính chặt chẽ; phần gần đúng do ANLS đo. Trên ViTextVQA, bậc S3 và S4 đổi 25,8% đáp án gold (do gold viết tách dấu câu); trên ViVQA, bậc S5 và S6 đổi 20,9% và 14,8% đáp án. Mô hình đã huấn luyện gần như không phụ thuộc chuẩn hóa (C3 đạt 76,6 ở mọi bậc), nên không bậc nào tự tạo ra cải tiến.

3.6.2 Thước đo

Gọi p là câu trả lời và G là tập đáp án gold, cả hai đã chuẩn hóa.

Exact Match (thước đo chính). $\mathrm{EM}(p,G) = 1$ nếu p trùng khít một phần tử của G, ngược lại bằng 0.

VQA Accuracy. $\mathrm{Acc}(p,G) = \min\left(\#\{g \in G : g = p\}/3,\ 1\right)$ theo Antol và cộng sự [4]. Trong cả hai bộ dữ liệu mỗi câu chỉ có một đáp án gold, nên VQA-Acc trùng EM ở mọi lần chạy; khóa luận báo EM và ghi chú điều này.

ANLS. Theo Biten và cộng sự [6],

$$\mathrm{ANLS}(p,G) = \max_{g \in G} s(p,g), \qquad s(p,g) = \begin{cases} 1 - \dfrac{\mathrm{Lev}(p,g)}{\max(|p|,|g|)} & \text{nếu giá trị này } \geq 0{,}5, \\ 0 & \text{ngược lại,} \end{cases} \tag{3.2}$$

trong đó Lev là khoảng cách Levenshtein theo ký tự. ANLS chịu được lỗi đọc nhỏ: "miền bác" so với "miền bắc" có EM bằng 0 nhưng ANLS bằng 0,95.

Token-F1 (chỉ số phụ). F1 trên túi âm tiết của câu trả lời và gold, chỉ dùng để so với số công bố của ViTextVQA. Vì khoảng trắng tiếng Việt tách âm tiết chứ không tách từ, nhóm báo thêm F1 sau khi tách từ bằng pyvi để kiểm tra kết luận không đổi.

BLEU và CIDEr không được dùng làm thước đo chính, đúng theo đề cương.

3.6.3 Kiểm định thống kê

Mọi so sánh giữa hai mô hình được thực hiện trên cùng một tập câu hỏi, nên nhóm dùng kiểm định ghép cặp thay cho so sánh số tổng:

- **EM**: kiểm định McNemar chính xác [29] (nhị thức hai phía) trên các câu chỉ một trong hai mô hình đúng.
- **ANLS, ΔEM và hiệu ứng tương tác**: khoảng tin cậy 95% bằng bootstrap ghép cặp [30], 10.000 lần lấy mẫu, seed 42.
- **Tỉ lệ trong duyệt tay**: khoảng tin cậy Wilson [31].
- **POPE-vi**: bootstrap theo ảnh, vì các câu hỏi trên cùng một ảnh không độc lập.

Với 2.000 câu, ngưỡng $p < 0{,}05$ ứng với chênh lệch khoảng 1,7 điểm EM, và độ mạnh kiểm định 80% đạt khi chênh lệch thật khoảng 2,3 điểm. Các ablation trên test2000 được đọc với giới hạn này.

3.6.4 Luật quyết định ghi trước

Trước mỗi thí nghiệm, nhóm ghi luật quyết định vào kho mã (commit có dấu thời gian) rồi mới chạy. Luật nêu tập dữ liệu, mốc so sánh, thước đo, ngưỡng và cách kết luận. Ví dụ: H1 được ủng hộ nếu QLoRA tăng EM ít nhất 5 điểm với $p < 0{,}05$; adapter dùng chung được coi là "không kém" nếu cận dưới CI95 của ΔEM lớn hơn $-1{,}5$ trên từng bộ dữ liệu; một mô hình "không tăng hallucination" nếu cận dưới CI95 của ΔF1 trên POPE-vi lớn hơn -2. Khi kết quả không đạt luật, nhóm báo đúng như vậy và không đổi luật sau khi đã thấy số.

3.6.5 Đo hallucination: POPE-vi

Nhóm xây POPE-vi, phiên bản tiếng Việt của POPE [17]. Ảnh là 500 ảnh ViVQA test chưa từng xuất hiện trong train hoặc val; nhãn vật thể lấy từ chú thích COCO 2014 và dịch sang tiếng Việt bằng một từ điển 80 lớp. Mỗi ảnh có ba câu hỏi về vật có trong ảnh (đáp án "có") và ba câu hỏi về vật không có (đáp án "không") cho mỗi cách chọn vật vắng mặt: ngẫu nhiên

(random), vật phổ biến (popular) và vật hay đi kèm (adversarial). Mẫu câu là `Trong ảnh có {vật} không? Trả lời "có"hoặc "không".` Sau khi bỏ câu trùng còn 4.985 câu. Từ điển, luật và file câu hỏi được khóa trong kho mã trước khi chạy mô hình.

Mỗi mô hình được so với chính mô hình nền zero-shot dùng cùng dạng prompt. Ngoài F1 như cách báo cáo của LLaVA-1.5 [19], nhóm báo thêm tỉ lệ trả lời "có" (yes-ratio), tỉ lệ báo sai (câu "không" bị trả lời "có") và tỉ lệ câu trả lời không đọc được thành có hoặc không.

3.6.6 Phân tích lỗi

Phân tích lỗi gồm hai phần. Phần tự động xếp mỗi câu sai EM vào một kiểu lỗi theo thứ tự ưu tiên: chỉ khác dấu thanh, thiếu chữ, thừa chữ (gold nằm trong câu trả lời), lệch không quá 2 ký tự, và còn lại. Với ViTextVQA, mỗi câu còn được xếp theo trạng thái OCR: đáp án nằm nguyên văn trong OCR, chỉ khớp khi bỏ dấu, OCR có chữ nhưng không chứa đáp án, hoặc OCR không đọc ra chữ. Định nghĩa được ghi trước khi chạy. Phần duyệt tay lấy ngẫu nhiên (seed 42) 100 lỗi của B3-full và 50 lỗi của C3, khóa danh sách trước khi gán nhãn, và gán nhãn mù: người gán chỉ thấy ảnh, câu hỏi, gold và câu trả lời, không thấy kiểu lỗi tự động hay chữ OCR.

3.7 Thiết lập thí nghiệm

Phần cứng. Mọi lần huấn luyện và đánh giá chạy trên một GPU NVIDIA L4 24 GB của Google Colab Pro. OCR chạy trên GPU Tesla T4 trong một phiên riêng. Không lần chạy nào dùng quá một GPU.

Phần mềm. Phiên bản thư viện được ghim trong `requirements-colab.txt`: PyTorch 2.11.0, Transformers 5.17.0, PEFT 0.21.2, bitsandbytes 0.50.2, Accelerate 1.15.0, qwen-vl-utils 0.0.14, PaddleOCR 3.x, VietOCR và Gradio 6.31.0.

Log để tái lập. Mỗi lần chạy ghi một file chữ ký gồm split và mã băm file dữ liệu, seed, commit mã nguồn, loại GPU, phiên bản thư viện, toàn bộ cấu hình, thời gian huấn luyện và suy luận, VRAM đỉnh. Kết quả được lưu theo từng câu (`predictions.json`) để mọi thước đo và kiểm định có thể tính lại từ đầu. Thư mục kết quả đặt tên theo quy ước `experiments/W<tuổấn>_<chòểỉỎÈòệỄ>_<mÕéhÕằnh>_<dòệẳliòệẤu>_seed<seed>/`.

3.8 Thiết kế prototype

Prototype là một ứng dụng web Gradio [32] chạy trên Colab L4. Người dùng tải ảnh lên và đặt câu hỏi tiếng Việt; hệ thống trả lời kèm chữ OCR và mức tin cậy. Thiết kế tuân theo ba nguyên tắc:

1. **Cùng một đường suy luận với đánh giá.** Prototype gọi đúng hàm dựng prompt, đúng adapter và đúng cách sinh câu trả lời (greedy, tối đa 32 token) của đường đánh giá. Điều này được kiểm bằng luật trùng khớp ở mục 4.8.

2. **Câu trả lời kèm bằng chứng.** Vì mô hình dùng OCR, giao diện hiển thị chữ OCR đọc được để người dùng tự kiểm tra câu trả lời. OCR chạy trong một tiến trình riêng, đọc ảnh gốc (tối đa 6.000 điểm ảnh mỗi cạnh) đã xoay theo cờ EXIF.

3. **Một adapter cho mọi câu hỏi.** Prototype dùng adapter SH, huấn luyện trên cả ViVQA và ViTextVQA, để không phải đoán trước người dùng hỏi loại câu nào.

Độ tin cậy. Với câu hỏi mở, độ tin cậy là exp của trung bình log xác suất các token trả lời. Vì độ tin cậy này chưa được hiệu chỉnh tốt (ECE [33] bằng 0,198), giao diện chỉ hiện mức Cao, Trung bình hoặc Thấp thay cho con số phần trăm.

Câu hỏi có/không. Một bộ nhận diện theo luật đánh dấu câu hỏi có/không (kết thúc bằng "không", "chưa", "phải không"... và không chứa từ để hỏi). Với các câu này, quyết định dựa trên hiệu $m = s_{\text{có}} - s_{\text{không}}$ giữa log xác suất lớn nhất của token đầu phía "có" và phía "không": trả lời "có" khi $m > \tau^*$. Ngưỡng $\tau^* = 4{,}85$ được chọn trên một tập hiệu chỉnh riêng (ảnh ViVQA test chưa thấy khi huấn luyện, không thuộc POPE-vi) bằng cách tối đa balanced accuracy, để sửa thiên lệch "có" của SH (mục 5.6) mà không phải huấn luyện lại. Câu hỏi khác vẫn đi đường greedy như khi đánh giá.

Quyền riêng tư. Prototype không lưu ảnh hay câu hỏi của người dùng; chỉ ghi thời gian xử lý.

Chương 4

KẾT QUẢ

Chương này báo cáo kết quả theo thứ tự của các câu hỏi nghiên cứu. Mục 4.1 trình bày việc tái lập baseline và kết quả zero-shot (RQ1). Mục 4.2 báo cáo QLoRA (RQ2), mục 4.3 báo cáo phương pháp đề xuất QLoRA nhận biết OCR (RQ3). Mục 4.4 trình bày các ablation, mục 4.5 kết quả theo loại câu hỏi, mục 4.6 chi phí tính toán, mục 4.7 một phân tích độ nhạy, và mục 4.8 kiểm chứng prototype. Mục 4.9 tổng hợp kết luận cho từng giả thuyết. Kết quả về hallucination (RQ4) và phân tích lỗi nằm ở Chương 5.

Trừ khi ghi khác, mọi số liệu được đo trên toàn bộ tập test (ViVQA 3.001 câu, ViTextVQA 10.028 câu), một GPU NVIDIA L4, bf16, mô hình nền 4-bit NF4, seed 42. Số liệu được viết theo thang phần trăm.

4.1 Tái lập baseline và kết quả zero-shot

4.1.1 Tái lập số đã công bố (R0)

Bảng 4.1 so sánh kết quả của nhóm với số trong báo cáo kỹ thuật của Qwen2.5-VL [1] trên toàn bộ 5.000 câu TextVQA val. Với cấu hình gốc của paper (bf16, không giới hạn độ phân giải), nhóm đạt VQA-Acc 79,60 so với 79,3 công bố, chênh $+0{,}3$ điểm. Đường suy luận của nhóm vì vậy được coi là đúng. Cấu hình tiết kiệm dùng cho mọi thí nghiệm sau (4-bit NF4, tối đa 512 token ảnh) đạt 75,21, tức giữ 94,5% độ chính xác trong khi VRAM khi suy luận giảm từ 10,9 GB xuống 2,5 GB (giảm 77%).

4.1.2 Zero-shot trên dữ liệu tiếng Việt (B1)

Bảng 4.2 trình bày kết quả zero-shot. Mô hình nền đạt EM 22,09 trên ViVQA và 29,12 trên ViTextVQA. Riêng trên ViTextVQA, B1 đã cao hơn kết quả công bố tốt nhất trước đây

Bảng 4.1 Tái lập Qwen2.5-VL-3B-Instruct trên TextVQA val (5.000 câu)

Cấu hình	**VQA-Acc**	**VRAM suy luận**
Báo cáo gốc [1]	79,3	—
R0: nhóm chạy lại, cấu hình gốc (bf16)	79,60	10,9 GB
R0b: cấu hình tiết kiệm (4-bit, $\leq$ 512 token ảnh)	75,21	2,5 GB

(ViTextBLIP-2, EM 25,48 [11]), cho thấy mô hình nền hiện đại đã đọc chữ tốt hơn các hệ thống trước.

Bảng 4.2 Kết quả zero-shot (B1) trên toàn bộ tập test

Tập test	**EM**	**ANLS**	**F1 (phụ)**
ViVQA (3.001 câu)	22,09	28,61	38,05
ViTextVQA (10.028 câu)	29,12	47,60	53,89

EM thấp chủ yếu vì sai định dạng. Câu trả lời zero-shot dài hơn đáp án gold: trung bình 2,9 từ so với 1,6 từ trên ViVQA, và 5,4 từ so với 3,7 từ trên ViTextVQA. 18% câu ViTextVQA có câu trả lời chứa đúng đáp án nhưng vẫn trượt EM vì thừa chữ. Hai ví dụ: câu hỏi "đây là bảo tàng gì?" được trả lời "Bảo tàng Lịch sử Quốc gia." trong khi gold là "lịch sử quốc gia"; câu hỏi "màu của chiếc tàu là gì" được trả lời "Đỏ và trắng" trong khi gold là "màu đỏ".

Theo loại câu hỏi ViVQA. EM zero-shot khác nhau rất xa giữa các loại: số lượng 69,1 (444 câu), màu sắc 44,8 (625 câu), vật thể 5,7 (1.247 câu) và vị trí 0,7 (685 câu). Với câu hỏi vật thể và vị trí, gold chỉ là một danh từ ("phòng"), còn mô hình trả lời cả cụm ("trong phòng khách").

Ngôn ngữ và dấu thanh. Ở lần chạy baseline đầu tiên (cấu hình ban đầu, trước khi chốt bf16), khoảng 90 câu trả lời bằng tiếng Anh dù câu hỏi bằng tiếng Việt. Trên test2000 ViTextVQA, EM với đáp án tiếng Việt có dấu (22,4) thấp hơn hẳn EM với đáp án chỉ gồm chữ Latin không dấu (39,4). Đây là bằng chứng định lượng cho vấn đề V1 và V2 ở Chương 1.

Các cách không cần huấn luyện. Nhóm thử thêm ba cách không huấn luyện. (i) Prompt few-shot với 5 ví dụ chỉ gồm chữ, để mô hình thấy định dạng đáp án, làm EM giảm 2,1 điểm trên ViVQA và 1,2 điểm trên ViTextVQA. (ii) Thêm dòng OCR vào prompt khi suy luận

không cải thiện có ý nghĩa (mục 4.4.1). (iii) Một VLM lớn hơn, Qwen2-VL-7B [34], ở chế độ zero-shot chỉ đạt EM 16,7 trên test2000, chủ yếu vì trả lời dài. Không cách nào trong số này sửa được vấn đề định dạng, nên cần huấn luyện.

4.2 QLoRA

Bảng 4.3 so sánh zero-shot với QLoRA. Chỉ với 0,196% tham số được huấn luyện, QLoRA tăng EM thêm 21,1 điểm trên ViTextVQA (29,12 lên 50,26) và 51,7 điểm trên ViVQA sau một epoch (22,09 lên 73,78). Trên ViTextVQA, 2.543 câu chỉ B2 trả lời đúng so với 423 câu chỉ B1 trả lời đúng; kiểm định McNemar cho p gần bằng 0 trên cả hai bộ dữ liệu.

Bảng 4.3 Zero-shot so với QLoRA trên toàn bộ tập test

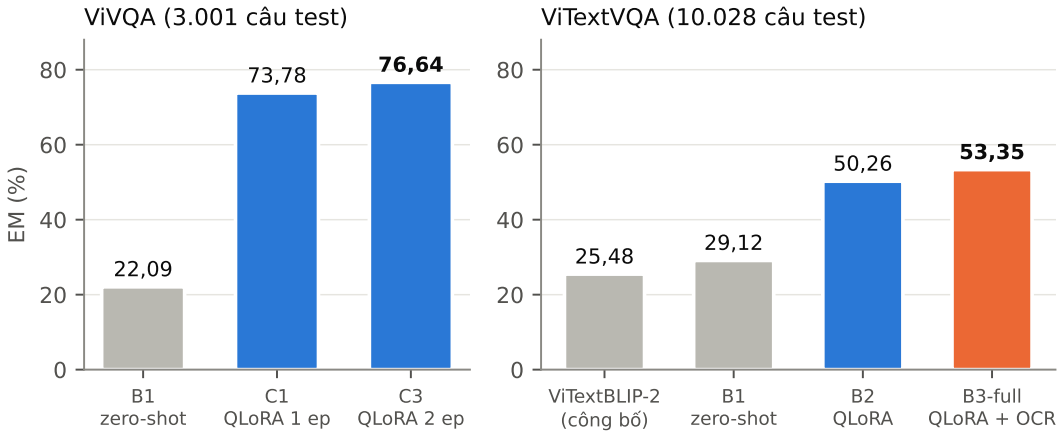
Mô hình	**Epoch**	**EM**	**ANLS**	**F1 (phụ)**
ViVQA (3.001 câu)				
B1 · zero-shot	—	22,09	28,61	38,05
C1 · QLoRA	1	73,78	75,66	76,20
C3 · QLoRA (chính thức)	2	**76,64**	**78,03**	**78,84**
ViTextVQA (10.028 câu)				
B1 · zero-shot	—	29,12	47,60	53,89
B2 · QLoRA	1	50,26	72,02	71,16

Chọn số epoch cho ViVQA. Lịch hai epoch được so với một epoch trên val sạch (688 câu, ảnh không có trong train) theo luật ghi trước: C1 đạt 73,11, adapter sau epoch 1 của lịch hai epoch đạt 71,51, adapter sau epoch 2 (C3) đạt 77,03 ($p = 1{,}4 \times 10^{-4}$ so với C1). Sau khi chọn, tập test chỉ được chạy một lần: C3 hơn C1 2,86 điểm EM (65 câu chỉ C1 đúng so với 151 câu chỉ C3 đúng, $p = 4{,}6 \times 10^{-9}$) và 2,4 điểm ANLS. C3 là mô hình chính thức cho ViVQA, tăng 54,6 điểm EM so với zero-shot.

Mức tăng không do rò rỉ ảnh. Vì khoảng một nửa ảnh test ViVQA có trong train (mục 3.2.4), nhóm kiểm lại trên test sạch 1.219 câu (ảnh chưa thấy khi huấn luyện): QLoRA một epoch nâng EM từ 25,0 lên 69,1, tức $+44{,}1$ điểm (CI95 [+41; +47]). Mức tăng từ C1 lên C3 cũng bằng nhau trên ảnh đã thấy và ảnh chưa thấy ($+2{,}9$ và $+2{,}9$ điểm). C3 đạt 77,66 trên ảnh đã thấy và 75,67 trên ảnh chưa thấy; trên tập con nghiêm ngặt hơn (ảnh chưa thấy và cặp hỏi–đáp chưa có trong train, 1.118 câu) C3 đạt 71,74. Phần thổi phồng do trùng ảnh vì vậy nhỏ, khoảng 2 điểm.

4.3 QLoRA nhận biết OCR

Bảng 4.4 là kết quả chính của khóa luận trên ViTextVQA. Phương pháp đề xuất B3-full đạt EM 53,35, ANLS 73,89 và F1 73,73. Hình 4.1 tóm tắt EM của các mô hình chính trên cả hai bộ dữ liệu.



Hình 4.1 EM trên toàn bộ tập test. Màu xám: mốc so sánh (zero-shot và kết quả công bố); xanh: QLoRA; cam: phương pháp đề xuất QLoRA nhận biết OCR.

Bảng 4.4 Kết quả trên toàn bộ tập test ViTextVQA (10.028 câu)

Mô hình	**Dữ liệu train**	**OCR**	**EM**	**ANLS**	**F1**
ViTextBLIP-2 [11]	100%	có	25,48	—	53,95
B1 · zero-shot	—	không	29,12	47,60	53,89
B2-sub · QLoRA	23%	không	46,56	68,90	67,83
B3 · QLoRA nhận biết OCR	23%	có	49,10	70,47	70,03
B2 · QLoRA	100%	không	50,26	72,02	71,16
B3-full · QLoRA nhận biết OCR	100%	có	**53,35**	**73,89**	**73,73**

So sánh có kiểm soát. Mỗi cặp so sánh chỉ khác nhau ở dòng OCR:

- Tập con 8.000 câu: B3 hơn B2-sub 2,54 điểm EM (417 câu chỉ B2-sub đúng so với 672 câu chỉ B3 đúng, $p = 1{,}1 \times 10^{-14}$); ΔANLS +1,57, CI95 [+1,06; +2,08].
- Toàn bộ dữ liệu: B3-full hơn B2 3,09 điểm EM (395 so với 705 câu, $p = 6{,}7 \times 10^{-21}$); ΔANLS +1,87, CI95 [+1,38; +2,36].

Với tập con, B3 vẫn thấp hơn B2 dùng toàn bộ dữ liệu 1,16 điểm EM ($p = 0{,}0025$). Như vậy với 23% dữ liệu và khoảng 25% thời gian huấn luyện, dòng OCR bù được khoảng 69% khoảng cách EM do cắt dữ liệu; khi đủ dữ liệu, QLoRA nhận biết OCR vượt QLoRA thường.

So với kết quả công bố. B3-full có EM 53,35 (CI95 [52,39; 54,33]) và F1 73,73 (CI95 [73,02; 74,45]); cận dưới CI95 cao hơn số công bố của ViTextBLIP-2 ở cả hai thước đo. Bài báo ViTextVQA không công bố hàm chuẩn hóa đáp án, nên so sánh tuyệt đối chỉ mang tính tham khảo; nhóm công khai hàm chấm điểm của mình. Mức chênh có thể tách thành ba phần: mô hình nền tốt hơn (B1 29,12 đã hơn 25,48), QLoRA (+21,1 EM) và OCR (+3,1 EM).

Thước đo không phụ thuộc cách tách từ. Vì token-F1 phụ thuộc cách tách đơn vị, nhóm tính lại F1 sau khi tách từ bằng pyvi. F1 theo từ thấp hơn F1 theo âm tiết 1–3 điểm (B1 51,83; B2 69,07; B3-full 71,67), nhưng mức tăng từ B2 lên B3-full gần như không đổi (+2,57 theo âm tiết, +2,60 theo từ) và thứ hạng B1 < B2 < B3-full giữ nguyên. EM và ANLS so cả chuỗi và theo ký tự nên không phụ thuộc tách từ.

4.4 Ablation

Các ablation dưới đây chạy trên test2000 (2.000 câu ViTextVQA) và tập con train8k, trừ khi ghi khác.

4.4.1 Chỉ thêm OCR khi suy luận

Bảng 4.5 cho thấy đưa dòng OCR vào prompt của một mô hình chưa từng được huấn luyện cùng OCR không cải thiện có ý nghĩa, dù đó là mô hình zero-shot hay mô hình đã QLoRA.

Bảng 4.5 Thêm dòng OCR chỉ lúc suy luận (test2000)

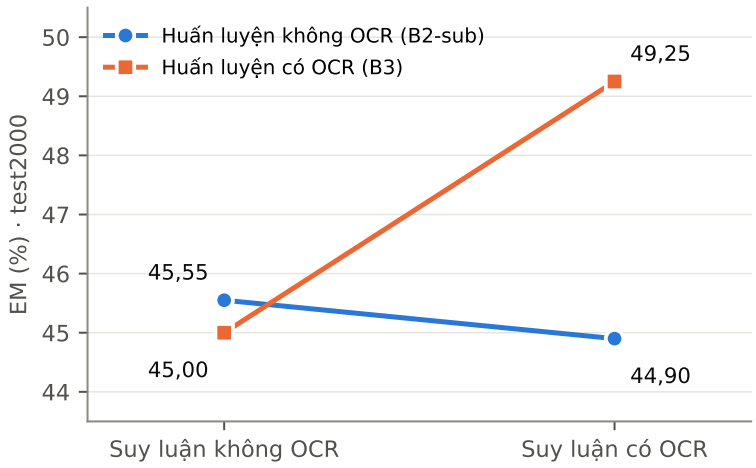
Mô hình	**EM không OCR**	**EM có OCR**	**McNemar p**
B1 · zero-shot	28,80	29,35	0,55
B2 · QLoRA không OCR	49,70	50,70	0,24

4.4.2 OCR lúc huấn luyện × OCR lúc suy luận

Để tách cơ chế, nhóm chạy thí nghiệm giai thừa 2×2 trên cùng tập con 8.000 câu (Bảng 4.6). Chỉ thêm OCR lúc suy luận làm EM giảm 0,65 điểm ($p = 0{,}49$); chỉ huấn luyện cùng OCR rồi suy luận không OCR giảm 0,55 điểm ($p = 0{,}35$). Chỉ khi có OCR ở cả hai lúc, EM mới tăng: 49,25 so với 44,90 ($p = 2{,}2 \times 10^{-8}$). Hiệu ứng tương tác bằng +4,90 điểm EM, CI95 [+3,20; +6,60], và +3,62 điểm ANLS, CI95 [+2,25; +5,03].

Bảng 4.6 EM theo OCR lúc huấn luyện và lúc suy luận (test2000, train8k)

	Suy luận không OCR	**Suy luận có OCR**
Huấn luyện không OCR (B2-sub)	45,55	44,90
Huấn luyện có OCR (B3)	45,00	**49,25**



Hình 4.2 Hiệu ứng tương tác giữa OCR lúc huấn luyện và OCR lúc suy luận (test2000, train8k). Hai đường cắt nhau: OCR chỉ giúp khi có ở cả hai lúc.

Kết quả này (Hình 4.2) cho thấy lợi ích đến từ việc *dạy mô hình dùng dòng OCR*, không đến từ việc thêm OCR vào prompt. Nó cũng cho thấy B3 phụ thuộc OCR: bỏ OCR lúc suy luận, EM của B3 giảm từ 49,25 xuống 45,00 ($p = 3{,}8 \times 10^{-9}$), ngang mức B2-sub. Prototype vì vậy luôn chạy OCR trước khi hỏi mô hình.

4.4.3 Lượng dữ liệu × OCR

Bảng 4.7 so sánh lợi ích của OCR ở hai lượng dữ liệu, trên toàn bộ tập test. Lợi ích của OCR không giảm khi tăng dữ liệu (+2,54 lên +3,09 EM); hiệu ứng tương tác dữ liệu × OCR bằng +0,55, CI95 [−0,20; +1,29], tức hai yếu tố cộng gộp.

Bảng 4.7 EM theo lượng dữ liệu và OCR (toàn bộ test ViTextVQA)

Dữ liệu train	**Không OCR**	**Có OCR**	**Lợi ích của OCR**
23% (8.000 câu)	46,56	49,10	$+2{,}54$ ($p = 1{,}1 \times 10^{-14}$)
100% (35.159 câu)	50,26	53,35	$+3{,}09$ ($p = 6{,}7 \times 10^{-21}$)

4.4.4 Độ ổn định theo seed

Vì B3-full chỉ chạy với một seed, nhóm kiểm độ ổn định của so sánh B3 với B2-sub trên ba seed huấn luyện (Bảng 4.8). Mức tăng $+3{,}57 \pm 0{,}76$ điểm EM và có ý nghĩa thống kê ở cả ba seed. ΔANLS bằng $+1{,}55 \pm 0{,}40$; ở seed 44 cận dưới CI95 của ΔANLS sát 0.

Bảng 4.8 B3 so với B2-sub theo seed (test2000, train8k)

Seed	**EM B2-sub**	**EM B3**	**ΔEM**	**McNemar p**
42	45,55	49,25	$+3{,}70$	$1{,}7 \times 10^{-6}$
43	44,75	49,00	$+4{,}25$	$4{,}0 \times 10^{-8}$
44	46,05	48,80	$+2{,}75$	$1{,}4 \times 10^{-4}$
Trung bình $\pm$ độ lệch chuẩn	$45{,}45 \pm 0{,}66$	$49{,}02 \pm 0{,}23$	$+3{,}57 \pm 0{,}76$	

4.4.5 Cấu hình LoRA

Hai ablation cấu hình dùng công thức B3 (Bảng 4.9). A1 gắn LoRA vào cả các lớp MLP của mô hình ngôn ngữ, với rank 4 để giữ gần bằng số tham số (lệch 1,5%); kết quả không tốt hơn và huấn luyện chậm hơn 17,5%. QLoRA paper [15] khuyên gắn mọi lớp tuyến tính nhưng cũng nêu tổng số tham số LoRA là yếu tố quan trọng nhất; ở đây tổng đó được giữ bằng nhau. A2 tăng rank lên 64: EM tăng 1,05 điểm nhưng không có ý nghĩa thống kê ($p = 0{,}071$; CI95 vẫn chứa mức tăng tới 2,15 nên kết luận này yếu), trong khi adapter nặng gấp bốn. Nhóm giữ cấu hình $r = 16$ trên q, k, v, o.

Bảng 4.9 Ablation cấu hình LoRA (test2000, công thức B3)

	Lớp gắn LoRA	r/α	**Tham số**	**EM**	**ΔEM (CI95), p**	**s/bước**	**MB**
B3	q, k, v, o	16/32	7.372.800	49,25	—	21,48	28,2
A1	q, k, v, o, gate, up, down	4/8	7.483.392	48,70	$-0{,}55$ [$-1{,}60$; $+0{,}45$], 0,34	25,24	28,6
A2	q, k, v, o	64/128	29.491.200	50,30	$+1{,}05$ [$-0{,}05$; $+2{,}15$], 0,071	20,85	112,5

4.4.6 Một adapter cho hai bộ dữ liệu

Adapter SH được huấn luyện trên 10.799 câu ViVQA và 8.000 câu ViTextVQA, mọi câu dùng prompt có OCR (ảnh không có chữ thì prompt trùng prompt không OCR), siêu tham số y hệt C1 và B3. Luật ghi trước coi SH là "không kém" nếu cận dưới CI95 của ΔEM lớn hơn $-1{,}5$ trên từng bộ dữ liệu. Bảng 4.10 cho thấy SH đạt luật trên cả hai bộ: một adapter 29,5 MB phục vụ cả hai loại câu hỏi mà không mất độ chính xác so với adapter chuyên biệt cùng ngân sách. Không có bằng chứng chuyển giao dương giữa hai bộ dữ liệu.

Bảng 4.10 Adapter dùng chung (SH) so với adapter chuyên biệt cùng ngân sách

Tập test	**Mốc → SH (EM)**	**ΔEM (CI95)**	p	**Kết luận**
ViVQA (3.001)	C1 73,78 → 73,51	$-0{,}27$ [$-1{,}13$; $+0{,}60$]	0,60	không kém
ViTextVQA test2000	B3 49,25 → 49,50	$+0{,}25$ [$-0{,}95$; $+1{,}45$]	0,75	không kém

Trên ViVQA, 44% câu có dòng OCR, phần lớn là chữ tiếng Anh trên ảnh COCO mà VietOCR đọc thành chuỗi vô nghĩa; đáp án gold không nằm trong OCR ở câu nào. Trên nhóm câu này, ΔEM bằng $+0{,}15$ [$-1{,}05$; $+1{,}36$] và tỉ lệ chép chữ OCR sai vào câu trả lời chỉ 0,30% (C1: 0,23%): mô hình học được cách bỏ qua dòng OCR không liên quan. SH vẫn thấp hơn các mô hình chính thức (C3 cao hơn 3,13 điểm, B3-full cao hơn 4,35 điểm trên cùng tập) vì chỉ dùng một epoch ViVQA và 23% dữ liệu ViTextVQA; đây là phiên bản rẻ đã ghi trước. Bảng kết quả chính vẫn dùng C3 và B3-full; SH chỉ dùng cho prototype.

4.5 Kết quả theo loại câu hỏi ViTextVQA

Bảng 4.11 chia EM trên toàn bộ test ViTextVQA theo 9 loại câu hỏi của bộ phân loại `qt-v1` (mục 3.2.4). Ba loại đánh dấu † có độ chính xác nhãn dưới 80% nên kém tin cậy.

OCR giúp nhiều nhất ở các loại phải chép đúng từng ký tự: số liên hệ (số điện thoại, website) tăng 8,6 điểm và tên người tăng 6,4 điểm. OCR giúp ít nhất ở loại nguồn ($+0{,}9$), thường là watermark nhỏ ở góc ảnh. Sau B3-full, các loại khó nhất là câu cần suy ra từ chữ thay vì chép lại chữ: sản phẩm, dịch vụ (44,1) và địa điểm (47,0).

4.6 Chi phí tính toán

Bảng 4.12 tổng hợp chi phí của các lần huấn luyện. Mọi lần chạy dùng một GPU L4 24 GB và có VRAM đỉnh không quá 8,4 GB, tức chạy được trên Colab Pro, đúng ràng buộc hiệu

Bảng 4.11 EM theo loại câu hỏi trên toàn bộ test ViTextVQA

Loại câu hỏi	**n**	**B1**	**B2**	**B3-full**	**Δ B2→B3-full**
Nguồn (source)	661	24,5	57,2	58,1	+0,9
Liên hệ (contact)	641	47,9	55,5	64,1	+8,6
Số, thời gian	1.041	41,2	55,7	58,8	+3,1
Người (person)	420	40,7	54,8	61,2	+6,4
Địa điểm (location)	969	25,3	44,0	47,0	+3,0
Tên (name)†	1.971	34,9	55,7	57,6	+1,9
Nội dung chữ†	777	27,4	48,6	51,1	+2,5
Sản phẩm, dịch vụ	1.144	16,5	42,5	44,1	+1,6
Khác†	2.404	21,5	46,1	49,6	+3,5
Tất cả	10.028	29,1	50,3	53,4	+3,1

quả của đề tài. Mô hình chính thức cho ViTextVQA (B3-full) cần 12,75 giờ huấn luyện và khoảng 1 giây suy luận mỗi câu.

Bảng 4.12 Chi phí huấn luyện và suy luận (một GPU L4)

Lần chạy	**Dữ liệu**	**Câu train**	**Giờ train**	**s/bước**	**VRAM**	**Suy luận (s/câu)**
B1 · zero-shot	cả hai	—	—	—	—	0,876 / 0,510
C1 · QLoRA	ViVQA	10.799	3,03	16,17	6,62 GB	0,571
C3 · QLoRA (2 epoch)	ViVQA	10.799	6,07	16,20	6,62 GB	0,571
B2 · QLoRA	ViTextVQA	35.159	11,99	19,63	6,88 GB	1,001
B3-full · QLoRA + OCR	ViTextVQA	35.159	12,75	20,89	8,38 GB	0,996
SH · dùng chung	cả hai	18.799	6,07	18,58	8,15 GB	0,574 / 1,002

Ở mọi lần chạy chính, số tham số huấn luyện là 7.372.800 (0,196%) và adapter nặng 29,5 MB; SH thay hai adapter bằng một. Dòng OCR làm VRAM khi huấn luyện tăng khoảng 1,5 GB và thời gian mỗi bước tăng 6–8% vì prompt dài hơn, còn thời gian suy luận gần như không đổi. OCR chạy một lần cho mỗi ảnh và được cache: khoảng 0,72–0,85 giây mỗi ảnh ViTextVQA và 0,11 giây mỗi ảnh ViVQA (ít chữ) trên T4.

4.7 Phân tích độ nhạy: ảnh có cờ xoay EXIF

Khi kiểm thử prototype, nhóm phát hiện một số ảnh có chữ OCR vô nghĩa trong cache dù ảnh đọc được rõ. Nguyên nhân là ảnh có cờ xoay EXIF: thư viện dò chữ (OpenCV) tự xoay

ảnh theo cờ, còn thư viện cắt ảnh cho VietOCR (PIL) thì không, nên vùng chữ được dò trên ảnh đã xoay nhưng lại cắt trên ảnh chưa xoay. Theo luật ghi trước, nhóm xác nhận: 164/165 ảnh có cờ xoay cho chữ OCR rác, so với 0/200 ảnh đối chứng. Lỗi ảnh hưởng 1,256% câu test ViTextVQA (126 câu trên 41 ảnh), 1,28% câu train và không ảnh hưởng ViVQA.

Sau khi sửa (xoay ảnh trước khi dò và cắt) và OCR lại 167 ảnh, EM của B3-full trên 126 câu bị ảnh hưởng tăng từ 26,98 lên 49,21, và trên toàn tập test tăng từ 53,35 lên 53,63; mức hơn B2 tăng từ $+3{,}09$ lên $+3{,}37$ điểm EM và ΔANLS từ $+1{,}87$ lên $+2{,}05$. Theo luật đã ghi, số chính thức của khóa luận vẫn là số trước khi sửa (53,35); số sau khi sửa được báo như phân tích độ nhạy. Kết luận không đổi, và lỗi này nếu có thì làm phương pháp đề xuất bị đánh giá thấp đi chứ không thổi phồng nó.

4.8 Kiểm chứng prototype

Prototype phải cho đúng câu trả lời như đường đánh giá, nếu không các số trong khóa luận không còn đúng cho bản demo. Nhóm đặt năm luật trước khi kiểm (Bảng 4.13); cả năm đều đạt sau khi sửa ngưỡng thu nhỏ ảnh ở phiên bản 2.

Bảng 4.13 Kiểm chứng prototype theo luật đặt trước

Luật	**Kết quả**	**Ý nghĩa**
R-PAR: backend trùng đường đánh giá	100%	Cùng câu trả lời với lần đánh giá chính thức
R-LIVE: qua giao diện, OCR trực tiếp	100% / 100%	200 ảnh mỗi bộ ViVQA / ViTextVQA
R-OCR: OCR qua giao diện bằng OCR đọc thẳng	100% / 100%	Sau khi nâng ngưỡng ảnh lên 6.000 điểm ảnh mỗi cạnh
R-CONF: mức tin cậy có ý nghĩa	Đạt	EM giảm dần theo mức Cao, Trung bình, Thấp
R-YB: sửa thiên lệch "có"	Đạt	$\tau^* = 4{,}85$; tỉ lệ trả lời "có" 41–45%

Trên Colab L4, độ trễ trung vị là 1,00 giây và phân vị 95 là 3,58 giây mỗi câu, VRAM 4,78 GB. Trên 20 ảnh tự chụp của nhóm, prototype trả lời đúng 14 câu, trong đó đúng cả 5 câu có/không. Phiên bản đầu tiên không đạt luật R-OCR (87,5% trên ViTextVQA) vì giao diện thu nhỏ ảnh lớn hơn 2.048 điểm ảnh trước khi OCR, trong khi 1.418 ảnh ViTextVQA vượt ngưỡng này; nâng ngưỡng lên 6.000 điểm ảnh sửa được lỗi. Một video demo 10 phút 28 giây được ghi lại làm phương án dự phòng.

4.9 Tổng hợp theo giả thuyết

Bảng 4.14 đối chiếu kết quả với luật quyết định của từng giả thuyết ở Bảng 1.2. Bằng chứng cho H4 được trình bày ở mục 5.6.

Bảng 4.14 Kết luận cho từng giả thuyết

ID	Bằng chứng	Kết luận
H1	QLoRA tăng EM 51,7 điểm (ViVQA, một epoch) và 21,1 điểm (ViTextVQA), p gần 0; ngưỡng là 5 điểm.	Ủng hộ
H2	Tương tác OCR huấn luyện $\times$ suy luận $+4{,}9$ EM; đủ dữ liệu B3-full hơn B2 $+3{,}09$ EM ($p = 6{,}7 \times 10^{-21}$), ổn định trên ba seed. Nhưng ΔANLS chỉ $+1{,}87$, dưới ngưỡng 3 điểm (trên ngưỡng bác bỏ 1 điểm).	Ủng hộ một phần
H3	Dạng đã thử là prompt few-shot định dạng: EM giảm 2,1 (ViVQA) và 1,2 (ViTextVQA).	Không được ủng hộ
H4	POPE-vi: B3-full không tăng hallucination theo F1; C3 không kết luận được vì không trả lời dạng có/không; tỉ lệ báo sai của B3-full tăng ở cách chọn adversarial.	Ủng hộ một phần

Về câu hỏi nghiên cứu: RQ1 được trả lời bởi B1 (EM 22,09 và 29,12; lỗi chủ yếu là định dạng và ngôn ngữ). RQ2 được trả lời bởi B2 và C3 (tăng 21,1 và 54,6 điểm EM chỉ với 0,196% tham số). RQ3 được trả lời bởi B3-full và thí nghiệm 2×2: OCR có ích, nhưng chỉ khi mô hình được huấn luyện cùng OCR. RQ4 được thảo luận ở Chương 5.

Chương 5

THẢO LUẬN

Chương 4 cho biết các mô hình đạt bao nhiêu. Chương này trả lời vì sao, và lỗi còn lại nằm ở đâu. Mục 5.1 phân tích QLoRA sửa được loại lỗi nào. Mục 5.2 xem xét cơ chế của QLoRA nhận biết OCR, mục 5.3 và 5.4 phân tích nguồn lỗi còn lại bằng phân tích tự động và duyệt tay, mục 5.5 xem xét lỗi trên ViVQA. Mục 5.6 trả lời RQ4 về hallucination. Mục 5.7 đối chiếu với bốn vấn đề tiếng Việt V1–V4, mục 5.8 nêu ví dụ định tính, mục 5.9 bàn về giới hạn và tính hợp lệ, và mục 5.10 bàn về khía cạnh đạo đức.

Mọi số trong chương chỉ dùng để mô tả, không dùng để chọn mô hình. Định nghĩa kiểu lỗi và trạng thái OCR được ghi lại trước khi chạy phân tích (mục 3.6.6).

5.1 QLoRA sửa loại lỗi nào

Bảng 5.1 phân loại các câu sai EM theo kiểu lỗi. Ở chế độ zero-shot, lỗi thừa chữ (gold nằm trong câu trả lời) chiếm 25,7% số lỗi trên ViTextVQA và 21,3% trên ViVQA. Sau QLoRA, tỉ lệ này giảm còn 13,6% (B2) và 3,9% (C3). Như vậy phần lớn mức tăng của QLoRA đến từ việc mô hình học đúng định dạng đáp án của bộ dữ liệu: ngắn, đúng cách viết. Kết luận này khớp với vấn đề V2 và với phân tích zero-shot ở mục 4.1. Sau QLoRA, lỗi còn lại dịch về phía đọc sai ký tự (lệch vài ký tự, sai dấu) và sai nội dung.

5.2 Cơ chế của QLoRA nhận biết OCR

Thí nghiệm 2×2 (Bảng 4.6) cho thấy OCR chỉ có ích khi mô hình được huấn luyện cùng OCR. Một cách giải thích phù hợp: mô hình chưa thấy OCR khi huấn luyện không biết dòng OCR đáng tin đến đâu, nên dùng nó không phân biệt và sửa bao nhiêu câu thì cũng làm

Bảng 5.1 Kiểu lỗi trên các câu sai EM (% số câu sai của từng mô hình)

Mô hình	Tỉ lệ sai	Sai dấu	Thiếu chữ	Thừa chữ	Lệch $\leq$ 2 ký tự	Khác
ViTextVQA · B1	70,9	3,3	5,0	**25,7**	8,0	57,9
ViTextVQA · B2	49,7	9,0	13,2	13,6	16,8	47,4
ViTextVQA · B3-full	46,6	9,6	15,5	14,5	16,5	43,9
ViVQA · B1	77,9	0,0	3,6	**21,3**	6,4	68,6
ViVQA · C1	26,2	0,5	2,8	3,2	15,1	78,4
ViVQA · C3	23,4	0,0	2,3	3,9	16,0	77,9

hỏng bấy nhiêu câu (16 và 16 trên dev300). Khi được huấn luyện cùng OCR, adapter học được khi nào chép từ OCR và khi nào dựa vào ảnh.

Bảng 5.2 chia các câu thay đổi từ B2 sang B3-full theo trạng thái OCR. Hiệu số 705 câu được sửa trừ 395 câu bị làm hỏng bằng 310 câu, đúng bằng mức tăng 3,09 điểm EM. Lợi ích tập trung ở các câu mà OCR chứa nguyên văn đáp án (sửa 326, hỏng 116). Ở các câu OCR không chứa đáp án, sửa và hỏng gần cân bằng (289 và 211).

Bảng 5.2 Thay đổi từ B2 sang B3-full theo trạng thái OCR (toàn bộ test ViTextVQA)

Trạng thái OCR	n	Sửa được	Làm hỏng	Cùng đúng	Cùng sai
OCR chứa nguyên văn đáp án	3.321	**326**	116	2.105	774
OCR đúng chữ nhưng sai dấu	1.149	90	68	506	485
OCR có chữ, không chứa đáp án	5.526	289	211	2.023	3.003
OCR không đọc ra chữ	32	0	0	11	21
Tất cả	10.028	705	395	4.645	4.283

OCR cũng có thể làm mô hình phân tâm. Trong 138 câu (34,9% số câu bị làm hỏng, khoảng 1,4% tập test), B2 trả lời đúng nhưng B3-full trả lời bằng một cụm khác lấy từ dòng OCR. Đây là cái giá của việc đưa thêm chữ vào prompt, và là một lý do prototype hiển thị chữ OCR để người dùng tự kiểm tra.

5.3 Lỗi còn lại của B3-full: do OCR hay do mô hình

Với mỗi câu ViTextVQA, nhóm xét đúng phần chữ OCR đã vào prompt. Chỉ 33,1% câu có đáp án gold nằm nguyên văn trong OCR; 11,5% câu chỉ khớp khi bỏ dấu (OCR đọc đúng chữ nhưng sai dấu); 55,1% câu OCR có chữ nhưng không chứa nguyên văn đáp án; và 0,3% câu OCR không đọc ra chữ nào. Đáng chú ý, EM của B3-full (53,35) cao hơn nhiều so với tỉ lệ 33,1%, nghĩa là ở nhiều câu mô hình tự đọc ảnh đúng mà OCR không giúp được.

Bảng 5.3 xếp 4.678 câu sai của B3-full theo nguồn lỗi tự động.

Bảng 5.3 Nguồn lỗi tự động của B3-full (4.678 câu sai)

Nguồn lỗi	**%**	**Kiểu lỗi nhiều nhất**
OCR không đưa nguyên văn đáp án vào prompt	81,0	khác 1.816; lệch ký tự 682; thiếu chữ 537
OCR có đáp án, mô hình chép sai đoạn	10,5	thừa chữ 193; thiếu chữ 190
OCR có đáp án, câu trả lời nằm ngoài OCR	8,5	khác 143; thừa chữ 123

Con số 81% cần được đọc thận trọng. Đây là cận trên của lỗi do OCR, vì nhóm "OCR không chứa đáp án" gồm cả những câu cần suy luận (đáp án không được viết nguyên văn trong ảnh) và những câu có gold nhiễu; mục 5.4 tách các trường hợp này bằng duyệt tay. Khi OCR có đáp án mà mô hình vẫn sai, lỗi chủ yếu là cắt sai ranh giới cụm chữ: 383 trong 492 câu lấy thiếu hoặc thừa từ. Sai dấu từ OCR là thách thức riêng của tiếng Việt: 393 trong 450 lỗi sai dấu của B3-full nằm ở nhóm OCR không đưa nguyên văn đáp án. Theo loại câu hỏi, tỉ lệ lỗi do OCR cao nhất ở loại liên hệ (90,9%) và nội dung chữ (87,6%), thấp nhất ở loại số và thời gian (72,5%).

5.4 Duyệt tay 150 lỗi

Bảng 5.4 tổng hợp kết quả duyệt tay mù 100 lỗi EM của B3-full và 50 lỗi EM của C3 (thiết kế ở mục 3.6.6). Cột cuối là tham chiếu từ lần duyệt 200 lỗi của B2 ở giai đoạn trước, chỉ để mô tả: khác người gán, khác mô hình và các khoảng tin cậy chồng nhau.

Bảng 5.4 Kết quả duyệt tay lỗi EM (CI95 Wilson trong ngoặc)

	B3-full (100 lỗi)	**C3 (50 lỗi)**	**Tham chiếu B2 (ViTextVQA / ViVQA)**
Lỗi EM thật ra đúng ý	**55,0** [45,2; 64,4]	**64,0** [50,1; 75,9]	46 / 62
Lỗi là hallucination	5,0 [2,2; 11,2]	16,0 [8,3; 28,5]	9 / 5
EM → độ đúng theo người đọc	53,35 → **79,01**	76,64 → **91,59**	
Hallucination trên mọi câu trả lời	2,33%	3,74%	

Có bốn nhận xét.

EM đánh giá thấp mô hình rất nhiều. Hơn một nửa số lỗi EM của B3-full thật ra đúng ý, nên độ đúng theo người đọc khoảng 79% so với EM 53,35%. Kiểu lỗi lớn nhất là định

Bảng 5.5 Kiểu lỗi theo nhãn tay (% số lỗi đã duyệt)

Kiểu lỗi	B3-full	C3
Định dạng, độ dài (ý đúng)	**40,0**	—
Đồng nghĩa, khác từ (ý đúng)	4,0	**36,0**
Đọc chữ sai	29,0	—
Sai dấu thanh	7,0	—
Sai vùng hoặc không có trong ảnh	15,0	28,0
Gold sai hoặc nhiễu	5,0	**28,0**
Đếm sai	—	6,0
Khác	—	2,0

dạng và độ dài (40%): câu trả lời và gold cùng nội dung nhưng khác cách viết, ví dụ "combo 3" so với gold "3", hoặc khoảng trắng quanh dấu chấm trong địa chỉ email. Với C3, 36% lỗi là đồng nghĩa, nên độ đúng theo người đọc khoảng 92%.

81% lỗi "do OCR" không có nghĩa 81% lỗi do OCR. Trong 78 câu thuộc nhóm OCR không chứa đáp án, chỉ 34 câu (43,6%, CI95 [33,1; 54,6]) là lỗi đọc chữ thật (đọc sai 27, sai dấu 7), còn 28 câu (35,9%) là đúng ý. Tính trên cả mẫu, lỗi đọc chữ thật chiếm 36% (CI95 [27,3; 45,8]) số lỗi của B3-full, tức khoảng 17 điểm EM. Đây là ước lượng thô cho phần mà một OCR tiếng Việt tốt hơn có thể sửa được.

Lỗi cắt sai ranh giới phần lớn được người đọc chấp nhận. Trong 14 câu mô hình chép sai đoạn từ OCR, 11 câu là định dạng hoặc độ dài với ý đúng.

Gold ViVQA nhiễu. 28% lỗi của C3 là do gold sai hoặc nhiễu, khớp với các câu hỏi dịch máy khó hiểu ở mục 5.8.

Giới hạn của lần duyệt này: chỉ một người gán nên không tính được độ đồng thuận κ (bộ nhãn này đã đo $\kappa = 0{,}62$ giữa hai người ở lần duyệt trước); 50 câu ViVQA cho khoảng tin cậy rộng; và "đúng ý" là đánh giá chủ quan.

5.5 Lỗi trên ViVQA

Với C3, lỗi phân bố theo loại câu hỏi như sau:

- **Số lượng** (444 câu, sai 23,0%): toàn bộ lỗi là đếm lệch, chủ yếu lệch một (bốn thành ba 11 câu, ba thành bốn 10 câu, một thành hai 10 câu).

- **Màu sắc** (625 câu, sai 15,7%): nhầm màu gần nhau (nâu thành đen 5 câu, đỏ thành cam 5 câu). Có 4 câu gold "đỏ" bị trả lời "tía", đúng lỗi dịch máy "purple" thành "tía" đã gặp khi duyệt dữ liệu.
- **Vật thể** (1.247 câu, sai 23,3%): nhiều cặp đồng nghĩa hoặc khác mức chi tiết (máy tính và laptop, hải âu và con chim, tủ lạnh và tủ đá).
- **Vị trí** (685 câu, sai 30,7%, khó nhất): lệch mức chi tiết (phòng và phòng ngủ, nhà vệ sinh và phòng tắm).

Phần lớn các lỗi vật thể và vị trí là đúng ý, như duyệt tay ở mục 5.4 xác nhận. Một thước đo chấp nhận đồng nghĩa sẽ phản ánh tốt hơn chất lượng thật của mô hình trên ViVQA.

5.6 Hallucination

Bảng 5.6 trình bày kết quả trên POPE-vi (thiết kế ở mục 3.6.5).

Bảng 5.6 Kết quả POPE-vi (500 ảnh chưa thấy khi huấn luyện, 4.985 câu)

Cấu hình	**F1 random**	**F1 pop.**	**F1 adv.**	**Tỉ lệ "có"**	**Không đọc được**
B1 · zero-shot, prompt thường	84,60	83,17	81,19	40–43%	0,00%
B1-ocr · zero-shot, prompt OCR	83,39	81,99	80,59	38–41%	0,00%
C3	—	—	—	—	91,43%
B3-full	**88,89**	**85,65**	**83,06**	48–55%	0,00%
SH (adapter của prototype)	77,70	72,83	71,17	77–89%	0,16%

5.6.1 Kết luận theo luật

Luật ghi trước so mỗi mô hình với mô hình nền zero-shot dùng cùng dạng prompt và coi mô hình "không tăng hallucination" nếu cận dưới CI95 của ΔF1 lớn hơn -2 ở cả ba cách chọn.

- **B3-full**: ΔF1 $+5{,}50$ / $+3{,}65$ / $+2{,}47$ (random / popular / adversarial) so với B1-ocr: *không tăng hallucination*.
- **C3**: 91,43% câu trả lời không phải "có" hay "không", vượt ngưỡng hợp lệ 5%: *chưa kết luận được*.

- **SH**: ΔF1 $-5{,}69$ / $-9{,}16$ / $-9{,}42$, cận trên CI95 dưới -2: *tăng hallucination*. SH không thuộc H4 vì là adapter của prototype, nhưng kết quả này là một kiểm tra an toàn bắt buộc trước khi dùng.

Với B3-full đạt và C3 không đo được, H4 được kết luận là ủng hộ một phần.

5.6.2 Phân tích sau, ngoài luật

F1 che mất việc B3-full báo sai nhiều hơn. Tỉ lệ báo sai (câu "không" bị trả lời "có") của B1-ocr là 2,7% / 5,7% / 8,9%, còn của B3-full là 8,7% / 16,1% / 22,4%. F1 của B3-full tăng vì recall tăng (73,5% lên 86,9%), bù cho precision giảm. Nếu đo hallucination vật thể theo nghĩa hẹp, tức "nói có vật khi vật không có", thì B3-full bịa nhiều hơn zero-shot, khoảng 2,5 lần ở cách chọn adversarial. Một phần là vì mô hình zero-shot vốn dè dặt (tỉ lệ trả lời "có" khoảng 40%, dưới mức 50% của thiết kế POPE). Đây là một giới hạn phương pháp: F1, thước đo được chọn từ đầu theo cách báo cáo của LLaVA-1.5, không đủ để kết luận về hallucination; cần báo kèm tỉ lệ báo sai và tỉ lệ trả lời "có".

C3 quên cách trả lời có/không. ViVQA không có câu hỏi có/không. Sau QLoRA hai epoch, C3 trả lời câu có/không bằng danh từ ("bức ảnh" 525 lần, "cái ghế" 434 lần), chỉ 372 trên 4.985 câu là "không". Đây là một dạng quên kỹ năng làm theo chỉ dẫn khi huấn luyện trên một tập đáp án hẹp.

SH thiên lệch "có". SH trả lời "có" ở 3.773 trên 4.985 câu, tỉ lệ báo sai 55–79%. Đếm trong dữ liệu cho thấy cả train ViTextVQA lẫn train ViVQA không có đáp án "có" nào, nên giả thuyết "học lệch từ dữ liệu có/không" bị bác; nguyên nhân chưa rõ. Nhóm sửa ở lúc suy luận bằng ngưỡng $\tau^* = 4{,}85$ trên hiệu log xác suất giữa "có" và "không" (mục 3.8), chọn trên một tập hiệu chỉnh tách biệt với POPE-vi. Sau khi sửa, tỉ lệ trả lời "có" của SH về 41–45% và SH đạt luật R-YB, không cần huấn luyện lại. Tỉ lệ báo sai của SH sau khi sửa vẫn cao hơn B1-ocr khoảng 2–4 điểm.

Chen tiếng Anh. B3-full trả lời bằng chữ tiếng Anh "no" ở 881 trên 4.985 câu (17,7%), và gần như luôn đúng (802 câu ở câu có đáp án "không").

Vật bị báo sai nhiều nhất ở mọi cấu hình là cốc, rồi đến ghế, bát và chai. Một phần có thể do chú thích COCO thiếu nhãn, một giới hạn đã ghi trước.

Đối chiếu với duyệt tay. Hallucination chiếm 5,0% lỗi EM của B3-full và 16,0% lỗi của C3 (Bảng 5.4), tức khoảng 2,3% và 3,7% mọi câu trả lời. Hai cách đo cùng cho thấy hallucination không phải loại lỗi chính của các mô hình đã thích nghi trên VQA tiếng Việt.

5.7 Bốn vấn đề tiếng Việt

Bảng 5.7 đối chiếu bốn vấn đề V1–V4 nêu ở Chương 1 với số đo cụ thể của khóa luận.

Bảng 5.7 Bốn vấn đề tiếng Việt và số đo tương ứng

Vấn đề	Số đo
V1 · Dấu thanh khi đọc chữ	OCR giữ đúng dấu: PaddleOCR 27,0% so với VietOCR 37,7% ($p = 0{,}0008$); 9,0% lỗi của B2 chỉ sai dấu; 11,5% câu có OCR đúng chữ nhưng sai dấu; zero-shot EM 22,4 với đáp án có dấu so với 39,4 với đáp án Latin không dấu.
V2 · Sai ngôn ngữ, sai định dạng	Zero-shot trả lời dài: 2,9 so với 1,6 từ (ViVQA), 5,4 so với 3,7 từ (ViTextVQA); lỗi thừa chữ giảm từ 25,7% xuống 13,6% số lỗi sau QLoRA; B3-full trả lời "no" tiếng Anh ở 17,7% câu có/không.
V3 · Thứ tự chữ, ranh giới cụm	Nhầm vùng chữ chiếm 23% lỗi của B2; 383/492 lỗi khi OCR có đáp án là cắt sai ranh giới cụm; F1 theo từ thấp hơn F1 theo âm tiết 1–3 điểm.
V4 · Hallucination	2,3% câu trả lời của B3-full; POPE-vi ΔF1 từ $+2{,}5$ đến $+5{,}5$, nhưng tỉ lệ báo sai tăng ở cách chọn adversarial.

V2 được QLoRA sửa phần lớn. V1 và V3 là lý do chọn QLoRA nhận biết OCR, và cũng là nơi còn nhiều lỗi nhất: khoảng 17 điểm EM của B3-full là lỗi đọc chữ thật. V4 được đo riêng bằng POPE-vi và duyệt tay.

5.8 Ví dụ định tính

Bảng 5.8 nêu các ví dụ được rút tất định (seed 42) từ các nhóm lỗi, minh họa những hiện tượng đã đo ở trên.

Trên ViVQA, câu hỏi "đồng hồ và tranh cũ dòng những gì" với gold "tường" là một ví dụ câu hỏi dịch máy khó hiểu: cả B1 ("đồng hồ và tranh cũ dòng những bức tranh") lẫn C3 ("con chim") đều trả lời sai. Câu hỏi "màu của nho là gì" với gold "màu đỏ" được C3 trả lời "màu tía"; ranh giới giữa đỏ, tía và đen của nho vốn mơ hồ.

Bảng 5.8 Ví dụ định tính trên test ViTextVQA và ViVQA

Hiện tượng	Câu hỏi	Gold	B2	B3-full	Ghi chú
OCR sửa đúng tên riêng	trạm xăng này có tên là gì?	mipec	mipeo	**mipec**	chép đúng từng ký tự
OCR sửa đúng số	bức hình được chụp vào năm nào?	2016	2017	**2016**	số dễ đọc nhầm
OCR sửa cả chữ lẫn độ dài	trường thpt này mang tên gọi là gì?	đào duy từ	thành phố đào duy trì	**đào duy từ**	
OCR làm phân tâm	… liên hệ với người nào?	cô tuyết	**cô tuyết**	có tuyết	OCR sai dấu
Cắt sai ranh giới	món cơm gà hải nam làm theo nước nào?	kiểu singapore	**kiểu singapore**	singapore	đúng ý
Sai dấu thanh	di tích lịch sử này tên gì?	nhà tù hòa bình	nhà từ hòa bình	nhà tu hòa bình	cả hai sai
Định dạng	máy mài góc … thuộc combo nào?	3	combo 3	combo 3	đúng ý
Chuỗi dài	địa chỉ email của công ty là gì?	tnhhanphat-vn@gmail . com	tnhanhphat-vn@…	tnhphanhat-vn@…	lệch vài ký tự

5.9 Giới hạn và tính hợp lệ

Một seed cho mô hình chính. B3-full và C3 chỉ chạy với seed 42 vì mỗi lần huấn luyện B3-full mất gần 13 giờ GPU. Độ ổn định theo seed chỉ được kiểm trên tập con 8.000 câu (ba seed, $+3{,}57 \pm 0{,}76$ EM). Với $p = 6{,}7 \times 10^{-21}$ trên 10.028 câu, khả năng kết luận B3-full hơn B2 đảo chiều theo seed là thấp, nhưng độ lớn chính xác của mức tăng có thể dao động.

EM quá khắt khe. Duyệt tay cho thấy 55% lỗi EM của B3-full và 64% lỗi của C3 thật ra đúng ý. EM vì vậy đánh giá thấp chất lượng thật; nhóm bổ sung ANLS và duyệt tay, nhưng chưa có đánh giá người quy mô lớn.

So sánh với kết quả công bố. Bài báo ViTextVQA không công bố hàm chuẩn hóa đáp án. Mức chênh với ViTextBLIP-2 lớn đến mức khó do chuẩn hóa gây ra, nhưng con số tuyệt đối chỉ mang tính tham khảo.

H2 về ANLS chưa đạt ngưỡng. OCR giúp trả lời đúng nguyên chuỗi (EM) rõ hơn là giúp gần đúng theo ký tự (ANLS $+1{,}87$ so với ngưỡng 3). Ngưỡng được đặt trước khi có số liệu và nhóm giữ nguyên.

Phụ thuộc OCR. B3 phụ thuộc vào OCR: bỏ OCR lúc suy luận thì về mức không OCR. Chất lượng OCR tiếng Việt cho chữ cảnh là nút thắt chính, và lỗi EXIF (mục 4.7) cho thấy đường OCR cần được kiểm chặt.

Dữ liệu. Câu hỏi ViVQA được dịch máy và một phần gold nhiễu; khoảng một nửa ảnh test ViVQA có trong train. Nhóm đo và báo cáo các vấn đề này, đồng thời kiểm trên tập sạch, nhưng không sửa dữ liệu để giữ khả năng so sánh. Bộ phân loại câu hỏi `qt-v1` có độ chính xác 80,7%, nên bảng theo loại câu hỏi chỉ mang tính mô tả.

POPE-vi. Chú thích COCO có thể thiếu nhãn vật thể, và mô hình nền có thể đã thấy ảnh COCO khi tiền huấn luyện. POPE-vi chỉ đo hallucination vật thể trên ảnh đời thường, chưa đo hallucination chữ trên ảnh có chữ.

Người gán nhãn. Lần duyệt tay cuối chỉ có một người gán.

Độ mạnh kiểm định trên test2000. Các ablation trên 2.000 câu chỉ phát hiện được chênh lệch từ khoảng 1,7 điểm EM; vì vậy kết luận "không khác biệt" ở ablation cấu hình LoRA là kết luận yếu.

5.10 Khía cạnh đạo đức và sử dụng có trách nhiệm

Quyền riêng tư. Ảnh người dùng tải lên có thể chứa khuôn mặt, giấy tờ hoặc thông tin cá nhân. Prototype không lưu ảnh hay câu hỏi, chỉ ghi thời gian xử lý.

Thiên lệch ngôn ngữ. Mô hình nền được tiền huấn luyện thiên về tiếng Anh. Khóa luận đo được thiên lệch này (chênh 17 điểm EM giữa đáp án có dấu và không dấu ở zero-shot; mô hình chen tiếng Anh) và giảm nó bằng thích nghi, nhưng không loại bỏ hoàn toàn.

Hallucination và độ tin cậy. Câu trả lời trôi chảy nhưng sai là rủi ro chính. Prototype hiển thị chữ OCR và mức tin cậy để người dùng tự kiểm tra, và chỉ hiện mức (Cao, Trung bình, Thấp) vì độ tin cậy chưa được hiệu chỉnh tốt (ECE 0,198). Hệ thống không nên được dùng cho các tình huống nhạy cảm như y tế hoặc pháp lý khi chưa có người kiểm tra.

Giấy phép dữ liệu. ViTextVQA được dùng qua kho có kiểm soát truy cập, theo giấy phép CC BY-NC 3.0 chỉ cho mục đích nghiên cứu phi thương mại; tập test có đáp án không được phát tán lại.

Chương 6

KẾT LUẬN

6.1 Tóm tắt

Khóa luận nghiên cứu cách thích nghi một vision-language model mã nguồn mở cho hỏi đáp trên ảnh tiếng Việt dưới ràng buộc tài nguyên chặt: chỉ dùng parameter-efficient fine-tuning và chỉ một GPU Colab. Nhóm chọn Qwen2.5-VL-3B-Instruct làm baseline, tái lập nó trên TextVQA val (79,60 so với 79,3 công bố), đo baseline zero-shot trên ViVQA và ViTextVQA, rồi thích nghi bằng QLoRA với 7,37 triệu tham số huấn luyện, tức 0,196% tổng số tham số.

Cải tiến đề xuất là QLoRA nhận biết OCR: chữ trong ảnh được đọc bằng VietOCR, sắp theo thứ tự đọc và đưa vào prompt ngay trong lúc huấn luyện. Trên toàn bộ 10.028 câu test ViTextVQA, phương pháp này đạt EM 53,35, hơn QLoRA thông thường với cùng dữ liệu 3,09 điểm ($p = 6{,}7 \times 10^{-21}$) và cao hơn kết quả công bố tốt nhất trước đây (EM 25,48). Trên ViVQA, QLoRA nâng EM từ 22,09 lên 76,64.

6.2 Trả lời các câu hỏi nghiên cứu

RQ1. *Zero-shot đạt bao nhiêu, và lỗi tiếng Việt nào chiếm ưu thế?* Zero-shot đạt EM 22,09 trên ViVQA và 29,12 trên ViTextVQA. Lỗi chiếm ưu thế là sai định dạng: mô hình trả lời dài hơn đáp án (2,9 so với 1,6 từ trên ViVQA) và đôi khi trả lời bằng tiếng Anh. Đáp án có dấu thanh khó hơn rõ rệt so với đáp án chỉ gồm chữ Latin. Prompt few-shot định dạng không sửa được các lỗi này (H3 không được ủng hộ).

RQ2. *QLoRA cải thiện bao nhiêu khi không dùng full fine-tuning?* QLoRA tăng EM thêm 21,1 điểm trên ViTextVQA và 54,6 điểm trên ViVQA (mô hình chính thức C3), chỉ với 0,196% tham số, một GPU L4, tối đa 12,75 giờ huấn luyện và VRAM đỉnh dưới

8,4 GB. Mức tăng chủ yếu đến từ việc học đúng định dạng đáp án và không do rò rỉ ảnh: trên tập test sạch, mức tăng vẫn là 44,1 điểm (H1 được ủng hộ).

RQ3. *Chữ OCR có giúp, và có cộng hưởng với QLoRA không?* Có, nhưng chỉ khi mô hình được huấn luyện cùng OCR. Thêm OCR vào prompt của một mô hình chưa từng thấy OCR không cải thiện; huấn luyện cùng OCR cho hiệu ứng tương tác +4,9 điểm EM, ổn định trên ba seed, và lợi ích không giảm khi tăng dữ liệu. Mức tăng ANLS (+1,87) thấp hơn ngưỡng 3 điểm đặt trước, nên H2 được ủng hộ một phần: OCR giúp trả lời đúng nguyên chuỗi nhiều hơn là giúp gần đúng theo ký tự.

RQ4. *Sau khi thích nghi, mô hình bịa nội dung nhiều hơn hay ít hơn?* Trên POPE-vi, B3-full không tăng hallucination theo luật đặt trước (ΔF1 từ +2,5 đến +5,5), nhưng tỉ lệ báo sai vật thể tăng ở cách chọn adversarial. C3 không đo được vì đã quên cách trả lời có/không. Duyệt tay cho thấy hallucination chỉ chiếm khoảng 2,3% (B3-full) và 3,7% (C3) mọi câu trả lời. H4 được ủng hộ một phần.

6.3 Đóng góp

1. **QLoRA nhận biết OCR cho VQA tiếng Việt**, với cơ chế được tách bạch bằng thí nghiệm 2×2: lợi ích đến từ việc dạy mô hình dùng OCR, không đến từ việc thêm OCR vào prompt.

2. **Thích nghi hiệu quả và tái lập được.** Kết quả trên ViTextVQA cao hơn kết quả công bố trước đây với 0,196% tham số trên một GPU; mọi con số có log, seed và cấu hình, kèm gói tái lập gồm mã nguồn, adapter, cấu hình, script suy luận và hướng dẫn chạy lại.

3. **Đo các vấn đề riêng của tiếng Việt.** Bốn vấn đề V1–V4 đều có số đo cụ thể; POPE-vi là bộ đo hallucination tiếng Việt gồm 4.985 câu trên 500 ảnh chưa thấy khi huấn luyện.

4. **Phân tích lỗi hai tầng.** Phân tích tự động theo kiểu lỗi và trạng thái OCR, đối chiếu với duyệt tay mù, cho thấy EM đánh giá thấp mô hình và ước lượng phần còn có thể cải thiện nhờ OCR tốt hơn (khoảng 17 điểm EM).

5. **Prototype đã kiểm chứng.** Ứng dụng web trả lời kèm chữ OCR và mức tin cậy, được kiểm cho cùng câu trả lời với đường đánh giá chính thức, với độ trễ trung vị khoảng 1 giây trên một GPU L4.

6.4 Giới hạn

Các giới hạn chính đã được phân tích ở mục 5.9: mô hình chính chỉ chạy một seed; EM quá khắt khe với câu trả lời đúng ý nhưng khác cách viết; chất lượng OCR tiếng Việt cho chữ cảnh là nút thắt; ngưỡng ANLS của H2 chưa đạt; F1 trên POPE-vi che mất tỉ lệ báo sai; so sánh với kết quả công bố phụ thuộc cách chuẩn hóa đáp án của bài báo; và lần duyệt tay cuối chỉ có một người gán.

6.5 Hướng phát triển

1. **Nâng cấp OCR tiếng Việt cho chữ cảnh**: fine-tune VietOCR trên chữ cảnh và cải tiến thứ tự đọc. Đây là hướng có trần cải thiện lớn nhất theo phân tích lỗi.
2. **OCR có vị trí**: đưa tọa độ và thứ tự các hộp chữ vào mô hình theo hướng của M4C [7], để giảm lỗi cắt sai ranh giới cụm chữ.
3. **Đánh giá có người chấm và thước đo chấp nhận đồng nghĩa**, vì hơn một nửa lỗi EM là đúng ý.
4. **Cân bằng câu hỏi có/không khi huấn luyện** để tránh quên định dạng như C3, và đo hallucination chữ trên ảnh có chữ, không chỉ hallucination vật thể.
5. **Hiệu chỉnh độ tin cậy** (ví dụ temperature scaling) để prototype có thể hiện xác suất thay cho mức.
6. **Thêm seed cho mô hình chính** và thử các mô hình nền mới hơn dưới cùng giao thức đánh giá.

Kết quả của khóa luận cho thấy một nhóm có tài nguyên hạn chế vẫn có thể thích nghi một VLM lớn cho tiếng Việt và đạt kết quả vượt các công trình trước, miễn là mỗi thay đổi được đo dưới cùng điều kiện và mỗi kết luận được kiểm định.

Tài liệu tham khảo

[1] S. Bai *et al.*, "Qwen2.5-VL technical report," 2025, arXiv:2502.13923.

[2] Y. Du *et al.*, "PP-OCR: A practical ultra lightweight OCR system," 2020, arXiv:2009.09941.

[3] B. C. Q. Pham, "VietOCR: Transformer-based Vietnamese optical character recognition," https://github.com/pbcquoc/vietocr, 2020.

[4] S. Antol, A. Agrawal, J. Lu, M. Mitchell, D. Batra, C. L. Zitnick, and D. Parikh, "VQA: Visual question answering," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015.

[5] A. Singh, V. Natarajan, M. Shah, Y. Jiang, X. Chen, D. Batra, D. Parikh, and M. Rohrbach, "Towards VQA models that can read," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

[6] A. F. Biten *et al.*, "Scene text visual question answering," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.

[7] R. Hu, A. Singh, T. Darrell, and M. Rohrbach, "Iterative answer prediction with pointer-augmented multimodal transformers for TextVQA," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[8] J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023.

[9] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] B. Xiao *et al.*, "Florence-2: Advancing a unified representation for a variety of vision tasks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[11] Q. V. Nguyen, D. Q. Tran, H. Q. Pham, T. K.-B. Nguyen, N. H. Nguyen, K. V. Nguyen, and N. L.-T. Nguyen, "ViTextVQA: A large-scale visual question answering dataset for evaluating Vietnamese text comprehension in images," 2024, arXiv:2404.10652; extended version in Expert Systems with Applications.

[12] N. Houlsby *et al.*, "Parameter-efficient transfer learning for NLP," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.

[13] Y.-L. Sung, J. Cho, and M. Bansal, "VL-Adapter: Parameter-efficient transfer learning for vision-and-language tasks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 5227–5237.

[14] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations (ICLR)*, 2022.

[15] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[16] K. Q. Tran, A. T. Nguyen, A. T.-H. Le, and K. V. Nguyen, "ViVQA: Vietnamese visual question answering," in *Proceedings of the 35th Pacific Asia Conference on Language, Information and Computation (PACLIC)*, 2021.

[17] Y. Li, Y. Du, K. Zhou, J. Wang, W. X. Zhao, and J.-R. Wen, "Evaluating object hallucination in large vision-language models," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023.

[18] M. Ren, R. Kiros, and R. Zemel, "Exploring models and data for image question answering," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.

[19] H. Liu, C. Li, Y. Li, and Y. J. Lee, "Improved baselines with visual instruction tuning," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[20] X. L. Li and P. Liang, "Prefix-tuning: Optimizing continuous prompts for generation," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2021.

[21] N. H. Nguyen *et al.*, "OpenViVQA: Task, dataset, and multimodal fusion models for visual question answering in Vietnamese," *Information Fusion*, 2023.

[22] D.-M. Nguyen-Tran, T. Le, M. L. Nguyen, and H. T. Nguyen, "Bi-directional cross-attention network on Vietnamese visual question answering," in *Proceedings of the 36th Pacific Asia Conference on Language, Information and Computation (PACLIC)*, 2022, pp. 834–841.

[23] N. H. Nguyen and K. V. Nguyen, "PAT: Parallel attention transformer for visual question answering in Vietnamese," 2023, arXiv:2307.08247.

[24] K. V. Tran *et al.*, "BARTPhoBEiT: Pre-trained sequence-to-sequence and image transformers models for Vietnamese visual question answering," 2023, arXiv:2307.15335.

[25] N. S. Nguyen, V. S. Nguyen, and T. Le, "Advancing Vietnamese visual question answering with transformer and convolutional integration," *Computers and Electrical Engineering*, vol. 119, p. 109474, 2024.

[26] A. Rohrbach, L. A. Hendricks, K. Burns, T. Darrell, and K. Saenko, "Object hallucination in image captioning," in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2018.

[27] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2014.

[28] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations (ICLR)*, 2021.

[29] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.

[30] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[31] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.

[32] A. Abid, A. Abdalla, A. Abid, D. Khan, A. Alfozan, and J. Zou, "Gradio: Hassle-free sharing and testing of ML models in the wild," 2019, arXiv:1906.02569.

[33] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017.

[34] P. Wang *et al.*, "Qwen2-VL: Enhancing vision-language model's perception of the world at any resolution," 2024, arXiv:2409.12191.

Phụ lục A

Kế hoạch quản lý dự án

Phụ lục này mô tả cách nhóm tổ chức 15 tuần thực hiện khóa luận: phạm vi công việc, các mốc, rủi ro, cách bảo đảm chất lượng, phân công, giao tiếp và quản lý tài liệu, mã nguồn. Đề tài là một nghiên cứu nên kế hoạch xoay quanh thí nghiệm: mỗi kết luận ở Chương 4 phải truy ngược được về một lần chạy có log, seed và cấu hình cố định.

A.1 Phạm vi công việc và ước lượng

Công việc được chia thành tám gói (Bảng A.1). Thời gian tính theo tuần làm việc W01–W15 trong khung 15 tuần của đề cương; mục A.4 trình bày cách các tuần này khớp với lịch thực.

Ước lượng ban đầu ở W01 giả định có GPU server của trường. Đến W06, nhóm xác nhận trường không có GPU server, nên chi phí được ước lượng lại theo đơn vị tính toán (compute unit, CU) của Google Colab. Từ W08, trước mỗi việc cần GPU, nhóm ước tính số giờ GPU và số CU (L4 khoảng 1,54 CU/giờ, T4 khoảng 1,2 CU/giờ), rồi đối chiếu với số đọc thực tế trên Colab. Một lần huấn luyện QLoRA đầy đủ trên ViTextVQA mất khoảng 12 giờ L4 (B2: 11,99 giờ; B3-full: 12,75 giờ), nên số lần huấn luyện đầy đủ là ràng buộc lớn nhất của kế hoạch.

A.2 Mục tiêu quản lý

- **Tái lập được:** mọi lần chạy ghi split, seed, phần cứng, siêu tham số, thời gian huấn luyện và suy luận.
- **Không chọn kết quả sau khi thấy số:** luật quyết định của mỗi phép thử chính được commit lên Git trước khi chạy.

Bảng A.1 Phân rã công việc

Gói công việc	Nội dung chính	Tuần	Phụ trách chính
1. Khảo sát và định hướng	Đọc paper theo mảng, literature matrix, khoảng trống nghiên cứu, câu hỏi nghiên cứu, giả thuyết	W01–W03	Cả nhóm
2. Dữ liệu	Lấy ViVQA và ViTextVQA từ nguồn chính thức, cố định split, kiểm tra rò rỉ train/test, OCR cache	W02, W05, W08, W14	SV2
3. Baseline	Tái lập Qwen2.5-VL-3B-Instruct zero-shot (B1), đối chiếu số công bố trên TextVQA (R0), chốt cấu hình suy luận	W04–W07	SV1
4. Thích nghi bằng QLoRA	Đường ray huấn luyện QLoRA; các mô hình B2, B3, B3-full, C3, adapter dùng chung SH; ablation cấu hình LoRA	W06–W11	SV3
5. Đánh giá	EM, VQA-Acc, ANLS, F1; kiểm định McNemar ghép cặp; độ ổn định qua seed; bảng đánh giá đầy đủ	W05–W11	SV4
6. Phân tích	Error analysis, phân loại câu hỏi, hallucination POPE-vi, ngân sách token, ảnh hưởng của chuẩn hóa và tách từ lên metric	W07, W11–W12, W15	SV4, SV3
7. Prototype	Web demo, hiệu chỉnh ngưỡng có/không, kiểm tra prototype khớp hệ thống đã đánh giá, video demo	W13–W14	SV4
8. Báo cáo và bảo vệ	Báo cáo tuần, slide review, gói tái lập, khóa luận	Hằng tuần, W15	Cả nhóm, trưởng nhóm điều phối

- **Đúng ràng buộc tài nguyên:** chỉ dùng QLoRA, mọi thí nghiệm chạy được trên một GPU Colab (T4 hoặc L4).
- **Đúng mốc:** xong nghiên cứu chính trước Review 2 và hội đồng cấp khoa.

Đến hết W14, thư mục `experiments/` có 141 lần chạy, lần nào cũng có log. Sáu mô hình chính thức được liệt kê trong `configs/official_models.json`, file này sinh tự động từ log; bốn adapter lưu trên Google Drive đều khớp mã băm SHA-256 đã ghi.

A.3 Rủi ro

Kế hoạch W01 liệt kê tám rủi ro (mô hình quá lớn, thiếu GPU, dữ liệu lỗi, baseline khó tái lập, OCR kém, huấn luyện không hội tụ, demo khó triển khai, huấn luyện chậm). Bảng A.2 ghi lại các rủi ro đã thực sự xảy ra và cách nhóm xử lý.

A.4 Quy trình dự án

Nhóm làm theo chu kỳ tuần. Mỗi tuần làm việc đi qua năm bước:

1. **Lập kế hoạch:** chọn câu hỏi của tuần từ kế hoạch tổng và kết quả tuần trước, ghi vào README của tuần.
2. **Ghi luật trước:** với mỗi phép thử chính, viết luật quyết định (ngưỡng, kiểm định, tập dữ liệu) và commit lên Git trước khi chạy.
3. **Chạy:** code được viết và tự kiểm tra (self-test) trên máy cá nhân rồi đẩy lên GitHub; notebook Colab clone repo và chạy trên GPU; log, kết quả lưu trên Google Drive.
4. **Kiểm tra:** tính lại số liệu từ file dự đoán gốc (`predictions.json`) thay vì chép tay, và clone lại repo để xác minh từng commit.
5. **Đóng tuần:** cập nhật README, Team Report của tuần và bản nháp các chương liên quan.

Tuần làm việc W01–W15 được đánh số theo nội dung trong khung của đề cương, không theo lịch. Nhóm làm nhanh hơn lịch: ngày 02/11/2026 (tuần thực 9), nhóm đã sang W15. Tuần thực tính từ thứ Hai 07/09/2026 là tuần 1. Bảng A.3 đối chiếu hai cách đếm.

Các mốc của khoa giữ nguyên theo lịch thực (Bảng A.4). Điểm khóa luận gồm 50% quá trình, trong đó nhóm nộp 7 báo cáo cho giảng viên hướng dẫn, và 50% bảo vệ.

Bảng A.2 Rủi ro đã xảy ra và cách xử lý

Rủi ro	**Tuần**	**Mức**	**Cách xử lý**
Trường không có GPU server	W06	Cao	Chuyển toàn bộ huấn luyện sang Colab; nâng lên Colab Pro ngày 07/10/2026 để dùng L4
fp16 trên T4 làm hỏng câu trả lời	W06	Cao	Dò kiểu số trên 73 câu: fp16 hỏng 23 câu; chuyển sang bf16 trên L4 (0/73 câu hỏng)
Dữ liệu sai nguồn	W05	Cao	Dữ liệu trên máy là ViVQA-X chứ không phải ViVQA, còn ViTextVQA lấy từ bản sao không chính thức. Tải lại ViVQA từ repo gốc, xin quyền kho gated của ViTextVQA, dùng đáp án `test_gt.json`
Một lần huấn luyện đầy đủ tốn khoảng 12 giờ	W08	Trung bình	Chạy phép thử chính trên tập con 8.000 câu (B3 so với B2-sub); chỉ chạy bản đầy đủ B3-full ở W10 khi kết quả tập con đã rõ
Thư viện đổi API	W06	Thấp	`transformers` 5.17.0 bỏ `warmup_ratio`; đổi sang `warmup_steps`, ghi phiên bản thư viện vào log
PaddleOCR bản GPU xung đột với torch trong prototype	W13	Trung bình	Chạy OCR trong một tiến trình riêng (`src/prototype/ocr_worker.py`)
Adapter dùng chung thiên về trả lời "có"	W12–W13	Trung bình	Chọn ngưỡng trên logit token đầu bằng tập calibration tách rời tập POPE-vi
Ảnh có cờ xoay EXIF làm sai OCR cache	W14	Trung bình	Kiểm tra theo luật ghi trước (164/165 ảnh có cờ xoay bị lệch); sửa `ocr.py`, OCR lại 167 ảnh, suy luận lại B3-full (EM 53,35 → 53,63)
Lịch review thay đổi	W10	Thấp	Review 2 dời sang 29/10/2026; nhóm cập nhật một bộ slide cộng dồn thay vì làm lại

Bảng A.3 Tuần làm việc và lịch thực (năm 2026)

Tuần	**Nội dung chính**	**Thời gian thực**
W01–W02	Định hướng, kế hoạch 15 tuần, literature matrix, phân tích dữ liệu	07–16/09
W03	Hồ sơ Review 1	17/09 (Review 1: 24/09)
W04	Baseline zero-shot đầu tiên; đổi baseline sang Qwen2.5-VL-3B	18–21/09
W05	Dữ liệu chính thức; baseline zero-shot trên cả hai tập	22–27/09
W06	Chẩn đoán lỗi fp16; đường ray QLoRA	28–29/09
W07	Chốt cấu hình trên L4; B1 chính thức; B2; tái lập R0	30/09–12/10
W08	OCR-enhanced prompting; B3 trên tập con	12–14/10
W09	Ổn định qua seed; bảng 2×2; ViVQA 2 epoch	15–17/10
W10	Ablation cấu hình LoRA; B3-full	19–21/10
W11	Bảng đánh giá đầy đủ; adapter dùng chung	21–22/10
W12	Hallucination POPE-vi; error analysis	23–24/10
W13	Prototype web	26–31/10
W14	Hoàn thiện code, video demo, gói tái lập	01–02/11
W15	Góp ý Review 2, slide bảo vệ, khóa luận	từ 02/11

Bảng A.4 Các mốc của khoa

Mốc	**Thời gian**	**Nội dung**	**Trạng thái**
Review 1	24/09/2026 (tuần thực 3)	Bài toán, khoảng trống, câu hỏi nghiên cứu, kế hoạch; hai giảng viên không phải GVHD nhận xét	Đã qua, 10 góp ý
Review 2	29/10/2026 (tuần thực 8)	Baseline đã tái lập, phương pháp, kết quả sơ bộ	Đã qua
Hội đồng cấp Khoa/Bộ môn	30/11–06/12/2026 (tuần thực 13)	Ba thành viên, 60 phút mỗi nhóm	Chưa diễn ra
Hội đồng cấp trường	14–20/12/2026 (tuần thực 15)	Năm thành viên	Chưa diễn ra

A.5 Quản lý chất lượng

Trong đề tài này, chất lượng trước hết là độ tin cậy của con số. Nhóm dùng năm biện pháp:

- **Luật ghi trước:** ngưỡng và cách kết luận cho mỗi phép thử chính được commit trước khi có kết quả, ví dụ luật cho adapter dùng chung (commit `324caeb`, W11) và luật hallucination H4 (commit `9209170`, W12).
- **Kiểm định ghép cặp:** mọi so sánh hai mô hình trên cùng tập test dùng McNemar trên từng câu cho EM và khoảng tin cậy 95% bằng bootstrap ghép cặp cho ANLS; kết quả chính được lặp lại với seed 42, 43 và 44.
- **Tính lại từ dữ liệu gốc:** bảng kết quả cuối (`src/eval/full_eval_table.py`) đọc trực tiếp các file `predictions.json`, không chép số từ báo cáo tuần.
- **Self-test:** các module chính có chế độ `--selftest` chạy trên CPU, cả Windows lẫn Linux, để bắt lỗi trước khi tốn GPU.
- **Mã băm và chữ ký run:** adapter, OCR cache, file dữ liệu và slide được ghi mã SHA-256; mỗi run mang chữ ký cấu hình nên script không ghi tiếp kết quả của cấu hình khác vào cùng thư mục.

A.6 Kế hoạch đào tạo

Đề tài cần kiến thức ở bốn mảng khác nhau, nên ở W01 mỗi thành viên đọc ít nhất ba paper thuộc mảng của mình và trả lời 10 câu hỏi cố định cho mỗi paper, trong đó bắt buộc có câu "dùng được gì cho đề tài" (Bảng A.5).

Bảng A.5 Paper nền tảng theo mảng

Mảng	Paper đã đọc
SV1: VLM / Baseline	BLIP-2, Florence-2, Qwen2.5-VL
SV2: Dataset / OCR	ViVQA, ViTextVQA, TextVQA (LoRRA)
SV3: PEFT / Training	LoRA, QLoRA, VL-Adapter, LLaVA-1.5
SV4: Evaluation / Deployment	POPE, VQAv2, Survey Vision-Language Models (TPAMI 2024)

Những kỹ năng còn lại nhóm học trong quá trình làm: huấn luyện QLoRA với PEFT và bitsandbytes, PaddleOCR và VietOCR, kiểm định McNemar, và cách làm việc giữa máy cá nhân, GitHub, Colab và Google Drive. Sổ thuật ngữ song ngữ `docs/Glossary.md` được cập nhật suốt dự án.

A.7 Sản phẩm bàn giao

Bảng A.6 liệt kê sản phẩm theo yêu cầu của đề cương, gồm cả gói tái lập. Trạng thái tính đến ngày 10/11/2026.

Bảng A.6 Sản phẩm bàn giao

Sản phẩm	Vị trí	Trạng thái
Mã nguồn: 46 module Python (dữ liệu, huấn luyện, đánh giá, prototype)	`src/` trên GitHub (PLHGNAOH/ViVQA-VLM)	Hoàn thành
30 notebook Colab	`notebooks/`	Hoàn thành
Log 141 lần chạy	`experiments/`	Hoàn thành
Adapter QLoRA của các mô hình chính thức	Google Drive; mã băm trong `configs/official_models.json`	Hoàn thành
Gói tái lập: hướng dẫn, phiên bản thư viện, script suy luận	`docs/REPRODUCE.md`, `requirements-colab.txt`, `src/prototype/infer.py`	Hoàn thành
Prototype web và video demo (10 phút 28 giây)	`src/prototype/`, Google Drive	Hoàn thành
Báo cáo tuần W01–W15	`docs/W01/` đến `docs/W15/`	W15 đang làm
Slide Review 1, Review 2 (tiếng Anh, tiếng Việt)	`docs/W03/`, `docs/04_slides/`	Hoàn thành; slide bảo vệ đang làm
Khóa luận	Overleaf (bản tiếng Việt trước, bản tiếng Anh sau)	Đang viết

A.8 Phân công trách nhiệm

Nhóm có bốn sinh viên, mỗi người phụ trách một mảng kỹ thuật theo đề cương (Bảng A.7). Phạm Lê Huy Hoàng là trưởng nhóm: ngoài mảng PEFT/Training, còn điều phối tiến độ và tích hợp kết quả của các mảng. Việc liên mảng, ví dụ B3 cần OCR cache của SV2 và đường ray huấn luyện của SV3, do người tạo kết quả chính chịu trách nhiệm và trưởng nhóm duyệt. Đóng góp cụ thể của từng người theo tuần được ghi trong Team Report.

Bảng A.7 Phân công

Thành viên	Vai trò	Trách nhiệm chính	Thư mục chính
Hồ Đắc Toàn (SE183249)	SV1: VLM / Baseline	Hiểu kiến trúc Qwen2.5-VL, tái lập baseline zero-shot, đối chiếu số công bố	`src/models/`, `src/eval/run_baseline.py`
Trần Quốc Huân (SE193642)	SV2: Dataset / OCR	Dữ liệu chính thức, split, kiểm tra rò rỉ, OCR cache bằng PaddleOCR và VietOCR	`data/`, `src/data/`
Phạm Lê Huy Hoàng (SE182670)	SV3: PEFT / Training; trưởng nhóm	Huấn luyện QLoRA, ablation cấu hình LoRA, adapter dùng chung; điều phối, tích hợp	`src/adaptation/`, `configs/`, `adapters/`
Văn Quang Trường (SE182458)	SV4: Evaluation / Deployment	Metric, kiểm định thống kê, hallucination, prototype và demo	`src/eval/`, `src/prototype/`

Bảng A.8 Kênh giao tiếp

Kênh	Mục đích	Tần suất
Họp với giảng viên hướng dẫn	Xác nhận các quyết định lớn, ví dụ chốt baseline Qwen2.5-VL-3B ngày 07/10/2026	Theo mốc và khi cần
Review với giảng viên phản biện	Nhận góp ý từ bên ngoài; sau mỗi review nhóm điền checklist AI_Capstone_Review123, gửi email cho GVHD và giảng viên review, tải lên thư mục chung	Hai lần
Báo cáo tuần (README và Team Report trong `docs/Wxx/`)	Ghi việc đã làm, kết quả, quyết định và việc dời	Mỗi tuần làm việc
GitHub	Mã nguồn, log nhỏ, tài liệu; mỗi commit có mô tả	Liên tục
Google Drive	Ảnh, adapter, OCR cache, video demo, ghi âm buổi review	Liên tục
Email của bộ môn	Thông báo ngày review, chỉ gửi trong tuần review	Theo mốc

A.9 Giao tiếp trong dự án

A.10 Quản lý cấu hình

Quản lý tài liệu. Tài liệu chia làm hai loại. Tài liệu theo tuần nằm trong `docs/W01` đến `docs/W15`; mỗi thư mục có README làm mục lục tuần và một Team Report. Tài liệu xuyên suốt nằm trong các thư mục đánh số: `00_admin` (quy ước, checklist), `01_proposal` (đề cương), `02_references` (literature matrix, ghi chú đọc paper), `03_report` (bản nháp các chương), `04_slides` (slide review). Mỗi tài liệu chỉ có một bản sống; thư mục tuần dẫn link tới bản đó thay vì sao chép. Tài liệu cũ được chuyển vào `_archive/` thay vì xóa.

Quản lý mã nguồn. Mã nguồn được quản lý bằng Git trên repo công khai `github.com/PLHGNAOH/ViVQA-VLM`, làm việc trên nhánh `main`; nhánh `ai-context` do GitHub Actions tự sinh để gom báo cáo. Dữ liệu, ảnh và trọng số adapter không được đưa lên Git (chặn bằng `.gitignore`) mà được lưu trên Google Drive; vị trí và mã băm được ghi trong log và trong `configs/official_models.json`. Tên lần chạy theo quy ước trong `docs/00_admin/CONVENTIONS.md` và chứa tuần, phương pháp, mô hình, tập dữ liệu, kiểu số, GPU và seed, ví dụ: `W07_B2_qlora_r16_qwen25vl_vitextvqa_ep1_bf16_L4_seed42`. Mô hình gốc được ghim theo mã revision trên Hugging Face.

Bảng A.9 Công cụ và hạ tầng

Hạng mục	Công cụ
Ngôn ngữ và thư viện	Python, PyTorch, HuggingFace Transformers, PEFT, bitsandbytes, `qwen_vl_utils`
OCR và xử lý tiếng Việt	PaddleOCR, VietOCR; pyvi để tách từ
Huấn luyện và đánh giá	Google Colab Pro: NVIDIA L4 cho huấn luyện và suy luận, Tesla T4 cho OCR (W04–W06 dùng T4 bản miễn phí)
Máy cá nhân	Windows 11, GPU 4 GB: phát triển, self-test, tiền xử lý, phân tích lỗi
Lưu trữ	Google Drive (dữ liệu, adapter, log lớn); GitHub (mã, log nhỏ, tài liệu)
Prototype	Gradio
Soạn code và tài liệu	Cursor IDE; trợ lý AI (Claude, Gemini) hỗ trợ viết code và soạn tài liệu, mọi số liệu được đối chiếu lại với log
Slide và khóa luận	Canva, PowerPoint, Google Docs, Overleaf

Ngân sách Colab được theo dõi bằng CU và ghi trong báo cáo tuần. Số CU còn lại đọc trên Colab: 146,75 (13/10), 86,52 (19/10), 49,3 (21/10), 34,96 (23/10) và 17,38 (31/10). Riêng W10, với ablation cấu hình LoRA và B3-full, dùng khoảng 37 CU.

Phụ lục B

Gói tái lập

Phụ lục này giúp một người không thuộc nhóm dựng lại mọi số chính thức của khóa luận và chạy được prototype, chỉ từ kho mã và thư mục dữ liệu trên Google Drive. Hướng dẫn đầy đủ nằm trong file `docs/REPRODUCE.md` của kho mã `github.com/PLHGNAOH/ViVQA-VLM`.

B.1 Thành phần

Bảng B.1 Thành phần của gói tái lập

Thành phần	**Vị trí**
Mã nguồn	`src/` (data, adaptation, eval, prompting, prototype)
Adapter LoRA	Drive `ViVQA-VLM/adapters/<run>/epoch_N/`, khoảng 30 MB mỗi adapter, không đưa lên git; mã băm SHA-256 ghi trong `configs/official_models.json`
Cấu hình	`configs/qwen_lora.yaml` (mô hình, lượng tử hóa, LoRA, huấn luyện, đánh giá); `configs/pope_vi_objects.json`; cấu hình OCR đóng băng trong `experiments/W08_ocr_select_dev300_L4_seed42/`
Script suy luận	`python -m src.prototype.infer` (dòng lệnh) và `python -m src.prototype.app` (giao diện Gradio)
Log thí nghiệm	`experiments/<run>/`: `metrics.json`, `predictions.json`, `run_signature.json`, `train_log.json`
Môi trường	`requirements-colab.txt`

B.2 Môi trường

Mọi lần chạy dùng Google Colab Pro: GPU L4 24 GB cho huấn luyện, đánh giá và prototype; GPU T4 cho dựng cache OCR. Thư viện chính: PyTorch 2.11.0 (CUDA 13.0, bản Colab cài sẵn), Transformers 5.17.0, PEFT 0.21.2, bitsandbytes 0.50.2, Accelerate 1.15.0, qwen-vl-utils 0.0.14 và Gradio 6.31.0. Hai lưu ý khi cài đặt:

- **PaddleOCR GPU cài chung với PyTorch** có thể ghi đè thư viện NCCL của PyTorch làm `import torch` hỏng. Các notebook có sẵn quy trình bốn bước: ghi lại các gói `nvidia-*` của PyTorch, cài Paddle, cài lại NCCL của PyTorch, rồi kiểm cả hai trong tiến trình riêng.
- **VietOCR** cài bằng `pip install -no-deps vietocr==0.3.13`, vì bản trên PyPI khóa phiên bản Pillow cũ.

Mỗi notebook được mở từ GitHub trên Colab, chọn đúng loại GPU ghi ở đầu notebook rồi chạy toàn bộ. Notebook tự kiểm mã băm của dữ liệu, cache OCR và adapter trước khi dùng GPU.

B.3 Dữ liệu

- **ViVQA**: `python -m src.data.prepare_vivqa`, cho 10.799 câu train, 1.200 câu val và 3.001 câu test cùng ảnh COCO.
- **ViTextVQA**: kho Hugging Face có kiểm soát truy cập `minhquan6203/ViTextVQA` (người tái lập cần tự xin quyền), dựng bằng notebook `00_data_vitextvqa_official.ipynb`; kết quả gồm 35.159 câu train, 5.155 câu dev và 10.028 câu test, đáp án test lấy từ `ViTextVQA_test_gt.json`.
- **Cache OCR**: notebook `10_ocr_cache_vitextvqa.ipynb` trên T4; biên bản kèm mã băm nằm ở `experiments/W10_ocr_cache_fulltrain/ocr_cache_manifest.json`.

File dữ liệu dựng lại phải trùng mã băm `data_file_sha256` ghi cho từng lần chạy trong `configs/official_models.json`.

B.4 Các mô hình chính thức

Bảng B.2 liệt kê các mô hình chính thức, notebook tái lập và mã băm adapter (12 ký tự đầu của SHA-256 file trọng số). Bảng gốc được sinh tự động từ thư mục `experiments/` bằng `python -m src.eval.repro_manifest -build`, không gõ tay.

Bảng B.2 Mô hình chính thức và notebook tái lập

Mô hình	**Kết quả chính thức**	**Notebook (L4)**	**SHA-256 adapter**
R0 · tái lập	TextVQA val: VQA-Acc 79,60	`06_r0_textvqa_repro_qwen25vl`	—
B1 · zero-shot	ViVQA EM 22,09; ViTextVQA EM 29,12	`02_run_baseline_qwen25vl`, `08_fulltest_vitextvqa_b1_b2`	—
B2 · QLoRA	ViTextVQA EM 50,26	`04_qlora_qwen25vl`, `08_fulltest_vitextvqa_b1_b2`	`2e7b17d18b32`
C3 · QLoRA ViVQA	ViVQA EM 76,64	`16_qlora_vivqa_2epoch_select_qwen25vl`	`3ceff2f7f961`
B3-full · QLoRA nhận biết OCR	ViTextVQA EM 53,35	`18_qlora_ocr_b3full_vs_b2_qwen25vl`	`c1eb9c2b4baf`
SH · dùng chung (prototype)	ViVQA EM 73,51; ViTextVQA test2000 EM 49,50	`20_qlora_shared_adapter_qwen25vl`	`c9791e961aaa`

B.5 Lệnh chạy

Mọi notebook gọi hai lệnh nền dưới đây với tham số ghi sẵn. Ví dụ cho B3-full:

```
python -m src.adaptation.train_qlora --dataset vitextvqa_official \
    --run_name <run> --epochs 1 --save_steps 100 \
    --mode ocr --ocr_backend paddledet_vietocr --ocr_template v1 \
    --ocr_max_chars 600 --ocr_min_conf 0.0

python -m src.eval.run_baseline --dataset vitextvqa_official \
    --data_file <.../test.json> --run_name <run_eval> --chunk 500 \
    --adapter <Drive>/adapters/<run>/epoch_1 \
    --mode ocr --ocr_backend paddledet_vietocr --ocr_template v1 \
    --ocr_max_chars 600 --ocr_min_conf 0.0
```

Bỏ các tham số OCR (`-mode ocr` và `-ocr_*`) thì thành B2 hoặc C3; bỏ `-adapter` thì thành B1. Cấu hình chung (bf16, 4-bit NF4, tối đa 401.408 điểm ảnh, greedy, tối đa 32

token sinh, seed 42, LoRA $r = 16$ trên q, k, v, o) nằm trong `configs/qwen_lora.yaml`. File `run_signature.json` ngăn việc chạy tiếp một lần chạy dở bằng cấu hình khác.

Các phân tích (bảng đánh giá đầy đủ, kiểm định ghép cặp, ba seed, thí nghiệm 2×2, ablation LoRA, POPE-vi, phân tích lỗi, kiểm tra EXIF) chỉ cần CPU và đọc lại `predictions.json`; lệnh và notebook tương ứng được liệt kê trong `docs/REPRODUCE.md`, mục 5.

B.6 Prototype

Giao diện chạy bằng notebook `28_prototype_v2_live_demo_sh_qwen25vl.ipynb` trên L4; notebook kiểm lại các luật R-OCR và R-LIVE rồi mở đường dẫn Gradio. Có thể chạy bằng dòng lệnh:

```
python -m src.prototype.infer --official sh \
    --drive_root /content/drive/MyDrive/ViVQA-VLM \
    --image image.jpg --question "<cau hoi>" --out result.jsonl
```

Tham số `-official sh` tự lấy adapter SH và kiểm mã băm; thêm `-mock` để thử mà không cần GPU.

B.7 Độ tất định và giới hạn đã biết

Đánh giá dùng greedy và chạy từng câu. Chạy lại trên cùng loại GPU (L4) cho dự đoán trùng 100% (ví dụ 9.902/9.902 câu ở lần kiểm tra tuần 14). Đổi loại GPU (T4 và L4) có thể làm OCR lệch nhẹ ở vài ảnh, nên cần dùng đúng loại GPU ghi trong notebook. Các giới hạn đã biết:

1. Một số thư viện (bitsandbytes, Accelerate, qwen-vl-utils) không được ghi vào log của từng lần chạy mà chỉ có trong ảnh chụp môi trường; hai lần ghi khớp nhau.

2. PyTorch là bản Colab cài sẵn; nếu Colab đổi bản mặc định, cần cài đúng phiên bản ghi trong log.

3. Cache OCR chính thức có lỗi EXIF ở 1,256% câu test ViTextVQA; số chính thức giữ nguyên, kết quả sau khi sửa được báo như phân tích độ nhạy (mục 4.7). Muốn tái lập đúng cache chính thức, dùng mã nguồn trước khi sửa (commit `b9f7fd4`).

4. ViTextVQA có kiểm soát truy cập: người tái lập phải tự xin quyền.