NGHIÊN CỨU HỆ THỐNG HỎI ĐÁP TRỰC QUAN TIẾNG VIỆT HIỆU QUẢ SỬ DỤNG MÔ HÌNH VISION-LANGUAGE

Efficient Vietnamese Visual Question Answering using Vision-Language Models



FPT UNIVERSITY

Phạm Lê Huy Hoàng – SE182670

Hồ Đắc Toàn – SE183249

Trần Quốc Huân – SE193642

Văn Quang Trường – SE182458

Giảng viên hướng dẫn: PGS. Đặng Ngọc Minh Đức

Phạm Minh Trí

Department of Artificial Intelligence

FPT University

This capstone project submitted in partial fulfillment of the requirement for the *Degree of Bachelor of Artificial Intelligence in Computer Science*

FPT University Tháng 12/2026

I would like to dedicate this thesis to my loving parents ...

Lời cam đoan

Chúng tôi cam đoan rằng, ngoại trừ những phần có trích dẫn rõ ràng công trình của người khác, nội dung của khóa luận này là kết quả làm việc của chính nhóm và chưa từng được nộp, toàn bộ hay một phần, để xét cấp bất kỳ văn bằng nào khác tại trường này hay trường khác. Khóa luận là kết quả làm việc chung của bốn thành viên ghi trên trang bìa; trách nhiệm của từng thành viên được trình bày ở Phụ lục A. Khóa luận không chứa kết quả hợp tác với người ngoài nhóm, trừ những phần được nêu rõ trong nội dung và trong lời cảm ơn.

Phạm Lê Huy Hoàng – SE182670
Hồ Đắc Toàn – SE183249
Trần Quốc Huân – SE193642
Văn Quang Trường – SE182458
Tháng 12/2026

Lời cảm ơn

Nhóm xin gửi lời cảm ơn đến PGS. Đặng Ngọc Minh Đức và thầy Phạm Minh Trí đã hướng dẫn nhóm trong suốt học kỳ, đặc biệt là yêu cầu phải có sơ đồ baseline, hiểu dữ liệu và đánh giá rõ ràng trước khi nói đến cải tiến. Nhóm cũng cảm ơn các giảng viên phản biện ở Review 1 và Review 2: các câu hỏi về bài toán, số lượng token, cách tính metric và bằng chứng so với SOTA đã định hình lại nhiều phần của khóa luận này. Cuối cùng, nhóm cảm ơn Trường Đại học FPT đã tạo môi trường học tập và tác giả của các bộ dữ liệu ViVQA và ViTextVQA đã công bố dữ liệu cho cộng đồng.

Tóm tắt

[Viết sau cùng, khi các chương đã chốt.]

Mục lục

Danh sách hình vẽ **xiii**

Danh sách bảng **xv**

Danh mục từ viết tắt **xvii**

1 GIỚI THIỆU **1**

1.1 Bối cảnh và động lực 1

1.1.1 Hỏi đáp trên ảnh và vision-language model 1

1.1.2 Tiếng Việt với các VLM thiên tiếng Anh 1

1.1.3 Ràng buộc tài nguyên 2

1.2 Phát biểu bài toán 2

1.3 Khoảng trống nghiên cứu 2

1.4 Mục tiêu 3

1.5 Câu hỏi nghiên cứu và giả thuyết 4

1.6 Đóng góp 4

1.6.1 Ý nghĩa của đề tài 5

1.7 Phạm vi và giới hạn 5

1.8 Cấu trúc khóa luận 6

2 CÁC NGHIÊN CỨU LIÊN QUAN **7**

3 DỮ LIỆU VÀ PHƯƠNG PHÁP **9**

4 KẾT QUẢ **11**

5 THẢO LUẬN **13**

6 KẾT LUẬN **15**

Tài liệu tham khảo **17**

Phụ lục A Kế hoạch quản lý dự án **19**

A.1 Phạm vi công việc và ước lượng 19
A.2 Mục tiêu quản lý 19
A.3 Rủi ro 21
A.4 Quy trình dự án 21
A.5 Quản lý chất lượng 24
A.6 Kế hoạch đào tạo 24
A.7 Sản phẩm bàn giao 25
A.8 Phân công trách nhiệm 25
A.9 Giao tiếp trong dự án 27
A.10 Quản lý cấu hình 27

Phụ lục B Gói tái lập **29**

Danh sách hình vẽ

Danh sách bảng

1.1 Mục tiêu và tiêu chí hoàn thành 3
1.2 Giả thuyết và câu hỏi nghiên cứu tương ứng 4
1.3 Trong và ngoài phạm vi 6

A.1 Phân rã công việc 20
A.2 Rủi ro đã xảy ra và cách xử lý 22
A.3 Tuần làm việc và lịch thực (năm 2026) 23
A.4 Các mốc của khoa 23
A.5 Paper nền tảng theo mảng 24
A.6 Sản phẩm bàn giao 25
A.7 Phân công 26
A.8 Kênh giao tiếp 26
A.9 Công cụ và hạ tầng 27

Danh mục từ viết tắt

Từ viết tắt

ANLS Average Normalized Levenshtein Similarity: độ giống theo ký tự

EM Exact Match: câu trả lời trùng khít với đáp án sau chuẩn hóa

LoRA Low-Rank Adaptation: thêm hai ma trận hạng thấp vào các lớp tuyến tính và chỉ huấn luyện chúng

NF4 4-bit NormalFloat: kiểu lượng tử hóa 4-bit

OCR Optical Character Recognition: nhận dạng chữ trong ảnh

PEFT Parameter-Efficient Fine-Tuning: chỉ huấn luyện một phần rất nhỏ các tham số

POPE Polling-based Object Probing Evaluation: đo hallucination bằng câu hỏi có/không

QLoRA LoRA trên mô hình nền đã lượng tử hóa 4-bit (NF4)

SOTA State of the art: kết quả tốt nhất đã công bố

VLM Vision-Language Model: mô hình nhận cả ảnh và văn bản, sinh văn bản

VQA-Acc VQA Accuracy: min(số đáp án gold trùng / 3, 1)

VQA Visual Question Answering: hỏi đáp trên ảnh

Chương 1

GIỚI THIỆU

1.1 Bối cảnh và động lực

1.1.1 Hỏi đáp trên ảnh và vision-language model

Visual Question Answering (VQA) yêu cầu hệ thống trả lời một câu hỏi bằng ngôn ngữ tự nhiên dựa trên nội dung ảnh [1]. Khác với phân loại ảnh hay phát hiện vật thể, VQA cần hiểu đồng thời ảnh, ngữ nghĩa câu hỏi và đôi khi cả chữ xuất hiện trong ảnh [2, 3]. Các hệ thống VQA ban đầu ghép một bộ mã hóa ảnh (CNN) với một bộ mã hóa câu hỏi (LSTM) và chọn đáp án từ một tập cố định. Các vision-language model (VLM) gần đây như BLIP-2 [4], LLaVA [5], Florence-2 [6] và Qwen2.5-VL [7] thay đổi cách tiếp cận: một bộ mã hóa ảnh biến ảnh thành chuỗi token, một mô hình ngôn ngữ lớn đọc chuỗi đó cùng câu hỏi và sinh câu trả lời tự do. Các VLM này trả lời được câu hỏi mở và đọc được chữ trong ảnh ở mức zero-shot.

1.1.2 Tiếng Việt với các VLM thiên tiếng Anh

Phần lớn VLM mã nguồn mở được tiền huấn luyện chủ yếu trên dữ liệu tiếng Anh và tiếng Trung. Khi dùng cho tiếng Việt, nhóm quan sát bốn vấn đề riêng, ký hiệu V1–V4 và dùng xuyên suốt khóa luận:

V1, đọc chữ có dấu trong ảnh. Dấu thanh là nét rất nhỏ; đọc sai một dấu là đổi nghĩa (“BÁNH MÌ” đọc thành “banh mi”).

V2, sai ngôn ngữ hoặc sai định dạng. Mô hình trả lời bằng tiếng Anh, chen chữ Trung, hoặc trả lời cả câu dài trong khi đáp án chỉ vài từ.

V3, thứ tự chữ và ranh giới từ. Khoảng trắng trong tiếng Việt tách âm tiết, không tách từ; đọc sai thứ tự các vùng chữ là vỡ từ ("cửa hàng điện thoại" thành "cửa điện hàng thoại").

V4, hallucination. Câu trả lời trôi chảy nhưng nói về vật hoặc chữ không có trong ảnh.

Với dữ liệu tiếng Việt, khoảng cách giữa máy và người còn lớn: trên ViTextVQA [8], kết quả công bố tốt nhất trước khóa luận này là EM 25,48, trong khi người đạt 88,00.

1.1.3 Ràng buộc tài nguyên

Huấn luyện lại toàn bộ một VLM vài tỉ tham số (full fine-tuning) cần nhiều GPU dung lượng lớn, vượt quá điều kiện của một nhóm sinh viên. Trường không có máy chủ GPU cho đề tài, nên mọi thí nghiệm chạy trên Google Colab. Đề tài vì vậy đặt hiệu quả thành một ràng buộc thiết kế tường minh: chỉ dùng parameter-efficient fine-tuning (LoRA [9], QLoRA [10]) và báo cáo kèm thời gian huấn luyện, thời gian suy luận và bộ nhớ GPU cho mọi kết quả.

1.2 Phát biểu bài toán

Cho ảnh I và câu hỏi tiếng Việt q, hệ thống sinh câu trả lời tiếng Việt $\hat{a} = f(I, q)$. Câu trả lời được so với đáp án gold a sau cùng một bước chuẩn hóa văn bản. Hai bộ dữ liệu đặt ra hai yêu cầu khác nhau:

- **ViVQA** [11]: câu hỏi chung về ảnh (màu sắc, số lượng, vật thể, vị trí); 99,83% đáp án dài không quá 3 từ, nên EM và VQA-Acc là thước đo phù hợp.
- **ViTextVQA** [8]: đáp án là chữ đọc được trong ảnh, trung bình 4,18 từ; ANLS [3] được dùng thêm vì chịu được lỗi đọc nhỏ ở mức ký tự.

Với ví dụ của ViVQA, câu hỏi "màu của xe đạp là gì?" có đáp án "màu đỏ". Với ví dụ của ViTextVQA, câu hỏi "cửa hàng có biển màu vàng là nơi nào?" có đáp án "đại lý xổ số miền Bắc", chữ lấy trực tiếp từ biển hiệu.

1.3 Khoảng trống nghiên cứu

Từ khảo sát tài liệu ở Chương 2, nhóm xác định bốn khoảng trống:

G1. Tiền huấn luyện thiên lệch tiếng Anh: mô hình zero-shot trả lời bằng tiếng Anh và sai định dạng khi gặp câu hỏi tiếng Việt.

G2. VQA tiếng Việt còn yếu, nhất là với scene-text: SOTA ViTextVQA là EM 25,48 so với 88,00 của người.

G3. Thích nghi VLM cho VQA tiếng Việt bằng PEFT chưa được nghiên cứu: các công trình VQA tiếng Việt trong nhóm khảo sát đều huấn luyện mô hình riêng hoặc dùng mô hình đóng băng, không dùng LoRA/QLoRA trên VLM lớn.

G4. Chưa có cách đo hallucination cho VQA tiếng Việt: chưa có benchmark kiểu POPE [12] bằng tiếng Việt.

Khóa luận tập trung vào G3 và dùng G2, G4 làm nơi kiểm chứng.

1.4 Mục tiêu

Mục tiêu tổng quát là thích nghi một VLM mã nguồn mở cho VQA tiếng Việt dưới ngân sách tham số nghiêm ngặt và kiểm chứng bằng thực nghiệm ít nhất một cải tiến so với baseline đã tái lập. Mục tiêu này được chia thành các mục tiêu cụ thể trong Bảng 1.1, mỗi mục tiêu có tiêu chí đo lường.

Bảng 1.1 Mục tiêu và tiêu chí hoàn thành

Mục tiêu	**Tiêu chí hoàn thành**
Tái lập đúng một baseline	Chạy lại Qwen2.5-VL-3B-Instruct trên một benchmark có số công bố và đạt sai lệch nhỏ (TextVQA val: nhóm đạt 79,60 so với 79,3 công bố)
Đo baseline zero-shot trên dữ liệu tiếng Việt	EM, VQA-Acc, ANLS trên toàn bộ test ViVQA và ViTextVQA, cùng một giao thức
Thích nghi chỉ bằng PEFT	QLoRA 4-bit, số tham số huấn luyện $< 1\%$, chạy trên một GPU Colab
Đề xuất và kiểm chứng ≥ 1 cải tiến	Cải tiến so với baseline dưới điều kiện y hệt, có kiểm định thống kê ghép cặp và ablation
Phân tích lỗi và hallucination	Phân rã lỗi theo loại câu hỏi và loại lỗi; đo hallucination kiểu POPE cho tiếng Việt
Prototype web	Tải ảnh, hỏi tiếng Việt, nhận câu trả lời kèm chữ OCR và mức tin cậy; cho cùng kết quả với đường đánh giá
Tái lập được	Mọi run ghi lại split, seed, phần cứng, siêu tham số, thời gian; gói tái lập gồm code, adapter, config, script suy luận

1.5 Câu hỏi nghiên cứu và giả thuyết

RQ1. Zero-shot đạt bao nhiêu trên ViVQA và ViTextVQA, và lỗi tiếng Việt nào chiếm ưu thế?

RQ2. QLoRA cải thiện bao nhiêu so với zero-shot, khi không dùng full fine-tuning?

RQ3. Chữ OCR có dấu, đúng thứ tự đọc, có giúp mô hình đọc chữ trong ảnh không, và có cộng hưởng với QLoRA không?

RQ4. Sau khi thích nghi bằng QLoRA, mô hình bịa nội dung nhiều hơn hay ít hơn?

Mỗi giả thuyết trong Bảng 1.2 có ngưỡng định lượng được ghi lại trước khi chạy thí nghiệm tương ứng.

Bảng 1.2 Giả thuyết và câu hỏi nghiên cứu tương ứng

ID	Giả thuyết	Trả lời
H1	QLoRA trên Qwen2.5-VL-3B tăng EM ít nhất 5 điểm so với chính mô hình đó ở chế độ zero-shot.	RQ2; V1–V3
H2	Chữ OCR có dấu, sắp xếp từ trái-trên đến phải-dưới, đưa vào prompt tăng ANLS ít nhất 3 điểm trên ViTextVQA; kết hợp với QLoRA cho kết quả cao nhất.	RQ3; V1, V3
H3	Prompt định dạng tiếng Việt (trả lời ngắn, có dấu) tăng EM ít nhất 3 điểm và giảm câu trả lời sai ngôn ngữ hoặc mất dấu.	RQ1; V2
H4	QLoRA không làm tăng tỉ lệ hallucination so với zero-shot.	RQ4; V4

1.6 Đóng góp

Nhóm chọn Qwen2.5-VL-3B-Instruct [7] làm baseline, tái lập baseline này trước, rồi thích nghi nó cho tiếng Việt chỉ bằng QLoRA. Mô hình nền 3 tỉ tham số được lượng tử hóa 4-bit và giữ nguyên; nhóm chỉ huấn luyện 7,37 triệu tham số adapter, tức 0,196% tổng số tham số, trên một GPU NVIDIA L4. Các đóng góp của khóa luận gồm:

1. **QLoRA nhận biết OCR.** Văn bản đọc được trong ảnh bằng VietOCR (giữ dấu, sắp theo thứ tự đọc) được đưa vào prompt ngay trong lúc huấn luyện, để adapter học cách dùng nó. Trên toàn bộ tập test ViTextVQA (10.028 câu), cách này đạt EM 53,35 so với 50,26 của QLoRA thông thường với cùng dữ liệu (+3,09 EM, kiểm định McNemar $p = 6{,}7 \times 10^{-21}$), và cao hơn kết quả công bố tốt nhất trên cùng tập test (ViTextBLIP-2, EM 25,48 [8]).

2. **Một cơ chế được tách bạch.** Thí nghiệm 2×2 cho thấy OCR chỉ có ích khi được dùng cả lúc huấn luyện lẫn lúc suy luận: đưa OCR vào prompt của một mô hình chưa từng thấy OCR không cải thiện kết quả.

3. **Kết quả trên VQA tiếng Việt tổng quát.** Trên ViVQA, QLoRA nâng EM từ 22,09 (zero-shot) lên 76,64.

4. **Bộ đo hallucination tiếng Việt.** POPE-vi, gồm 4.985 câu hỏi có/không trên 500 ảnh chưa thấy khi huấn luyện.

5. **Phân tích và prototype đã kiểm chứng.** Ablation cho từng thành phần, phân tích lỗi tự động và duyệt tay, và một prototype web đã được kiểm chứng cho ra cùng câu trả lời với đường đánh giá chính thức.

1.6.1 Ý nghĩa của đề tài

Ý nghĩa khoa học. Khóa luận cung cấp một nghiên cứu có hệ thống về PEFT cho VLM trên VQA tiếng Việt, gồm baseline tái lập, ablation cho từng thành phần và kiểm định thống kê ghép cặp. Kết quả chính không chỉ là một con số cao hơn mà còn là một cơ chế được tách bạch: lợi ích của OCR đến từ việc huấn luyện mô hình dùng OCR, không đến từ việc thêm OCR vào prompt. Nhóm cũng đưa ra bộ POPE tiếng Việt để đo hallucination và một phân tích có số đo cho từng vấn đề V1–V4.

Ý nghĩa thực tiễn. Hệ thống đọc và trả lời câu hỏi về biển hiệu, nhãn hàng, bảng giá, thực đơn và biểu mẫu tiếng Việt. Đây là chức năng nền cho công nghệ hỗ trợ người khiếm thị và cho các ứng dụng tra cứu thông tin từ ảnh. Vì chỉ cần một GPU và một adapter 29,5 MB, cách làm có thể áp dụng cho các nhóm hoặc tổ chức có tài nguyên hạn chế.

Ý nghĩa phương pháp. Mọi kết luận trong khóa luận dựa trên luật quyết định được ghi lại trước khi chạy, kiểm định ghép cặp trên cùng tập test, và log đầy đủ (split, seed, GPU, thời gian). Quy trình này giúp tránh việc chọn kết quả sau khi đã thấy số liệu, và cho phép người khác chạy lại từng con số từ mã nguồn công khai.

1.7 Phạm vi và giới hạn

Giả định. Nhóm giả định rằng split chính thức của hai bộ dữ liệu đại diện cho phân bố câu hỏi thực tế của từng bộ, rằng đáp án gold là đúng ở đa số câu (phần gold sai được đo và báo

Bảng 1.3 Trong và ngoài phạm vi

Trong phạm vi	Ngoài phạm vi
Hai bộ dữ liệu ViVQA và ViTextVQA, split cố định	Xây bộ dữ liệu huấn luyện mới hoặc tăng cường dữ liệu
Một baseline Qwen2.5-VL-3B-Instruct; các VLM khác chỉ để tham khảo	So sánh nhiều backbone như baseline chính
Thích nghi chỉ bằng PEFT (QLoRA 4-bit); chữ OCR làm đầu vào phụ	Full fine-tuning; huấn luyện VLM từ đầu
Metric EM, VQA-Acc, ANLS (token-F1 làm chỉ số phụ); ablation, phân tích lỗi, hallucination	Retrieval-augmented VQA với tri thức ngoài
Prototype web chạy trên Colab với một GPU	Triển khai sản phẩm quy mô lớn, ứng dụng di động

cáo riêng ở Chương 4), và rằng GPU L4 trên Colab cho kết quả ổn định giữa các phiên khi cố định seed và cấu hình.

Giới hạn biết trước. Kết quả bị giới hạn bởi một mô hình nền 3 tỉ tham số ở 4-bit và bởi chất lượng OCR; mọi thí nghiệm chính chạy với một seed, riêng phần so sánh OCR được kiểm thêm trên ba seed. EM là thước đo khắt khe với câu trả lời đúng ý nhưng khác cách viết, nên nhóm bổ sung ANLS và duyệt tay. Các giới hạn này được phân tích lại ở Chương 5 và Chương 6.

1.8 Cấu trúc khóa luận

Chương 2 tổng quan VQA, vision-language model, parameter-efficient fine-tuning và các nghiên cứu VQA tiếng Việt. Chương 3 trình bày dữ liệu, baseline, phương pháp QLoRA nhận biết OCR và giao thức đánh giá. Chương 4 báo cáo kết quả chính và các ablation. Chương 5 thảo luận phân tích lỗi, hallucination và giới hạn. Chương 6 kết luận. Phụ lục A trình bày kế hoạch quản lý dự án.

Chương 2

CÁC NGHIÊN CỨU LIÊN QUAN

[Chưa viết. Nội dung dự kiến: VQA và scene-text VQA; các vision-language model (BLIP-2, LLaVA, Florence-2, Qwen2.5-VL); parameter-efficient fine-tuning (LoRA, QLoRA); VQA tiếng Việt (ViVQA, ViTextVQA, ViTextBLIP-2); đo hallucination (POPE).]

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP

[Chưa viết. Nội dung dự kiến: dữ liệu và split; kiến trúc baseline Qwen2.5-VL-3B-Instruct; cấu hình QLoRA; prompt và huấn luyện nhận biết OCR; metric và giao thức đánh giá; thiết lập thí nghiệm.]

Chương 4

KẾT QUẢ

[Chưa viết. Nội dung dự kiến: tái lập baseline; kết quả zero-shot; kết quả QLoRA; kết quả QLoRA nhận biết OCR; ablation; hiệu quả (thời gian, bộ nhớ, token).]

Chương 5

THẢO LUẬN

[Chưa viết. Nội dung dự kiến: phân tích lỗi theo loại câu hỏi; hallucination (POPE-vi); các vấn đề tiếng Việt V1–V4; giới hạn; khía cạnh đạo đức.]

Chương 6

KẾT LUẬN

[Chưa viết. Nội dung dự kiến: trả lời RQ1–RQ4; tóm tắt đóng góp; hướng phát triển.]

Tài liệu tham khảo

[1] S. Antol, A. Agrawal, J. Lu, M. Mitchell, D. Batra, C. L. Zitnick, and D. Parikh, "VQA: Visual question answering," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015.

[2] A. Singh, V. Natarajan, M. Shah, Y. Jiang, X. Chen, D. Batra, D. Parikh, and M. Rohrbach, "Towards VQA models that can read," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

[3] A. F. Biten *et al.*, "Scene text visual question answering," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.

[4] J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023.

[5] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[6] B. Xiao *et al.*, "Florence-2: Advancing a unified representation for a variety of vision tasks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[7] S. Bai *et al.*, "Qwen2.5-VL technical report," 2025, arXiv:2502.13923.

[8] Q. V. Nguyen *et al.*, "ViTextVQA: A large-scale visual question answering dataset for evaluating Vietnamese text comprehension in images," 2024, arXiv:2404.10652.

[9] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations (ICLR)*, 2022.

[10] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[11] K. Q. Tran, A. T. Nguyen, A. T.-H. Le, and K. V. Nguyen, "ViVQA: Vietnamese visual question answering," in *Proceedings of the 35th Pacific Asia Conference on Language, Information and Computation (PACLIC)*, 2021.

[12] Y. Li, Y. Du, K. Zhou, J. Wang, W. X. Zhao, and J.-R. Wen, "Evaluating object hallucination in large vision-language models," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023.

Phụ lục A

Kế hoạch quản lý dự án

Phụ lục này mô tả cách nhóm tổ chức 15 tuần thực hiện khóa luận: phạm vi công việc, các mốc, rủi ro, cách bảo đảm chất lượng, phân công, giao tiếp và quản lý tài liệu, mã nguồn. Đề tài là một nghiên cứu nên kế hoạch xoay quanh thí nghiệm: mỗi kết luận ở Chương 4 phải truy ngược được về một lần chạy có log, seed và cấu hình cố định.

A.1 Phạm vi công việc và ước lượng

Công việc được chia thành tám gói (Bảng A.1). Thời gian tính theo tuần làm việc W01–W15 trong khung 15 tuần của đề cương; mục A.4 trình bày cách các tuần này khớp với lịch thực.

Ước lượng ban đầu ở W01 giả định có GPU server của trường. Đến W06, nhóm xác nhận trường không có GPU server, nên chi phí được ước lượng lại theo đơn vị tính toán (compute unit, CU) của Google Colab. Từ W08, trước mỗi việc cần GPU, nhóm ước tính số giờ GPU và số CU (L4 khoảng 1,54 CU/giờ, T4 khoảng 1,2 CU/giờ), rồi đối chiếu với số đọc thực tế trên Colab. Một lần huấn luyện QLoRA đầy đủ trên ViTextVQA mất khoảng 12 giờ L4 (B2: 11,99 giờ; B3-full: 12,75 giờ), nên số lần huấn luyện đầy đủ là ràng buộc lớn nhất của kế hoạch.

A.2 Mục tiêu quản lý

- **Tái lập được:** mọi lần chạy ghi split, seed, phần cứng, siêu tham số, thời gian huấn luyện và suy luận.
- **Không chọn kết quả sau khi thấy số:** luật quyết định của mỗi phép thử chính được commit lên Git trước khi chạy.

Bảng A.1 Phân rã công việc

Gói công việc	Nội dung chính	Tuần	Phụ trách chính
1. Khảo sát và định hướng	Đọc paper theo mảng, literature matrix, khoảng trống nghiên cứu, câu hỏi nghiên cứu, giả thuyết	W01–W03	Cả nhóm
2. Dữ liệu	Lấy ViVQA và ViTextVQA từ nguồn chính thức, cố định split, kiểm tra rò rỉ train/test, OCR cache	W02, W05, W08, W14	SV2
3. Baseline	Tái lập Qwen2.5-VL-3B-Instruct zero-shot (B1), đối chiếu số công bố trên TextVQA (R0), chốt cấu hình suy luận	W04–W07	SV1
4. Thích nghi bằng QLoRA	Đường ray huấn luyện QLoRA; các mô hình B2, B3, B3-full, C3, adapter dùng chung SH; ablation cấu hình LoRA	W06–W11	SV3
5. Đánh giá	EM, VQA-Acc, ANLS, F1; kiểm định McNemar ghép cặp; độ ổn định qua seed; bảng đánh giá đầy đủ	W05–W11	SV4
6. Phân tích	Error analysis, phân loại câu hỏi, hallucination POPE-vi, ngân sách token, ảnh hưởng của chuẩn hóa và tách từ lên metric	W07, W11–W12, W15	SV4, SV3
7. Prototype	Web demo, hiệu chỉnh ngưỡng có/không, kiểm tra prototype khớp hệ thống đã đánh giá, video demo	W13–W14	SV4
8. Báo cáo và bảo vệ	Báo cáo tuần, slide review, gói tái lập, khóa luận	Hằng tuần, W15	Cả nhóm, trưởng nhóm điều phối

- **Đúng ràng buộc tài nguyên:** chỉ dùng QLoRA, mọi thí nghiệm chạy được trên một GPU Colab (T4 hoặc L4).
- **Đúng mốc:** xong nghiên cứu chính trước Review 2 và hội đồng cấp khoa.

Đến hết W14, thư mục `experiments/` có 141 lần chạy, lần nào cũng có log. Sáu mô hình chính thức được liệt kê trong `configs/official_models.json`, file này sinh tự động từ log; bốn adapter lưu trên Google Drive đều khớp mã băm SHA-256 đã ghi.

A.3 Rủi ro

Kế hoạch W01 liệt kê tám rủi ro (mô hình quá lớn, thiếu GPU, dữ liệu lỗi, baseline khó tái lập, OCR kém, huấn luyện không hội tụ, demo khó triển khai, huấn luyện chậm). Bảng A.2 ghi lại các rủi ro đã thực sự xảy ra và cách nhóm xử lý.

A.4 Quy trình dự án

Nhóm làm theo chu kỳ tuần. Mỗi tuần làm việc đi qua năm bước:

1. **Lập kế hoạch:** chọn câu hỏi của tuần từ kế hoạch tổng và kết quả tuần trước, ghi vào README của tuần.
2. **Ghi luật trước:** với mỗi phép thử chính, viết luật quyết định (ngưỡng, kiểm định, tập dữ liệu) và commit lên Git trước khi chạy.
3. **Chạy:** code được viết và tự kiểm tra (self-test) trên máy cá nhân rồi đẩy lên GitHub; notebook Colab clone repo và chạy trên GPU; log, kết quả lưu trên Google Drive.
4. **Kiểm tra:** tính lại số liệu từ file dự đoán gốc (`predictions.json`) thay vì chép tay, và clone lại repo để xác minh từng commit.
5. **Đóng tuần:** cập nhật README, Team Report của tuần và bản nháp các chương liên quan.

Tuần làm việc W01–W15 được đánh số theo nội dung trong khung của đề cương, không theo lịch. Nhóm làm nhanh hơn lịch: ngày 02/11/2026 (tuần thực 9), nhóm đã sang W15. Tuần thực tính từ thứ Hai 07/09/2026 là tuần 1. Bảng A.3 đối chiếu hai cách đếm.

Các mốc của khoa giữ nguyên theo lịch thực (Bảng A.4). Điểm khóa luận gồm 50% quá trình, trong đó nhóm nộp 7 báo cáo cho giảng viên hướng dẫn, và 50% bảo vệ.

Bảng A.2 Rủi ro đã xảy ra và cách xử lý

Rủi ro	**Tuần**	**Mức**	**Cách xử lý**
Trường không có GPU server	W06	Cao	Chuyển toàn bộ huấn luyện sang Colab; nâng lên Colab Pro ngày 07/10/2026 để dùng L4
fp16 trên T4 làm hỏng câu trả lời	W06	Cao	Dò kiểu số trên 73 câu: fp16 hỏng 23 câu; chuyển sang bf16 trên L4 (0/73 câu hỏng)
Dữ liệu sai nguồn	W05	Cao	Dữ liệu trên máy là ViVQA-X chứ không phải ViVQA, còn ViTextVQA lấy từ bản sao không chính thức. Tải lại ViVQA từ repo gốc, xin quyền kho gated của ViTextVQA, dùng đáp án `test_gt.json`
Một lần huấn luyện đầy đủ tốn khoảng 12 giờ	W08	Trung bình	Chạy phép thử chính trên tập con 8.000 câu (B3 so với B2-sub); chỉ chạy bản đầy đủ B3-full ở W10 khi kết quả tập con đã rõ
Thư viện đổi API	W06	Thấp	`transformers` 5.17.0 bỏ `warmup_ratio`; đổi sang `warmup_steps`, ghi phiên bản thư viện vào log
PaddleOCR bản GPU xung đột với torch trong prototype	W13	Trung bình	Chạy OCR trong một tiến trình riêng (`src/prototype/ocr_worker.py`)
Adapter dùng chung thiên về trả lời "có"	W12–W13	Trung bình	Chọn ngưỡng trên logit token đầu bằng tập calibration tách rời tập POPE-vi
Ảnh có cờ xoay EXIF làm sai OCR cache	W14	Trung bình	Kiểm tra theo luật ghi trước (164/165 ảnh có cờ xoay bị lệch); sửa `ocr.py`, OCR lại 167 ảnh, suy luận lại B3-full (EM 53,35 $\rightarrow$ 53,63)
Lịch review thay đổi	W10	Thấp	Review 2 dời sang 29/10/2026; nhóm cập nhật một bộ slide cộng dồn thay vì làm lại

Bảng A.3 Tuần làm việc và lịch thực (năm 2026)

Tuần	**Nội dung chính**	**Thời gian thực**
W01–W02	Định hướng, kế hoạch 15 tuần, literature matrix, phân tích dữ liệu	07–16/09
W03	Hồ sơ Review 1	17/09 (Review 1: 24/09)
W04	Baseline zero-shot đầu tiên; đổi baseline sang Qwen2.5-VL-3B	18–21/09
W05	Dữ liệu chính thức; baseline zero-shot trên cả hai tập	22–27/09
W06	Chẩn đoán lỗi fp16; đường ray QLoRA	28–29/09
W07	Chốt cấu hình trên L4; B1 chính thức; B2; tái lập R0	30/09–12/10
W08	OCR-enhanced prompting; B3 trên tập con	12–14/10
W09	Ổn định qua seed; bảng 2×2; ViVQA 2 epoch	15–17/10
W10	Ablation cấu hình LoRA; B3-full	19–21/10
W11	Bảng đánh giá đầy đủ; adapter dùng chung	21–22/10
W12	Hallucination POPE-vi; error analysis	23–24/10
W13	Prototype web	26–31/10
W14	Hoàn thiện code, video demo, gói tái lập	01–02/11
W15	Góp ý Review 2, slide bảo vệ, khóa luận	từ 02/11

Bảng A.4 Các mốc của khoa

Mốc	**Thời gian**	**Nội dung**	**Trạng thái**
Review 1	24/09/2026 (tuần thực 3)	Bài toán, khoảng trống, câu hỏi nghiên cứu, kế hoạch; hai giảng viên không phải GVHD nhận xét	Đã qua, 10 góp ý
Review 2	29/10/2026 (tuần thực 8)	Baseline đã tái lập, phương pháp, kết quả sơ bộ	Đã qua
Hội đồng cấp Khoa/Bộ môn	30/11–06/12/2026 (tuần thực 13)	Ba thành viên, 60 phút mỗi nhóm	Chưa diễn ra
Hội đồng cấp trường	14–20/12/2026 (tuần thực 15)	Năm thành viên	Chưa diễn ra

A.5 Quản lý chất lượng

Trong đề tài này, chất lượng trước hết là độ tin cậy của con số. Nhóm dùng năm biện pháp:

- **Luật ghi trước:** ngưỡng và cách kết luận cho mỗi phép thử chính được commit trước khi có kết quả, ví dụ luật cho adapter dùng chung (commit `324caeb`, W11) và luật hallucination H4 (commit `9209170`, W12).
- **Kiểm định ghép cặp:** mọi so sánh hai mô hình trên cùng tập test dùng McNemar trên từng câu cho EM và khoảng tin cậy 95% bằng bootstrap ghép cặp cho ANLS; kết quả chính được lặp lại với seed 42, 43 và 44.
- **Tính lại từ dữ liệu gốc:** bảng kết quả cuối (`src/eval/full_eval_table.py`) đọc trực tiếp các file `predictions.json`, không chép số từ báo cáo tuần.
- **Self-test:** các module chính có chế độ `--selftest` chạy trên CPU, cả Windows lẫn Linux, để bắt lỗi trước khi tốn GPU.
- **Mã băm và chữ ký run:** adapter, OCR cache, file dữ liệu và slide được ghi mã SHA-256; mỗi run mang chữ ký cấu hình nên script không ghi tiếp kết quả của cấu hình khác vào cùng thư mục.

A.6 Kế hoạch đào tạo

Đề tài cần kiến thức ở bốn mảng khác nhau, nên ở W01 mỗi thành viên đọc ít nhất ba paper thuộc mảng của mình và trả lời 10 câu hỏi cố định cho mỗi paper, trong đó bắt buộc có câu "dùng được gì cho đề tài" (Bảng A.5).

Bảng A.5 Paper nền tảng theo mảng

Mảng	Paper đã đọc
SV1: VLM / Baseline	BLIP-2, Florence-2, Qwen2.5-VL
SV2: Dataset / OCR	ViVQA, ViTextVQA, TextVQA (LoRRA)
SV3: PEFT / Training	LoRA, QLoRA, VL-Adapter, LLaVA-1.5
SV4: Evaluation / Deployment	POPE, VQAv2, Survey Vision-Language Models (TPAMI 2024)

Những kỹ năng còn lại nhóm học trong quá trình làm: huấn luyện QLoRA với PEFT và bitsandbytes, PaddleOCR và VietOCR, kiểm định McNemar, và cách làm việc giữa máy cá nhân, GitHub, Colab và Google Drive. Sổ thuật ngữ song ngữ `docs/Glossary.md` được cập nhật suốt dự án.

A.7 Sản phẩm bàn giao

Bảng A.6 liệt kê sản phẩm theo yêu cầu của đề cương, gồm cả gói tái lập. Trạng thái tính đến ngày 10/11/2026.

Bảng A.6 Sản phẩm bàn giao

Sản phẩm	Vị trí	Trạng thái
Mã nguồn: 46 module Python (dữ liệu, huấn luyện, đánh giá, prototype)	`src/` trên GitHub (PLHGNAOH/ViVQA-VLM)	Hoàn thành
30 notebook Colab	`notebooks/`	Hoàn thành
Log 141 lần chạy	`experiments/`	Hoàn thành
Adapter QLoRA của các mô hình chính thức	Google Drive; mã băm trong `configs/official_models.json`	Hoàn thành
Gói tái lập: hướng dẫn, phiên bản thư viện, script suy luận	`docs/REPRODUCE.md`, `requirements-colab.txt`, `src/prototype/infer.py`	Hoàn thành
Prototype web và video demo (10 phút 28 giây)	`src/prototype/`, Google Drive	Hoàn thành
Báo cáo tuần W01–W15	`docs/W01/` đến `docs/W15/`	W15 đang làm
Slide Review 1, Review 2 (tiếng Anh, tiếng Việt)	`docs/W03/`, `docs/04_slides/`	Hoàn thành; slide bảo vệ đang làm
Khóa luận	Overleaf (bản tiếng Việt trước, bản tiếng Anh sau)	Đang viết

A.8 Phân công trách nhiệm

Nhóm có bốn sinh viên, mỗi người phụ trách một mảng kỹ thuật theo đề cương (Bảng A.7). Phạm Lê Huy Hoàng là trưởng nhóm: ngoài mảng PEFT/Training, còn điều phối tiến độ và tích hợp kết quả của các mảng. Việc liên mảng, ví dụ B3 cần OCR cache của SV2 và đường ray huấn luyện của SV3, do người tạo kết quả chính chịu trách nhiệm và trưởng nhóm duyệt. Đóng góp cụ thể của từng người theo tuần được ghi trong Team Report.

Bảng A.7 Phân công

Thành viên	Vai trò	Trách nhiệm chính	Thư mục chính
Hồ Đắc Toàn (SE183249)	SV1: VLM / Baseline	Hiểu kiến trúc Qwen2.5-VL, tái lập baseline zero-shot, đối chiếu số công bố	`src/models/`, `src/eval/run_baseline.py`
Trần Quốc Huân (SE193642)	SV2: Dataset / OCR	Dữ liệu chính thức, split, kiểm tra rò rỉ, OCR cache bằng PaddleOCR và VietOCR	`data/`, `src/data/`
Phạm Lê Huy Hoàng (SE182670)	SV3: PEFT / Training; trưởng nhóm	Huấn luyện QLoRA, ablation cấu hình LoRA, adapter dùng chung; điều phối, tích hợp	`src/adaptation/`, `configs/`, `adapters/`
Văn Quang Trường (SE182458)	SV4: Evaluation / Deployment	Metric, kiểm định thống kê, hallucination, prototype và demo	`src/eval/`, `src/prototype/`

Bảng A.8 Kênh giao tiếp

Kênh	Mục đích	Tần suất
Họp với giảng viên hướng dẫn	Xác nhận các quyết định lớn, ví dụ chốt baseline Qwen2.5-VL-3B ngày 07/10/2026	Theo mốc và khi cần
Review với giảng viên phản biện	Nhận góp ý từ bên ngoài; sau mỗi review nhóm điền checklist AI_Capstone_Review123, gửi email cho GVHD và giảng viên review, tải lên thư mục chung	Hai lần
Báo cáo tuần (README và Team Report trong `docs/Wxx/`)	Ghi việc đã làm, kết quả, quyết định và việc dời	Mỗi tuần làm việc
GitHub	Mã nguồn, log nhỏ, tài liệu; mỗi commit có mô tả	Liên tục
Google Drive	Ảnh, adapter, OCR cache, video demo, ghi âm buổi review	Liên tục
Email của bộ môn	Thông báo ngày review, chỉ gửi trong tuần review	Theo mốc

A.9 Giao tiếp trong dự án

A.10 Quản lý cấu hình

Quản lý tài liệu. Tài liệu chia làm hai loại. Tài liệu theo tuần nằm trong `docs/W01` đến `docs/W15`; mỗi thư mục có README làm mục lục tuần và một Team Report. Tài liệu xuyên suốt nằm trong các thư mục đánh số: `00_admin` (quy ước, checklist), `01_proposal` (đề cương), `02_references` (literature matrix, ghi chú đọc paper), `03_report` (bản nháp các chương), `04_slides` (slide review). Mỗi tài liệu chỉ có một bản sống; thư mục tuần dẫn link tới bản đó thay vì sao chép. Tài liệu cũ được chuyển vào `_archive/` thay vì xóa.

Quản lý mã nguồn. Mã nguồn được quản lý bằng Git trên repo công khai `github.com/PLHGNAOH/ViVQA-VLM`, làm việc trên nhánh `main`; nhánh `ai-context` do GitHub Actions tự sinh để gom báo cáo. Dữ liệu, ảnh và trọng số adapter không được đưa lên Git (chặn bằng `.gitignore`) mà được lưu trên Google Drive; vị trí và mã băm được ghi trong log và trong `configs/official_models.json`. Tên lần chạy theo quy ước trong `docs/00_admin/CONVENTIONS.md` và chứa tuần, phương pháp, mô hình, tập dữ liệu, kiểu số, GPU và seed, ví dụ: `W07_B2_qlora_r16_qwen25vl_vitextvqa_ep1_bf16_L4_seed42`. Mô hình gốc được ghim theo mã revision trên Hugging Face.

Bảng A.9 Công cụ và hạ tầng

Hạng mục	**Công cụ**
Ngôn ngữ và thư viện	Python, PyTorch, HuggingFace Transformers, PEFT, bitsandbytes, `qwen_vl_utils`
OCR và xử lý tiếng Việt	PaddleOCR, VietOCR; pyvi để tách từ
Huấn luyện và đánh giá	Google Colab Pro: NVIDIA L4 cho huấn luyện và suy luận, Tesla T4 cho OCR (W04–W06 dùng T4 bản miễn phí)
Máy cá nhân	Windows 11, GPU 4 GB: phát triển, self-test, tiền xử lý, phân tích lỗi
Lưu trữ	Google Drive (dữ liệu, adapter, log lớn); GitHub (mã, log nhỏ, tài liệu)
Prototype	Gradio
Soạn code và tài liệu	Cursor IDE; trợ lý AI (Claude, Gemini) hỗ trợ viết code và soạn tài liệu, mọi số liệu được đối chiếu lại với log
Slide và khóa luận	Canva, PowerPoint, Google Docs, Overleaf

Ngân sách Colab được theo dõi bằng CU và ghi trong báo cáo tuần. Số CU còn lại đọc trên Colab: 146,75 (13/10), 86,52 (19/10), 49,3 (21/10), 34,96 (23/10) và 17,38 (31/10). Riêng W10, với ablation cấu hình LoRA và B3-full, dùng khoảng 37 CU.

Phụ lục B

Gói tái lập

[Chưa viết. Nội dung dự kiến: cấu trúc repo, môi trường, các mô hình chính thức và mã băm adapter, lệnh chạy lại từng bảng kết quả.]